Wahrscheinlichkeit 2

Bedingte Wahrscheinlichkeit und der Satz von Bayes

In Skript 1 haben wir Wahrscheinlichkeiten gezählt, addiert und multipliziert. Heute kommt eine neue Frage dazu: **Wie ändert sich eine Wahrscheinlichkeit, wenn wir schon etwas wissen?** Genau diese Frage steckt hinter jedem Spamfilter, jedem Virenscanner und jedem Alarm im Monitoring.

Schritt	Frage	Abschnitt
Bedingen	Was ändert sich, wenn ich schon etwas weiß?	1
Ordnen	Wie halte ich zwei Merkmale übersichtlich fest?	2
Verbinden	Was hat das mit dem Baumdiagramm zu tun?	3
Trennen	Wann hängen zwei Ereignisse nicht zusammen?	4
Umdrehen	Wie schließe ich vom Alarm auf die Ursache?	5
Prüfen	Welche Fallen lauern beim Bedingen?	6

> **Heute:** Zuerst rechnen wir mit Vierfeldertafeln und Bäumen von Hand. Dann filtert ihr in Pandas und lasst 100 000 Dateien durch einen erfundenen Virenscanner laufen.

1 – Wenn man schon etwas weiß

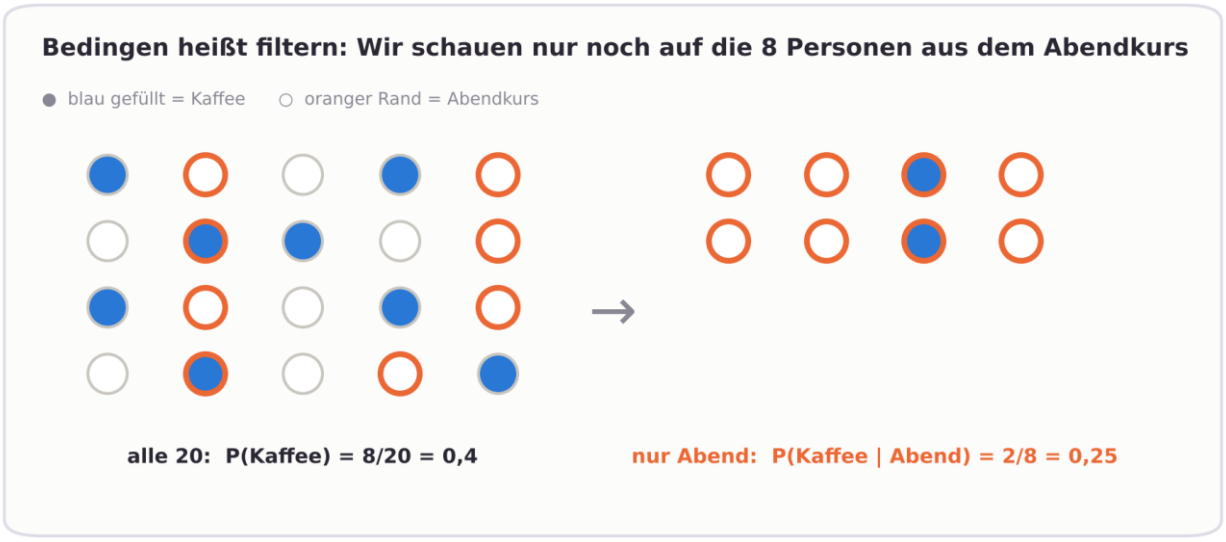


Herr Bauchgefühl behauptet:
„40 % unserer Leute trinken Kaffee. Wenn ich jemanden aus dem Abendkurs auslose, trinkt er also mit 40 % Kaffee."

Die Kreuztabelle der Kurs-Umfrage kennt ihr schon:

	Kaffee	Tee	Mate	Wasser	gesamt
Abend	2	3	1	2	8
Vormittag	6	2	3	1	12
gesamt	8	5	4	3	20

Unter allen 20 Personen trinken 8 Kaffee, das sind 40 %. Wissen wir aber schon, dass die Person aus dem **Abendkurs** kommt, bleiben nur noch 8 Personen übrig. Von ihnen trinken 2 Kaffee: **2/8 = 25 %**.



1.1 – Die Schreibweise. Man schreibt **P(Kaffee | Abend)** und liest: „Wahrscheinlichkeit für Kaffee **unter der Bedingung** Abendkurs“ oder kürzer „Kaffee, wenn Abend“. Hinter dem senkrechten Strich steht, was schon feststeht.

$$P(A \mid B) = P(A \cap B) / P(B)$$

Bei abzählbaren Daten geht es noch einfacher: **Anzahl in A und B / Anzahl in B**. Die Bedingung B wird zum neuen, kleineren Ergebnisraum.

$$P(\text{Kaffee} \mid \text{Abend}) = 2/8 = 0{,}25 \qquad P(\text{Kaffee} \mid \text{Vormittag}) = 6/12 = 0{,}5$$

1.2 – Die Reihenfolge zählt. P(A | B) und P(B | A) sind zwei verschiedene Fragen mit verschiedenen Antworten:

Frage	Schreibweise	Rechnung	Ergebnis
Wie viele Vormittags-Leute trinken Kaffee?	P(Kaffee | Vormittag)	6 / 12	0,5
Wie viele Kaffeetrinker kommen vormittags?	P(Vormittag | Kaffee)	6 / 8	0,75

Gleicher Zähler, anderer Nenner. Der Nenner ist immer die Bedingung.



Etta sagt:
„Das kenne ich aus Statistik 1: Zeilenprozente heißen, die Zeile ist die Bedingung. Spaltenprozente heißen, die Spalte ist die Bedingung. Bedingte Wahrscheinlichkeiten hatten wir also längst.“

Andere Schreibweise: Manche Schulbücher schreiben P_B(A) statt P(A | B). Das ist dasselbe. Wir bleiben bei P(A | B), so steht es auch in Pandas-Tutorials und in fast allen englischen Quellen.



Herr Bauchgefühl stutzt:
„Im Abendkurs nur 25 %? Dann stelle ich die Kaffeemaschine wohl besser in den Vormittagsraum.“

Zum Weiterlesen: Bedingte Wahrscheinlichkeit – Formel, Vierfeldertafel, Beispiele und Selbsttest

2 – Die Vierfeldertafel

Haben beide Merkmale nur zwei Ausprägungen (ja/nein), wird aus der Kreuztabelle eine **Vierfeldertafel**: vier Felder in der Mitte, dazu die Summen am Rand. Beispiel aus der Kurs-Umfrage: Haustier ja oder nein, Abend oder Vormittag.

	Haustier	kein Haustier	gesamt
Abend	4	4	8
Vormittag	7	5	12
gesamt	11	9	20

2.1 – Mit Anzahlen oder mit Wahrscheinlichkeiten. Teilt man jedes Feld durch 20, steht in der Tafel die Wahrscheinlichkeit für jede Kombination. Die Mitte enthält die „und“-Wahrscheinlichkeiten, der Rand die einfachen Wahrscheinlichkeiten.

	Haustier	kein Haustier	gesamt
Abend	$P(A \cap H) = 0{,}20$	0,20	$P(A) = 0{,}40$
Vormittag	0,35	0,25	0,60
gesamt	$P(H) = 0{,}55$	0,45	1

2.2 – Bedingt ablesen. Für eine bedingte Wahrscheinlichkeit nimmt man ein Feld aus der Mitte und teilt durch den passenden Rand:

$$P(\text{Haustier} \mid \text{Abend}) = 0{,}20 / 0{,}40 = 0{,}5 \qquad P(\text{Haustier} \mid \text{Vormittag}) = 0{,}35 / 0{,}60 \approx 0{,}583$$

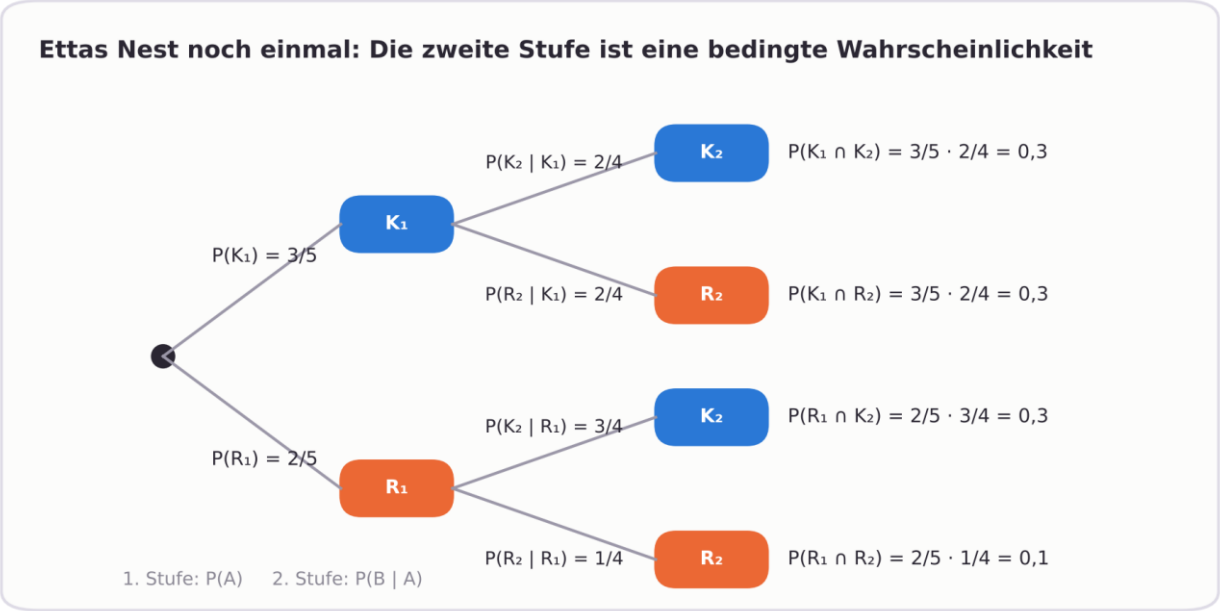
2.3 – Lücken füllen. Jede Zeile und jede Spalte muss ihre Randsumme ergeben. Deshalb reichen oft drei bis vier bekannte Zahlen, um die ganze Tafel auszufüllen. Das ist eine typische Prüfungsaufgabe (Übung 3).



Nils sagt:
„Ich prüfe immer zuerst die Ecke unten rechts. Steht da nicht die Gesamtzahl oder 1, habe ich mich verzählt.“

3 – Baumdiagramm und bedingte Wahrscheinlichkeit

Erinnert ihr euch an Ettas Nest aus Skript 1? Drei Knöpfe, zwei Ringe, zweimal ziehen ohne Zurücklegen. Die Zahlen in der zweiten Stufe hingen davon ab, was beim ersten Zug passiert war. Jetzt haben sie einen Namen: Es sind **bedingte Wahrscheinlichkeiten**.



3.1 – Der Multiplikationssatz. Die erste Pfadregel aus Skript 1 ist eigentlich die Formel aus Abschnitt 1, nur umgestellt:

$$P(A \cap B) = P(A) \cdot P(B \mid A)$$

Entlang eines Pfades multipliziert man also immer: erste Stufe P(A) mal zweite Stufe P(B | A).

3.2 – Baum und Vierfeldertafel sind zwei Ansichten. Die vier Pfade am Ende des Baums sind genau die vier Felder in der Mitte einer Vierfeldertafel. Der Baum zeigt, **wie** es dazu kommt (erst A, dann B). Die Tafel zeigt alles auf einen Blick und lässt sich auch „von der anderen Seite“ lesen. Das brauchen wir in Abschnitt 5.

	2. Zug Knopf	2. Zug Ring	gesamt
1. Zug Knopf	0,3	0,3	0,6
1. Zug Ring	0,3	0,1	0,4
gesamt	0,6	0,4	1



Etta sagt:
„Im Baum sehe ich meine Reihenfolge. In der Tafel sehe ich mein ganzes Nest. Ich nehme, was gerade passt.“

Zum Weiterlesen: Multiplikationssatz – unabhängige und abhängige Ereignisse

4 – Unabhängigkeit



Herr Bauchgefühl behauptet:
„Wer abends kommt, hat seltener ein Haustier: 50 % gegen 58 %. Der Abendkurs macht also haustierfrei!“

4.1 – Die Definition. Zwei Ereignisse heißen **unabhängig**, wenn das Wissen über das eine nichts an der Wahrscheinlichkeit des anderen ändert:

$$P(A \mid B) = P(A) \qquad \text{gleichbedeutend:} \qquad P(A \cap B) = P(A) \cdot P(B)$$

Die zweite Form ist praktisch zum Prüfen: Man multipliziert die beiden Randwerte und vergleicht mit dem Feld in der Mitte.

Beispiel	unabhängig?	Warum
Zwei Würfelwürfe	ja	Der Würfel hat kein Gedächtnis (Skript 1, Abschnitt 6).
Ettas Nest **mit** Zurücklegen	ja	Die zweite Stufe sieht genauso aus wie die erste.
Ettas Nest **ohne** Zurücklegen	nein	Nach einem Ring ist ein Ring weniger im Nest.
Regen heute und Regen morgen	nein	Wetterlagen dauern oft mehrere Tage.

4.2 – Prüfen mit echten Daten. Für die Haustiere: P(Abend) · P(Haustier) = 0,40 · 0,55 = **0,22**. In der Tafel steht P(Abend ∩ Haustier) = **0,20**. Nicht exakt gleich, also streng genommen abhängig. Aber bei nur 20 Personen ist so ein kleiner Unterschied ganz normal. Eine einzige Person mehr mit Haustier im Abendkurs, und es wären 0,25.



Der Ausreißer meldet sich:
„Bei 20 Leuten reicht ein einziger Kater, um eine Quote zu verschieben. Ob ein Unterschied Zufall ist oder nicht, klärt erst ein Test. Der kommt in Kapitel 5.“

4.3 – Unabhängig ist nicht unvereinbar. Diese beiden Wörter werden ständig verwechselt. Sie meinen fast das Gegenteil:

	unvereinbar	unabhängig
Bedeutung	können nicht gleichzeitig eintreten	beeinflussen sich nicht
Formel	$P(A \cap B) = 0$	$P(A \cap B) = P(A) \cdot P(B)$
Beispiel Würfel	„eine 1“ und „eine 6“ beim selben Wurf	„6 im 1. Wurf“ und „6 im 2. Wurf“

> **Merke:** Unvereinbare Ereignisse sind immer **abhängig**. Weiß ich, dass eine 1 gewürfelt wurde, weiß ich sicher, dass es keine 6 ist. Das Wissen hat die Wahrscheinlichkeit also von 1/6 auf 0 geändert.



Herr Bauchgefühl stutzt:
„Zwei Haustiere Unterschied bei 20 Leuten. Na gut, das ist wohl kein Naturgesetz."

Zum Weiterlesen: Bedingte Wahrscheinlichkeit und Unabhängigkeit – Produktsatz, Pfadregeln

5 – Der Satz von Bayes

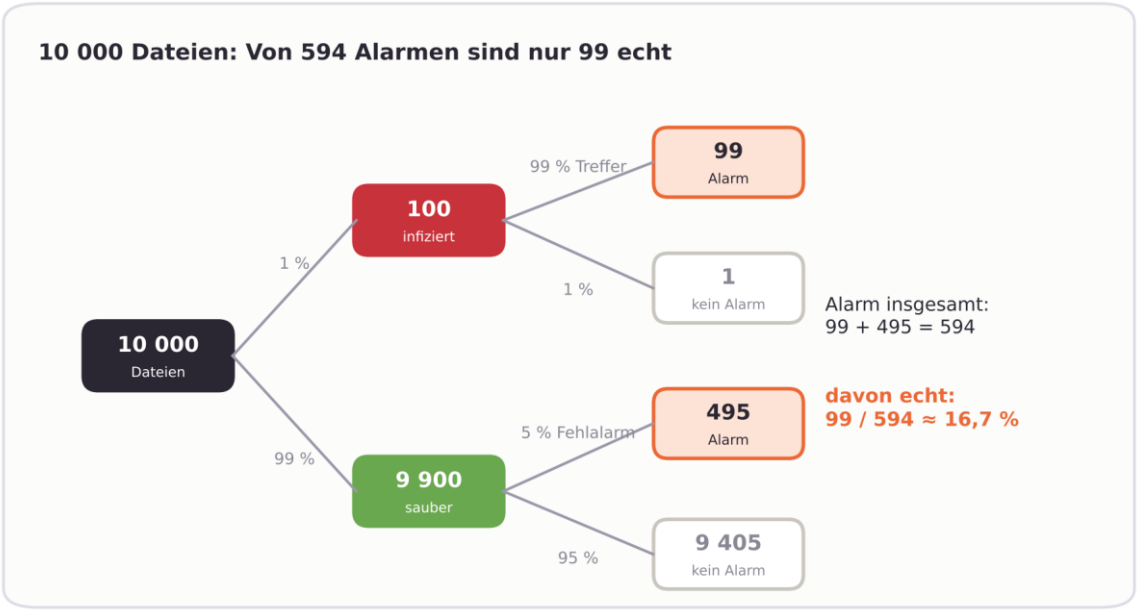


Herr Bauchgefühl behauptet:
„Unser Virenscanner erkennt 99 % aller Viren. Er hat gerade bei einer Datei Alarm geschlagen. Also ist sie zu 99 % ein Virus, ich lösche sofort."

Die Zahlen des Scanners: 1 % aller Dateien ist wirklich infiziert. Bei einer infizierten Datei schlägt er in 99 % der Fälle Alarm (**Trefferquote**). Bei einer sauberen Datei schlägt er in 5 % der Fälle trotzdem Alarm (**Fehlalarm**).

Herr Bauchgefühl kennt **P(Alarm | Virus) = 0,99**. Er will aber wissen: **P(Virus | Alarm)**. Das ist die umgedrehte Bedingung, und die kann ganz anders aussehen.

5.1 – Der einfachste Weg: mit Anzahlen rechnen. Statt mit Prozenten zu jonglieren, stellen wir uns 10 000 Dateien vor:



	Alarm	kein Alarm	gesamt
infiziert	99	1	100
sauber	495	9 405	9 900
gesamt	594	9 406	10 000

Es gibt 594 Alarme. Davon sind nur 99 echt: **99 / 594 ≈ 0,167**. Nur jeder sechste Alarm ist wirklich ein Virus!



Mats sagt:
„Ich bin die **Basisrate**: Nur 1 von 100 Dateien ist infiziert. Von hier unten sehe ich, was oben keiner sieht. Es gibt so viele saubere Dateien, dass schon 5 % Fehlalarm fünfmal mehr Alarme machen als alle echten Viren zusammen."

5.2 – Die Formel. Dasselbe als Formel heißt **Satz von Bayes**, nach dem englischen Pfarrer und Mathematiker Thomas Bayes:

$$P(A \mid B) = P(B \mid A) \cdot P(A) / P(B)$$

Den Nenner P(B) bekommt man aus dem Baum: alle Pfade, die zu B führen, addieren (zweite Pfadregel). Das heißt auch **Satz von der totalen Wahrscheinlichkeit**.

$$P(\text{Alarm}) = 0{,}01 \cdot 0{,}99 + 0{,}99 \cdot 0{,}05 = 0{,}0099 + 0{,}0495 = 0{,}0594$$

$$P(\text{Virus} \mid \text{Alarm}) = 0{,}0099 / 0{,}0594 \approx 0{,}167$$

Begriff	Bedeutung im Beispiel	Wert
Basisrate (Vorwissen)	P(Virus): so häufig ist das Gesuchte überhaupt	0,01
Trefferquote	P(Alarm | Virus)	0,99
Fehlalarm-Quote	P(Alarm | sauber)	0,05
Ergebnis (neues Wissen)	P(Virus | Alarm)	≈ 0,167

5.3 – Ein zweiter Scan. Bayes lässt sich wiederholen: Das Ergebnis wird zum neuen Vorwissen. Prüft ein zweiter, unabhängiger Scanner mit denselben Quoten die verdächtige Datei und schlägt auch Alarm, steigt die Wahrscheinlichkeit von 16,7 % auf rund **80 %**. Deshalb lässt man verdächtige Dateien in der Praxis von mehreren Scannern prüfen, bevor man löscht.

5.4 – Wo Bayes überall steckt. Spamfilter (Wie wahrscheinlich ist Spam, wenn „Gewinn" im Betreff steht?), Betrugserkennung bei Kartenzahlungen, Alarme im Server-Monitoring, medizinische Tests und viele Verfahren im maschinellen Lernen.



Herr Bauchgefühl stutzt:
„Nur jeder sechste Alarm ist echt? Dann lösche ich ab jetzt nicht mehr sofort alles, sondern scanne erst noch einmal."

Zum Weiterlesen: [Satz von Bayes – Formel, Werke-Beispiel, Selbsttest]

6 – Fallen beim Bedingen

6.1 – Die Bedingung vertauschen. „99 % der Viren lösen Alarm aus“ ist nicht dasselbe wie „99 % der Alarme sind Viren“. Das ist der häufigste Fehler überhaupt, auch in Zeitungen und vor Gericht.

6.2 – Die Basisrate vergessen. Je seltener das Gesuchte, desto mehr Fehlalarme. Bei einer Basisrate von 0,1 % statt 1 % wäre selbst bei 99 % Trefferquote und nur 1 % Fehlalarm nicht einmal jeder zehnte Alarm echt (Übung 11).

6.3 – Eine Bedingung fehlt. Aus Statistik 7 kennt ihr das Simpson-Paradoxon: Ohne die Bedingung „Vorwissen“ sah Plattform B besser aus, mit ihr Plattform A. Auch das ist bedingte Wahrscheinlichkeit, und auch dort hat Mats die versteckte Variable gespielt.



Herr Bauchgefühl behauptet:
„90 % aller Hacker benutzen Linux. Wer Linux benutzt, ist also verdächtig.“

Hier ist die Bedingung vertauscht. 90 % ist P(Linux | Hacker). Für einen Verdacht bräuchte man P(Hacker | Linux). Weil fast alle Linux-Nutzer ganz normale Admins, Entwickler und Studierende sind, ist dieser Wert winzig.



Herr Bauchgefühl stutzt:
„Dann hätte ich mich gerade selbst verdächtigt. Mein Laptop läuft nämlich auch mit Linux.“

Auf einen Blick

Begriff	Bedeutung / Formel
bedingte Wahrscheinlichkeit	$P(A \mid B) = P(A \cap B) / P(B)$; die Bedingung wird zum neuen Ergebnisraum
Reihenfolge	$P(A \mid B) \neq P(B \mid A)$; der Nenner ist immer die Bedingung
Vierfeldertafel	Mitte: „und“-Werte, Rand: einfache Werte; bedingt = Feld / Rand
Multiplikationssatz	$P(A \cap B) = P(A) \cdot P(B \mid A)$; zweite Stufe im Baum ist bedingt
unabhängig	$P(A \mid B) = P(A)$, gleichbedeutend $P(A \cap B) = P(A) \cdot P(B)$
unvereinbar	$P(A \cap B) = 0$; unvereinbare Ereignisse sind abhängig
Satz von Bayes	$P(A \mid B) = P(B \mid A) \cdot P(A) / P(B)$; am einfachsten mit 10 000 gedachten Fällen
Basisrate	wie häufig das Gesuchte überhaupt ist; seltene Ereignisse bedeuten viele Fehlalarme

Übungen

Du brauchst Stift und Taschenrechner. Für Übung 5 gibt es eine Vorlage zum Hineinzeichnen.

Übung 1 Bedingt in der Kurs-Umfrage

Gehört zu Abschnitt 1.

Benutze die Kreuztabelle aus Abschnitt 1.

a) Berechne P(Tee | Abend) und P(Abend | Tee).

---

b) Berechne P(Mate | Vormittag) und P(Vormittag | Mate).

---

c) Welche der vier Zahlen sind Zeilenprozente, welche Spaltenprozente?

Übung 2 Übersetzen

Gehört zu Abschnitt 1.

Schreibe jede Frage in der Form P(… | …).

Frage	Schreibweise
Welcher Anteil der Teetrinker kommt abends?	
Welcher Anteil der Abend-Leute trinkt Tee?	
Wie viele der fehlgeschlagenen Logins kamen aus dem Ausland?	
Wie oft schlägt ein Login aus dem Ausland fehl?	
Wie viele der Spam-Mails enthalten das Wort „Gewinn“?	

Übung 3 Die Vierfeldertafel vervollständigen

Gehört zu Abschnitt 2.

Ein Onlineshop hatte 400 Bestellungen. 240 wurden mit PayPal bezahlt, der Rest auf Rechnung. Insgesamt wurden 60 Bestellungen zurückgeschickt, davon 20 PayPal-Bestellungen.

	Retoure	keine Retoure	gesamt
PayPal			
Rechnung			
gesamt			

a) Fülle die Vierfeldertafel aus.

b) Berechne P(Retoure | PayPal) und P(Retoure | Rechnung).

---

c) Wie wahrscheinlich wurde eine zurückgeschickte Bestellung auf Rechnung bezahlt?

Übung 4 Eine Tafel aus Wahrscheinlichkeiten

Gehört zu Abschnitt 2.

Es gilt $P(A) = 0{,}3$, $P(B) = 0{,}5$ und $P(A \cap B) = 0{,}12$.

	B	nicht B	gesamt
A			
nicht A			
gesamt			1

a) Fülle die Tafel aus.

b) Berechne P(A | B) und P(B | A).

---

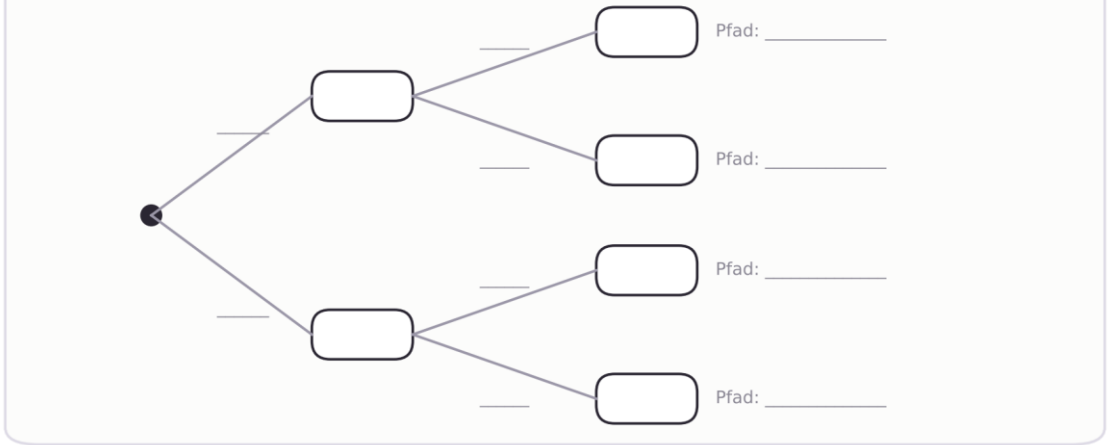
c) Sind A und B unabhängig?

Übung 5 Logins im Firmennetz

Gehört zu Abschnitt 3.

70 % aller Logins kommen aus dem Firmennetz, 30 % von außen. Von den Logins aus dem Firmennetz schlagen 2 % fehl, von denen von außen 10 %.

Vorlage: Baumdiagramm für die Logins



a) Zeichne das Baumdiagramm mit allen Wahrscheinlichkeiten.

b) Wie wahrscheinlich schlägt ein beliebiger Login fehl?

---

c) Übertrage die Pfade für 1 000 Logins in eine Vierfeldertafel.

	fehlgeschlagen	**erfolgreich**	**gesamt**
Firma			
außen			
gesamt			1 000

d) Ein Login ist fehlgeschlagen. Wie wahrscheinlich kam er von außen?

Übung 6 Noch einmal Ettas Nest

Gehört zu Abschnitt 3.

Im Nest liegen 4 Knöpfe und 2 Ringe (wie in Skript 1, Übung 10).

a) Ohne Zurücklegen: Berechne $P(R_2 \mid R_1)$ und $P(R_2 \mid K_1)$.

---

b) Mit Zurücklegen: Berechne dieselben beiden Werte. Was fällt auf?

Übung 7 Unabhängig oder nicht?

Gehört zu Abschnitt 4.

Entscheide und begründe in einem Satz.

Ereignisse	unabhängig?	Begründung
Münze zeigt Kopf, Würfel zeigt 6		
Zwei Karten ohne Zurücklegen: 1. Karte Herz, 2. Karte Herz		
Datei ist infiziert, Scanner schlägt Alarm		
Server A fällt aus, Server B im selben Rechenzentrum fällt aus		

Übung 8 Unabhängig oder unvereinbar?

Gehört zu Abschnitt 4.

Ein Würfel. A = {1, 2}, B = {3, 4}, C = {2, 4, 6}.

a) Welche der Paare (A, B), (A, C), (B, C) sind unvereinbar?

---

b) Prüfe für jedes Paar, ob es unabhängig ist: Vergleiche $P(X \cap Y)$ mit $P(X) \cdot P(Y)$.

---

c) Was zeigt das Paar (A, B)?

Übung 9 Hängt die Retoure an der Zahlart?

Gehört zu Abschnitt 4.

Benutze deine Vierfeldertafel aus Übung 3.

a) Vergleiche P(Retoure) mit P(Retoure | PayPal) und P(Retoure | Rechnung).

---

b) Herr Bauchgefühl folgert: „Rechnungskauf verursacht Retouren, wir schaffen ihn ab.“ Was hältst du davon?

Übung 10 Der Spamfilter

Gehört zu Abschnitt 5.

20 % aller Mails sind Spam. Der Filter markiert 95 % der Spam-Mails, aber auch 2 % der normalen Mails.

a) Stell dir 1 000 Mails vor. Wie viele sind Spam und markiert, wie viele normal und trotzdem markiert?

---

b) Eine Mail ist markiert. Wie wahrscheinlich ist sie wirklich Spam?

---

c) Beim Virenscanner waren es nur 16,7 %. Warum ist der Spamfilter so viel zuverlässiger?

Übung 11 Ein noch seltenerer Virus

Gehört zu Abschnitt 5.

Nur 0,1 % aller Dateien sind infiziert. Der Scanner erkennt 99 % der Viren und gibt bei 1 % der sauberen Dateien Fehlalarm.

a) Rechne mit 100 000 Dateien und fülle eine Vierfeldertafel.

	Alarm	**kein Alarm**	**gesamt**
infiziert			
sauber			
gesamt			100 000

b) Wie wahrscheinlich ist eine Datei mit Alarm wirklich infiziert?

---

c) Was würde Mats dazu sagen?

Übung 12 Herrn Bauchgefühls Schlagzeilen

Gehört zu Abschnitt 6.

Welche bedingte Wahrscheinlichkeit steckt in der Zahl, und welche bräuchte man für die Schlussfolgerung?

Schlagzeile	**Zahl ist …**	**Schluss braucht …**
„80 % aller Unfälle passieren in der Nähe der Wohnung. Zu Hause fahren ist gefährlich!“		
„75 % der gehackten Konten hatten ein Passwort mit weniger als 10 Zeichen. Kurze Passwörter werden fast immer gehackt!“		
„Die meisten Lottogewinner haben Lotto gespielt. Wer spielt, gewinnt!“		