Wahrscheinlichkeit 4

Stetige Verteilungen und die Normalverteilung

In Skript 3 hatten unsere Zufallsvariablen Lücken: 0, 1 oder 2 Tickets, aber nie 1,5. Viele Größen in der IT kennen keine Lücken: Antwortzeiten, Temperaturen, Auslastung, Wartezeiten. Heute lernen wir, wie man mit solchen **stetigen** Größen rechnet, und treffen die wichtigste Verteilung der Statistik: die **Normalverteilung**.

Schritt	Frage	Abschnitt
Unterscheiden	Was ist anders, wenn es keine Lücken gibt?	1
Messen	Wie wird aus einer Kurve eine Wahrscheinlichkeit?	2
Gleich verteilen	Was, wenn kein Wert bevorzugt ist?	3
Glocke	Warum ist so vieles normalverteilt?	4
Vergleichen	Wie vergleiche ich Werte aus verschiedenen Verteilungen?	5
Überblicken	Welche Verteilungen braucht man in der IT noch?	6

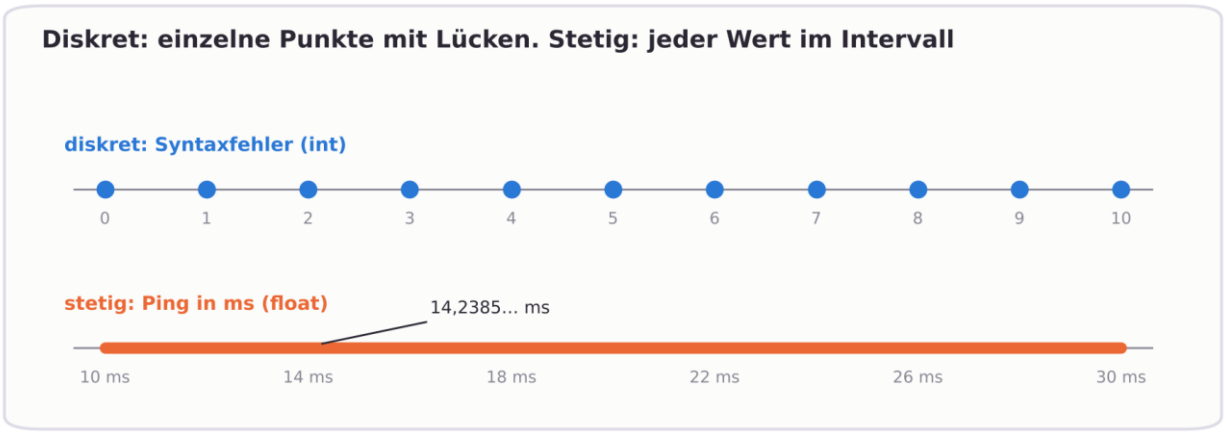
> **Heute:** Zuerst lesen wir Flächen unter Kurven ab und rechnen mit Rechtecken und Tabellen. Dann zieht ihr mit NumPy Zufallszahlen aus allen Verteilungen des Tages und wertet einen Ticket-Log mit Zeitstempeln aus.

1 – Stetige Zufallsvariablen



Herr Bauchgefühl behauptet:
„Unser Server antwortet sehr oft in genau 14 Millisekunden. Das ist sein Lieblingswert."

1.1 – Die Definition. Eine Zufallsvariable heißt **stetig** (oder kontinuierlich), wenn sie jeden beliebigen reellen Wert innerhalb eines Intervalls annehmen kann. Zwischen zwei Werten gibt es keine Lücken, zwischen 14 und 15 ms liegen 14,1 ms, 14,01 ms, 14,001 ms und so weiter. Die Menge der möglichen Werte ist **überabzählbar unendlich**: Man kann sie nicht einmal durchnummerieren.



1.2 – Beispiele aus der IT.

Beispiel	mögliche Werte
Antwortzeit (Ping, Latenz) eines Servers	z. B. 14,2385… ms
CPU-Auslastung eines Anwendungsservers	jeder Wert von 0 % bis 100 %
Durchsatz einer Glasfaserleitung	z. B. 0,9431… Gbit/s
Wartezeit bis zum nächsten Support-Ticket	jeder Wert ab 0 Minuten

Im Code wäre das ein „float“, bei diskreten Zufallsvariablen aus Skript 3 ein „int“.

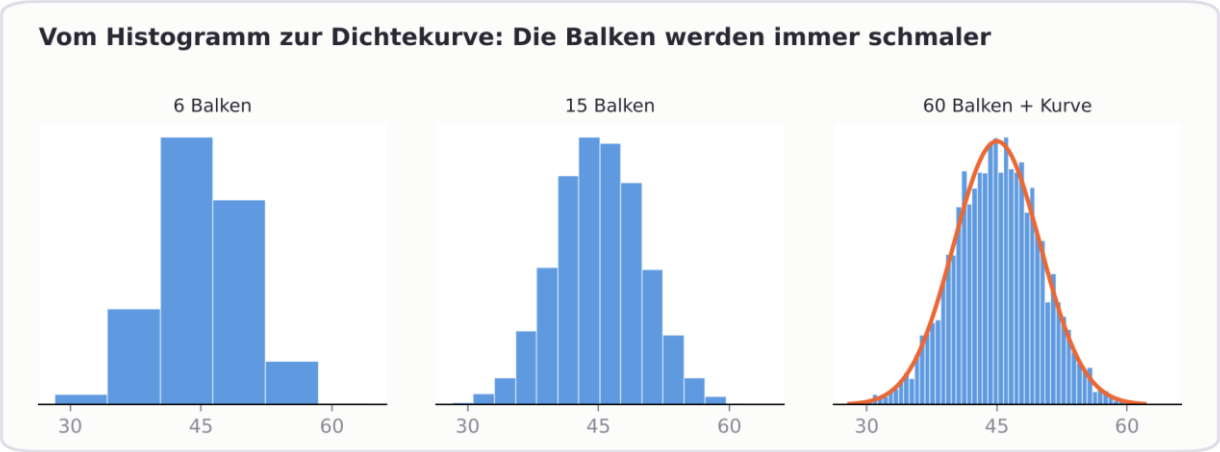
1.3 – Ein einzelner Wert hat die Wahrscheinlichkeit 0. Weil es unendlich viele mögliche Werte gibt, ist die Wahrscheinlichkeit, dass X **exakt** einen Wert trifft, gleich null: **P(X = 14 ms) = 0**. Gemeint ist wirklich exakt: 14,000000… ms mit unendlich vielen Nullen. Sinnvoll fragt man deshalb immer nach einem **Intervall**: Wie wahrscheinlich liegt die Antwortzeit zwischen 13 und 15 ms?



Nils sagt:
„Beim Würfel konnte ich jede Augenzahl einzeln zählen. Bei Millisekunden müsste ich unendlich fein zählen. Also zähle ich in Bereichen.“

2 – Dichte und Fläche

2.1 – Vom Histogramm zur Kurve. In Statistik 4 habt ihr Histogramme gezeichnet. Nimmt man immer mehr Messwerte und macht die Balken immer schmaler, wird aus den Treppenstufen eine glatte Kurve: die **Wahrscheinlichkeitsdichte** f(x).



2.2 – Was ist Dichte? Der Metallstab. Die Wahrscheinlichkeitsdichte ist das Gegenstück zur Massendichte in der Physik. Stell dir einen 1 Meter langen, dünnen Metallstab vor:

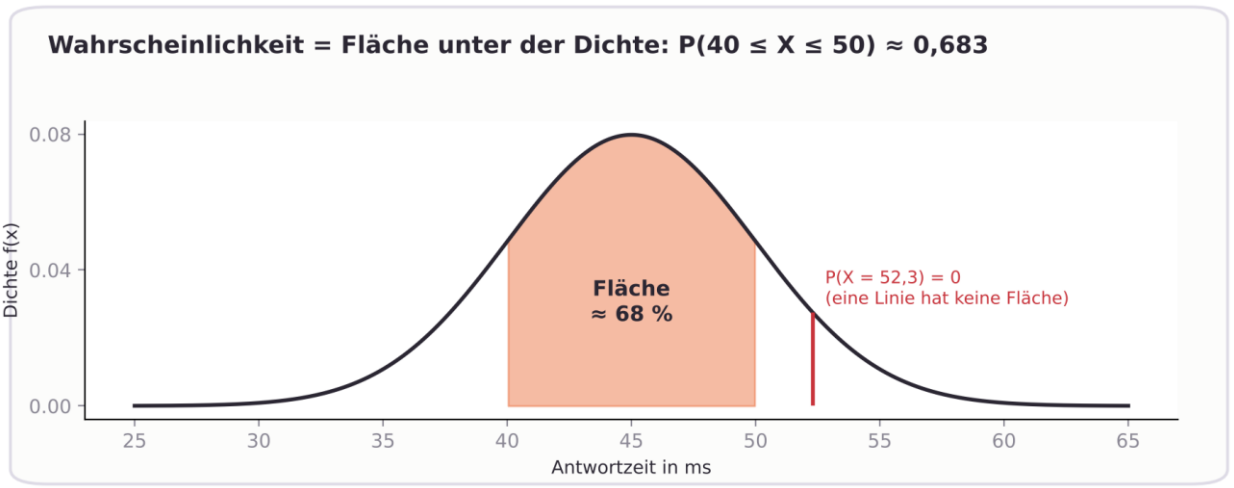
- Willst du wissen, wie schwer der ganze Stab ist, wiegst du ihn.
- Ein einzelner mathematischer Punkt auf dem Stab hat keine Breite und deshalb **kein Gewicht**. Ein Punkt hat keine Masse.
- Der Stab hat aber an jeder Stelle eine **Dichte** (z. B. Gramm pro Zentimeter). Ist er links aus leichtem Aluminium und rechts aus schwerem Blei, ist die Dichte rechts viel höher als links.



Genau das ist die Wahrscheinlichkeitsdichte f(x): eine Funktion, die für jeden Punkt x anzeigt, wie stark die Wahrscheinlichkeit dort **konzentriert** ist. Ein hoher Wert von f(x) heißt: In der Umgebung von x landen viele Werte. Ein niedriger Wert heißt: Hier landen Werte eher selten.

> **Wichtig:** Der Funktionswert f(x) ist **keine Wahrscheinlichkeit**. Er ist nur die Höhe der Kurve und kann sogar größer als 1 sein, was für eine Wahrscheinlichkeit unmöglich wäre. Beispiel: Liegt eine Größe gleichverteilt zwischen 0 und 0,5, ist die Dichte überall 2.

2.3 – Wahrscheinlichkeit = Fläche. Um aus der Dichte eine echte Wahrscheinlichkeit zu machen, muss man dem Zufall wieder „Raum“ geben: Man fragt nicht nach einem Punkt, sondern nach einem **Intervall** von a bis b. Beim Metallstab bestimmst du das Gewicht eines Teilstücks aus Länge mal Dichte. In der Stochastik ist die Wahrscheinlichkeit genau die **Fläche unter der Dichtekurve** in diesem Bereich.

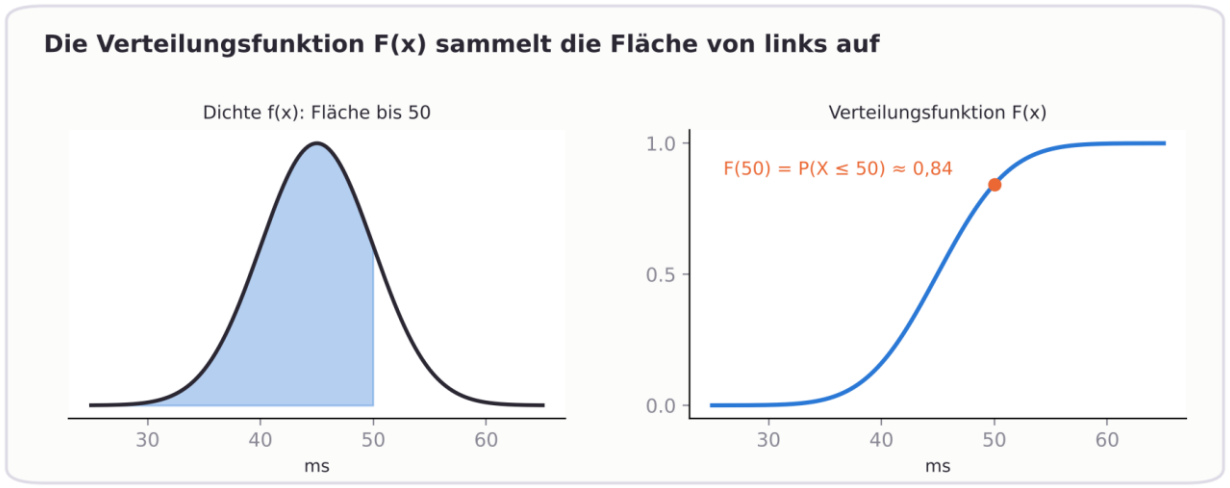


> **So steht es in Büchern:** $P(a \le X \le b) = \int_a^b f(x)\,dx$
>
> Das Zeichen ∫ ist ein langgezogenes S für „Summe“ und heißt: Fläche unter der Kurve von a bis b ausrechnen (Integral). Rechnen müsst ihr das nicht. Bei Rechtecken reicht Breite · Höhe, bei allen anderen Kurven erledigt das eine Tabelle oder der Computer.

2.4 – Zwei Regeln.

- **Die Gesamtfläche ist immer 1.** Irgendein Wert kommt sicher heraus, das ist P(Ω) = 1 aus Skript 1.
- **Punkte haben keine Fläche.** Startet und endet das Intervall bei a, ist die Breite 0 und damit auch die Fläche: P(X = a) = 0. Daraus folgt: Bei stetigen Zufallsvariablen ist es egal, ob „≤“ oder „<“ steht, **P(X ≤ a) = P(X < a)**. Bei diskreten Variablen aus Skript 3 ist das nicht egal!

2.5 – Die Verteilungsfunktion. Die **Verteilungsfunktion** F(x) = P(X ≤ x) sammelt die Fläche von ganz links bis x auf. Sie steigt von 0 auf 1. Das ist dieselbe Idee wie die kumulierte Häufigkeit aus Statistik 1 und die aufsummierten Wahrscheinlichkeiten aus Skript 3.



$$P(a \le X \le b) = F(b) - F(a)$$

2.6 – Der Erwartungswert. Auch eine stetige Zufallsvariable hat einen Erwartungswert: den Wert, der sich im langfristigen Mittel ergibt. Anschaulich ist er der **Schwerpunkt der Fläche**, genau wie bei der Waage aus

Skript 3. Bei symmetrischen Kurven liegt er genau in der Mitte. Kennt man die Dichte der Antwortzeiten eines Microservices, kann man so die mittlere Antwortzeit bestimmen. Für die Planung gilt aber wie in Skript 3: Server dimensioniert man nicht nach dem Mittel, sondern nach den Spitzen.



Herr Bauchgefühl stutzt:
„Genau 14 Millisekunden kommt also nie vor. Ich muss fragen: Wie oft liegt die Antwort zwischen 13 und 15?“

Zum Weiterlesen: Dichtefunktion – Fläche, Heizregler-Beispiel

Zum Weiterlesen: Verteilungsfunktion – kumulierte Wahrscheinlichkeit

3 – Die stetige Gleichverteilung



Herr Bauchgefühl behauptet:
„Ich komme zufällig ans Gleis, die S-Bahn fährt alle 10 Minuten. Da warte ich doch meistens fast 10 Minuten.“

3.1 – Kein Wert ist bevorzugt. Die Gleichverteilung (auch **Uniformverteilung** oder Rechteckverteilung) ist das Modell für Zufall, bei dem kein Wert bevorzugt ist. Beim Würfel aus Skript 3 hatte jede Augenzahl dieselbe Wahrscheinlichkeit. Bei der **stetigen** Gleichverteilung kann X jeden Wert in einem Intervall [a, b] annehmen, und jedes **gleich breite Teilintervall** ist gleich wahrscheinlich. Zwischen 2 und 3 Minuten zu warten ist genauso wahrscheinlich wie zwischen 7 und 8 Minuten.

3.2 – Die Dichte ist ein Rechteck. Die Dichte f(x) ist innerhalb von [a, b] konstant und außerhalb null. Weil die Gesamtfläche 1 sein muss (Rechteck: Breite · Höhe = 1), ist die Höhe der **Kehrwert** der Breite:

$$f(x) = 1 / (b - a) \quad \text{für } a \le x \le b \qquad f(x) = 0 \quad \text{sonst}$$

3.3 – Teilintervalle. Die Wahrscheinlichkeit für ein Teilintervall [c, d] ist einfach das Verhältnis der Breiten:

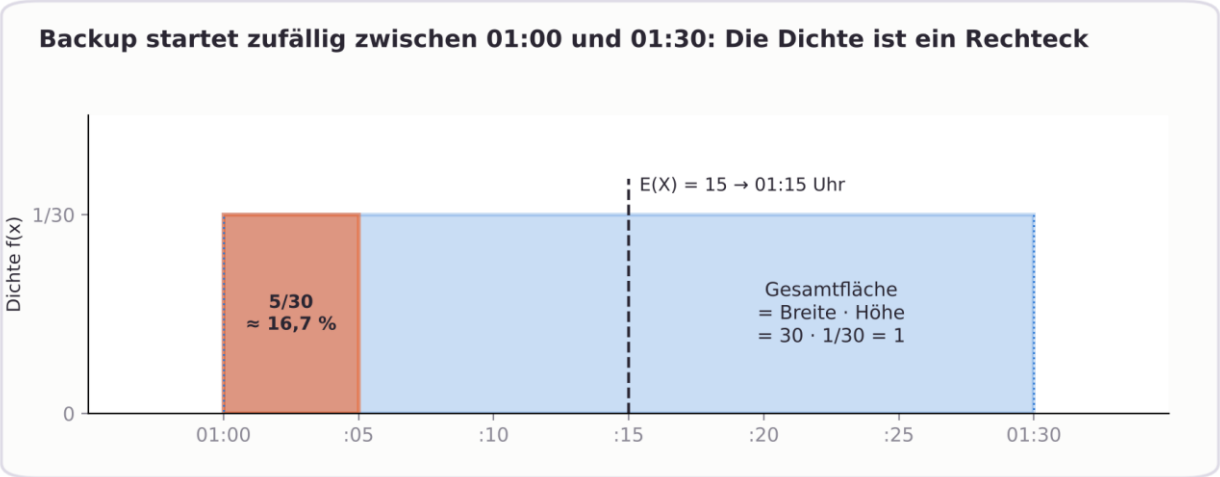
$$P(c \le X \le d) = (d - c) / (b - a)$$

3.4 – Der Erwartungswert. Weil das Rechteck symmetrisch ist, liegt der Erwartungswert genau in der Mitte:

$$E(X) = (a + b) / 2$$

3.5 – Rechenbeispiel: das nächtliche Backup. Ein Backup-Prozess soll jede Nacht zu einem zufälligen Zeitpunkt zwischen 01:00 Uhr (a = 0 Minuten) und 01:30 Uhr (b = 30 Minuten) starten, damit nicht alle Server gleichzeitig sichern.

Frage	Rechnung	Ergebnis
Dichte im Intervall	f(x) = 1 / (30 − 0)	1/30 pro Minute
Erwartungswert	E(X) = (0 + 30) / 2	15 Minuten → 01:15 Uhr
Start in den ersten 5 Minuten	P(0 ≤ X ≤ 5) = 5 / 30	1/6 ≈ 16,7 %



> **Dichte ≠ Wahrscheinlichkeit:** f(x) = 1/30 heißt nicht „3,3 % Wahrscheinlichkeit“. Es ist eine Höhe mit der Einheit „pro Minute“. Erst Breite mal Höhe ergibt eine Wahrscheinlichkeit.

Praxis-Hinweis für Admins: Ein klassischer Cronjob kann nicht zufällig starten, er läuft immer zur festen Zeit. Den zufälligen Start erreicht man mit einem systemd-Timer (Option RandomizedDelaySec=30min) oder mit einer zufälligen Wartezeit am Anfang des Skripts.

3.6 – Wo sie in der IT steckt.

- **Zufallszahlengeneratoren:** Fast jede Programmiersprache liefert gleichverteilte Kommazahlen im Intervall [0, 1), etwa Math.random() in JavaScript oder rng.random() in NumPy. Das sind **Pseudozufallszahlen**: Ein Algorithmus berechnet sie aus einem Startwert, dem Seed. Mit demselben Seed kommt dieselbe Folge heraus, deshalb sind eure Pandas-Ergebnisse mit random_state reproduzierbar. Aus solchen Zahlen baut man alle anderen Verteilungen.
- **Jitter:** Damit nicht alle Clients nach einem Netzwerkfehler gleichzeitig neu senden und wieder kollidieren, wartet jeder eine zufällige Zeit, etwa gleichverteilt zwischen 10 ms und 50 ms (z. B. beim Exponential Backoff).
- **Wartezeiten:** Wer zu einem zufälligen Zeitpunkt auf einen festen Takt trifft, wartet gleichverteilt.

Zurück zum Gleis: Die Wartezeit ist gleichverteilt zwischen 0 und 10 Minuten. Im Mittel wartet man E(X) = 5 Minuten, und länger als 8 Minuten nur mit P = 2/10 = 20 %.



Herr Bauchgefühl stutzt:
„Im Mittel 5 Minuten, und fast 10 Minuten nur in jedem fünften Fall. Ich hatte mir wohl nur die schlimmen Tage gemerkt."

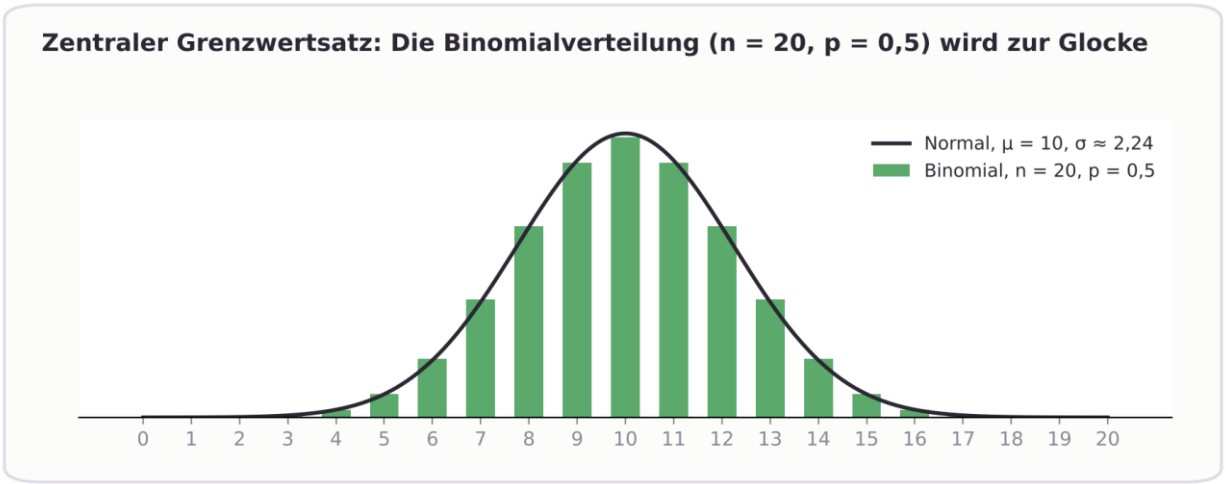
Zum Weiterlesen: Stetige Gleichverteilung – U-Bahn im 10-Minuten-Takt, Selbsttest

4 – Die Normalverteilung



Herr Bauchgefühl behauptet:
„Alles im Leben ist normalverteilt: Körpergrößen, Noten, Antwortzeiten, Anfahrtswege. Immer diese schöne Glocke."

4.1 – Warum gerade die Glocke? Die Normalverteilung (auch **Gauß-Verteilung**) ist die wichtigste stetige Verteilung. Ihre Bedeutung beruht auf dem **Zentralen Grenzwertsatz**: Die Summe vieler unabhängiger, beliebig verteilter Zufallsvariablen ist annähernd normalverteilt. In der Praxis heißt das: Wann immer ein Messwert durch **viele kleine, unabhängige Einflüsse** entsteht, etwa Messfehler, Hintergrundrauschen oder menschliches Verhalten, ergibt sich die typische symmetrische Glocke. Schon die Binomialverteilung aus Skript 3 ist so eine Summe aus vielen Ja/Nein-Versuchen:

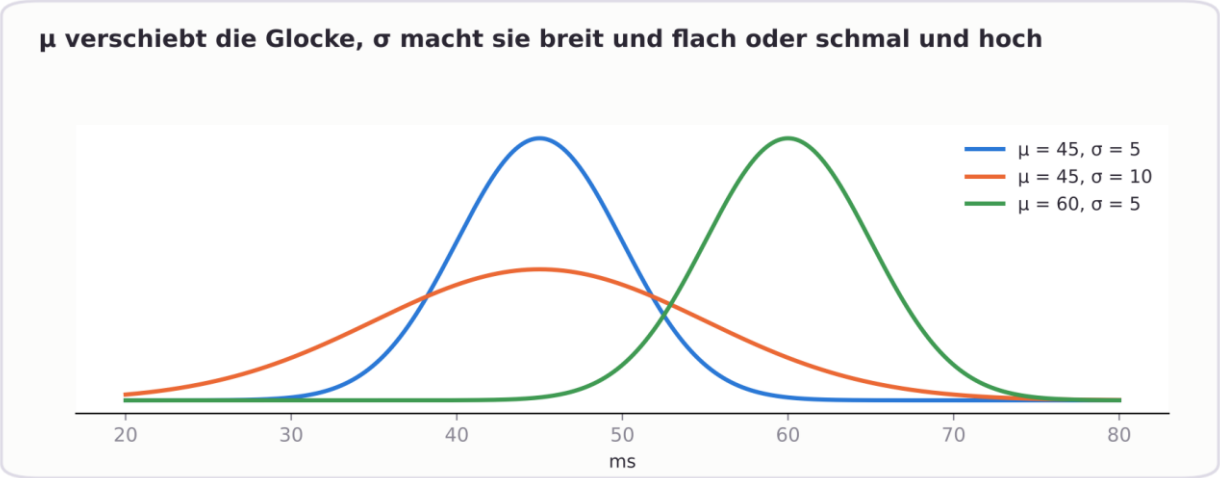


4.2 – Die Definition. Eine stetige Zufallsvariable X ist normalverteilt mit den Parametern μ (Erwartungswert, Lage) und σ (Standardabweichung, Streuung), kurz $\mathbf{X \sim N(\mu, \sigma^2)}$. Ihre Dichte lautet:

$$f(x) = 1 / (\sigma \cdot \sqrt{(2\pi)}) \cdot e^{(-½ \cdot ((x - \mu) / \sigma)^2)}$$

- **μ** ist der Mittelpunkt der Verteilung, die Symmetrieachse.
- **σ** ist die Standardabweichung und bestimmt die Breite der Glocke. Je größer σ, desto flacher und breiter die Kurve. Die Fläche bleibt immer 1.
- **e** ist die Eulersche Zahl (≈ 2,718) und **π** die Kreiszahl (≈ 3,14).

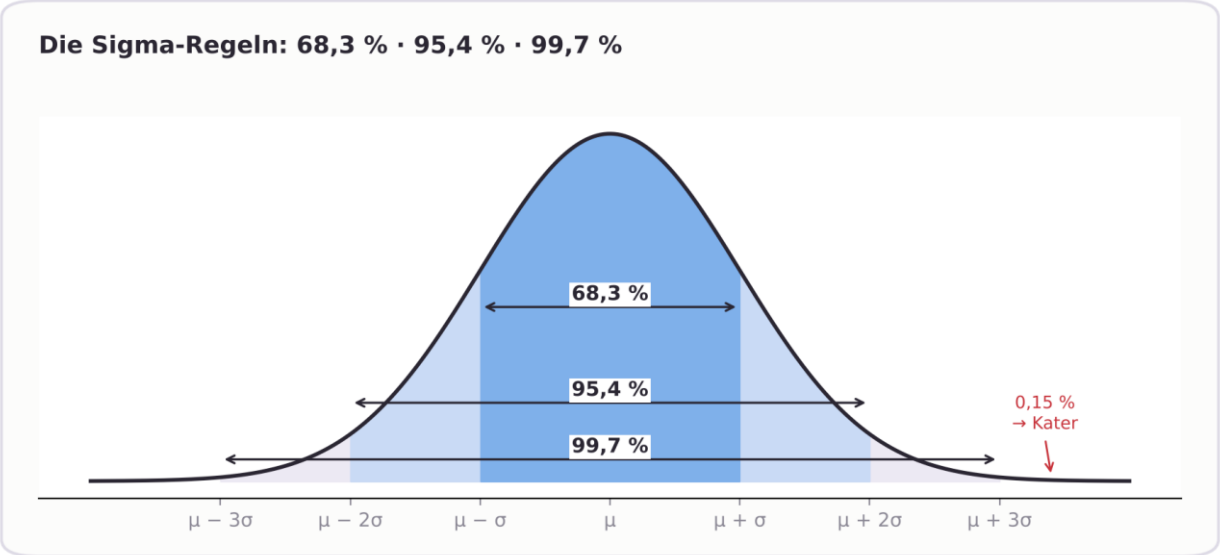
> Diese Formel muss niemand von Hand rechnen oder auswendig lernen. Wichtig ist nur: Die ganze Kurve hängt allein von **μ** und **σ** ab. Kennt man die beiden, kennt man alles.



4.3 – Erwartungswert, Median, Modus. Bei der Normalverteilung ist der Erwartungswert direkt der Parameter μ: **E(X) = μ**. Weil die Glocke perfekt symmetrisch ist, liegt er genau am höchsten Punkt. Dort fallen Erwartungswert, Median und Modus zusammen. Die drei Igel aus Statistik 2 stehen hier also an derselben Stelle.

4.4 – Die Sigma-Regeln. Für jede Normalverteilung gelten feste Anteile, egal welche Werte μ und σ haben:

Intervall	Anteil aller Werte
μ ± 1σ	ca. 68,3 %
μ ± 2σ	ca. 95,4 %
μ ± 3σ	ca. 99,7 % (fast alle Werte)

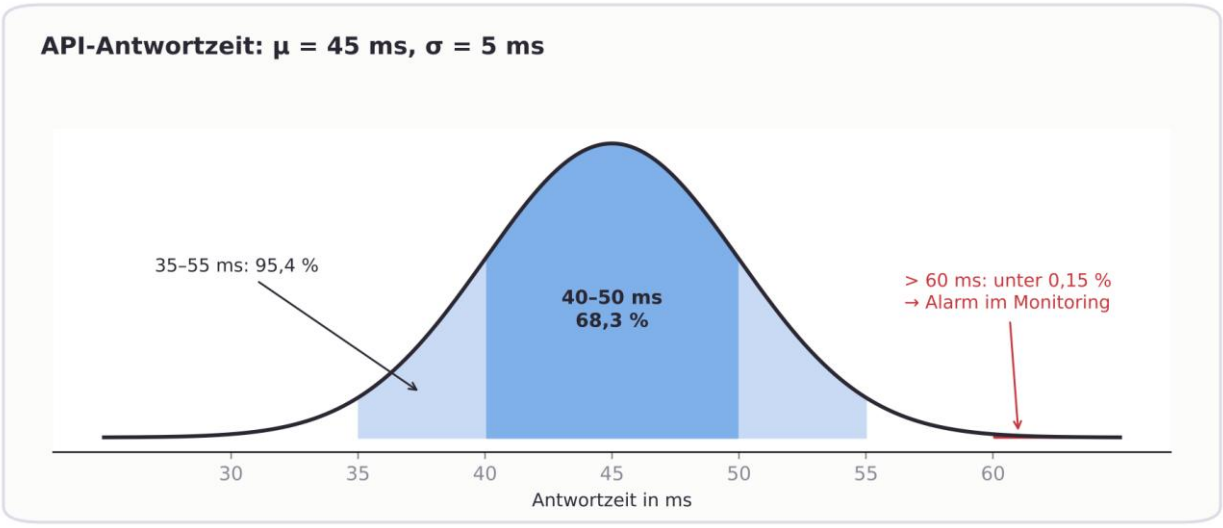




Der Ausreißer meldet sich:
„Ich wohne ganz draußen, jenseits von 3σ. Dort sind nur 0,3 % aller Werte, auf jeder Seite 0,15 %. Wer mich trifft, sollte genauer hinschauen."

4.5 – IT-Beispiel: Server-Antwortzeiten. Die Antwortzeit (Latenz) eines stark genutzten API-Endpunkts hängt von vielen kleinen Einflüssen ab: CPU-Auslastung, Routing-Laufzeiten im Rechenzentrum, RAM-Zugriffe. Sie sei annähernd normalverteilt mit **μ = 45 ms** und **σ = 5 ms**.

- Im langfristigen Mittel braucht eine Anfrage E(X) = 45 ms.
- Rund 68,3 % aller **Anfragen** werden in 40 bis 50 ms beantwortet (45 ± 5).
- Rund 95,4 % aller Anfragen liegen zwischen 35 und 55 ms (μ ± 2σ).
- Werte über 60 ms (μ + 3σ) kommen in weniger als 0,15 % aller Fälle vor. Im Monitoring kann man sie direkt als Ausreißer oder als Zeichen einer beginnenden Überlastung werten.



4.6 – Vorsicht: Nicht alles ist normalverteilt. Die Normalverteilung ist ein **Modell**, und man muss prüfen, ob es passt. Echte Antwortzeiten sind meist **rechtsschief**: Schneller als eine Mindestzeit geht es nicht, aber einzelne Anfragen dauern sehr lange. Deshalb schaut man im Monitoring oft auf Quantile wie P95 (95 % aller Anfragen sind schneller). Ein einfacher Test: Liefert μ − 2σ einen unmöglichen Wert? Bei der Anfahrt der Kurs-Umfrage (Mittelwert 39,6, Standardabweichung 22,0 Minuten) wäre μ − 2σ = −4,4 Minuten, also eine **negative** Anfahrt. Die Anfahrt ist nicht normalverteilt (Übung 10). Wie man mit schiefen Daten umgeht, kommt in Skript 5.



Herr Bauchgefühl stutzt:
„Eine negative Anfahrt? Gut, dann ist eben doch nicht alles normalverteilt. Aber vieles!"

Zum Weiterlesen: Normalverteilung – Glockenkurve, 68-95-99,7, Selbsttest

Zum Ausprobieren: Plinko Nagelbrett – aus Binomial wird die Glocke (PhET)

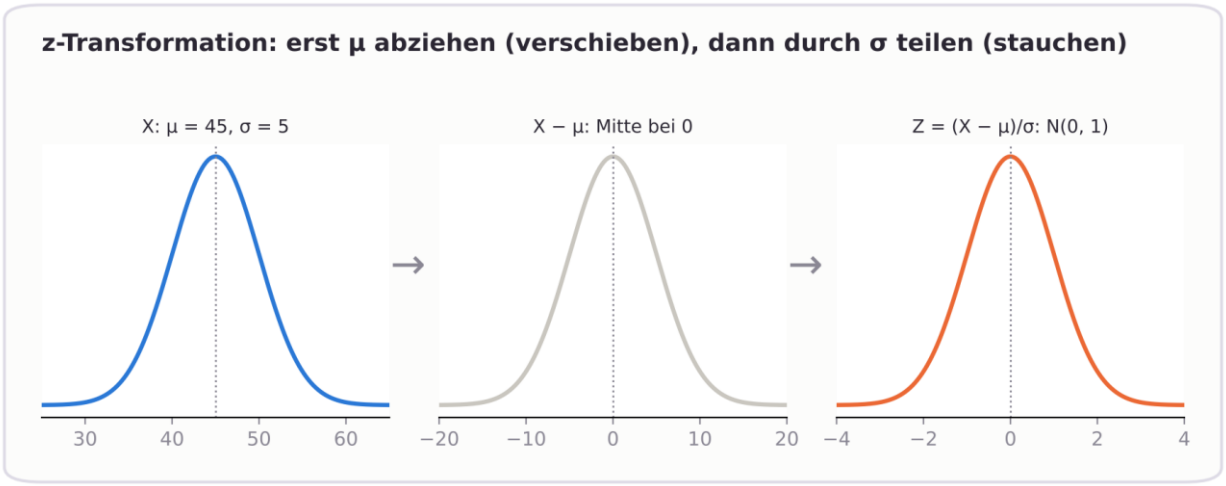
5 – Standardnormalverteilung und z-Wert



Etta sagt:
„Server A hat 52 ms gebraucht, Server B 150 ms. Welcher Wert ist ungewöhnlicher? Ich kann Äpfel nicht mit Birnen vergleichen, also sortiere ich beide erst einmal um.“

5.1 – Der z-Wert. Aus Statistik 3 kennt ihr den z-Wert: Er gibt an, wie viele Standardabweichungen ein Wert vom Mittelwert entfernt ist. Zieht man von jeder normalverteilten Variable μ ab und teilt durch σ, entsteht immer dieselbe Glocke, die **Standardnormalverteilung N(0, 1)** mit μ = 0 und σ = 1:

$$z = (x - \mu) / \sigma \qquad Z \sim N(0, 1)$$



5.2 – Die Tabelle Φ(z). Die Verteilungsfunktion der Standardnormalverteilung heißt Φ(z) (sprich: „Phi“). Sie steht in Tabellen, im Taschenrechner und in jeder Statistik-Software. Ein Auszug:

z	0	0,5	1	1,5	2	2,5	3
Φ(z) = P(Z ≤ z)	0,5000	0,6915	0,8413	0,9332	0,9772	0,9938	0,9987

- **Rechts davon:** P(Z > z) = 1 − Φ(z).
- **Negative z-Werte:** Wegen der Symmetrie gilt Φ(−z) = 1 − Φ(z).

5.3 – Ettas zwei Server. Server A: μ = 45 ms, σ = 5 ms, gemessen 52 ms. Server B: μ = 120 ms, σ = 20 ms, gemessen 150 ms.

$$z_A = (52 - 45) / 5 = 1{,}4 \qquad z_B = (150 - 120) / 20 = 1{,}5$$

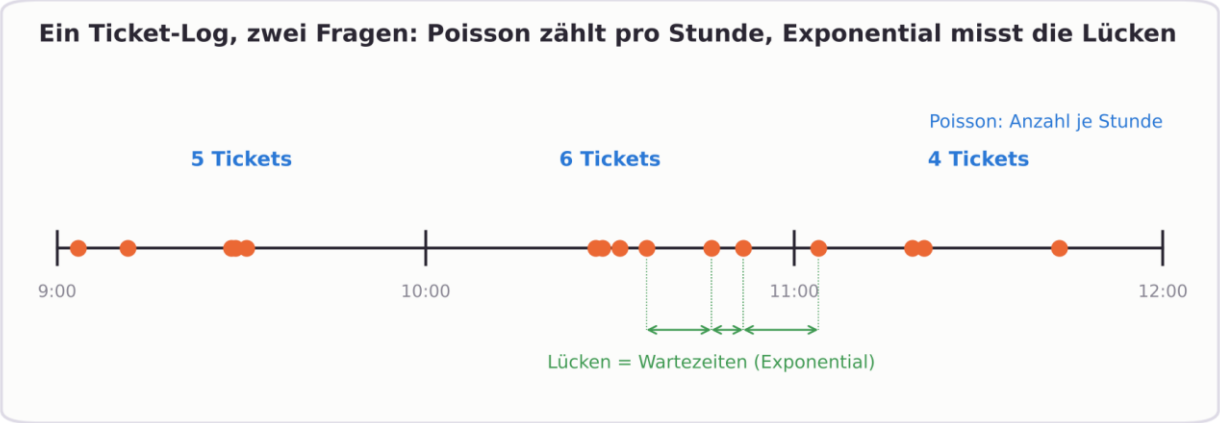
Der Wert von Server B liegt 1,5 Standardabweichungen über seinem Mittel, der von A nur 1,4. **B ist ungewöhnlicher**, obwohl der Unterschied in Millisekunden gar nicht vergleichbar ist. Und wie wahrscheinlich braucht Server A länger als 55 ms? z = (55 − 45)/5 = 2, also P = 1 − Φ(2) = 1 − 0,9772 ≈ **2,3 %**.

Zum Weiterlesen: Standardnormalverteilung – z-Transformation, Tabelle

Zum Nachschlagen: z-Verteilung – Tabelle und Rechner (numiqo)

6 – Weitere Verteilungen im Überblick

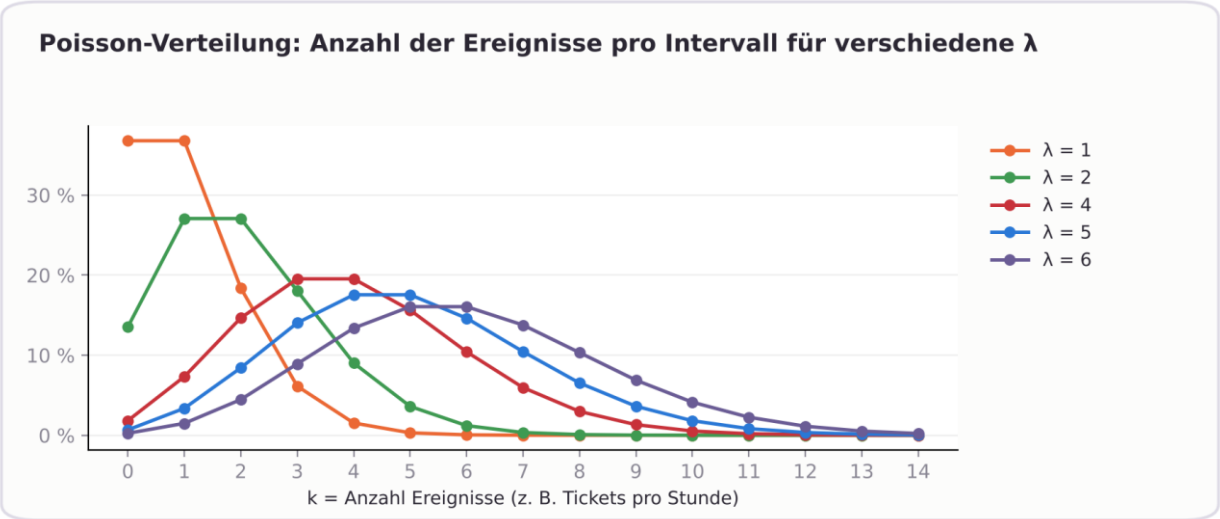
Am Helpdesk der Datenwald-Akademie wird jedes Ticket mit Zeitstempel gespeichert. Aus demselben Log lassen sich zwei verschiedene Fragen stellen, und jede hat ihre eigene Verteilung:



6.1 – Poisson-Verteilung: die Verteilung seltener Ereignisse. Die Poisson-Verteilung ist **diskret**. Sie beschreibt die **Anzahl** von Ereignissen, die in einem festen Zeitintervall oder Raumabschnitt eintreffen. Voraussetzung: Die Ereignisse treten unabhängig voneinander und mit einer konstanten mittleren Rate auf.

Steuerparameter: Die Verteilung hat nur einen Parameter, die mittlere Anzahl λ (Lambda) pro Intervall. Erwartungswert und Varianz sind beide gleich λ.

$$P(X = k) = \lambda^k \cdot e^{(-\lambda)} / k! \qquad E(X) = \lambda$$



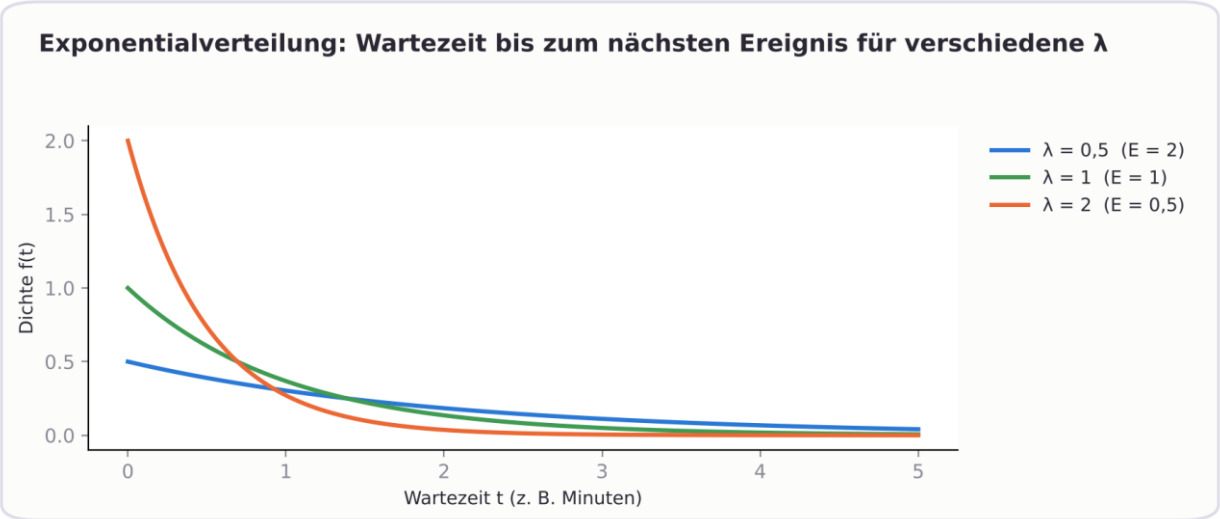
- **Server-Requests:** Anzahl der HTTP-Anfragen, die pro Sekunde auf einem Webserver eingehen.
- **Cybersecurity:** Anzahl der Brute-Force-Anmeldeversuche, die eine Firewall pro Minute blockiert.
- **Bug-Tracking:** Anzahl der gemeldeten Fehler pro Woche in einer stabilen Release-Phase.

In der Praxis ist sie ein Standardwerkzeug für Admins und DevOps, um Warteschlangen zu modellieren (Warteschlangentheorie) und Server so zu dimensionieren, dass plötzliche Request-Spitzen keine Überlastung auslösen. **Beispiel:** Am Helpdesk kommen im Mittel λ = 4 Tickets pro Stunde. Eine ruhige Stunde ohne Ticket hat $P(X = 0) = e^{-4} \approx 1{,}8\ \%$. Acht oder mehr Tickets kommen in rund 5,1 % der Stunden. Bei großem n und kleinem p sieht die Binomialverteilung aus Skript 3 fast genauso aus: Der Paketverlust mit $n \cdot p = 10$ ist praktisch eine Poisson-Verteilung mit λ = 10.

6.2 – Exponentialverteilung: die Verteilung von Wartezeiten. Die Exponentialverteilung ist **stetig** und das direkte Gegenstück zur Poisson-Verteilung. Während Poisson zählt, **wie viele** Ereignisse pro Zeiteinheit eintreffen, misst die Exponentialverteilung die **Zeitspanne zwischen** zwei aufeinanderfolgenden Ereignissen.

Steuerparameter: dieselbe Rate λ wie bei Poisson. Die mittlere Wartezeit ist ihr Kehrwert.

$$f(t) = \lambda \cdot e^{(-\lambda t)} \qquad P(T \le t) = 1 - e^{(-\lambda t)} \qquad E(T) = 1 / \lambda$$



Eine besondere Eigenschaft ist die **Gedächtnislosigkeit**: Wie lange man schon gewartet hat, ändert nichts daran, wie lange es ab jetzt noch dauert. **Beispiel:** Bei λ = 4 Tickets pro Stunde wartet man im Mittel 1/4 Stunde = 15 Minuten auf das nächste Ticket. Länger als 30 Minuten wartet man mit $P = e^{(-4 \cdot 0{,}5)} = e^{-2} \approx 13{,}5\ \%$. Hat man schon 20 Minuten gewartet, sind es für weitere 30 Minuten wieder genau 13,5 %.

- **Netzwerk-Traffic:** Zeit in Millisekunden zwischen zwei Datenpaketen an einem Router.
- **Hardware-Ausfälle:** Lebensdauer elektronischer Bauteile (SSDs, RAM-Riegel), wenn die Ausfallrate im regulären Betrieb konstant ist.
- **Message Queues:** Zeit, bis ein Worker-Prozess die nächste Aufgabe aus der Warteschlange holt.

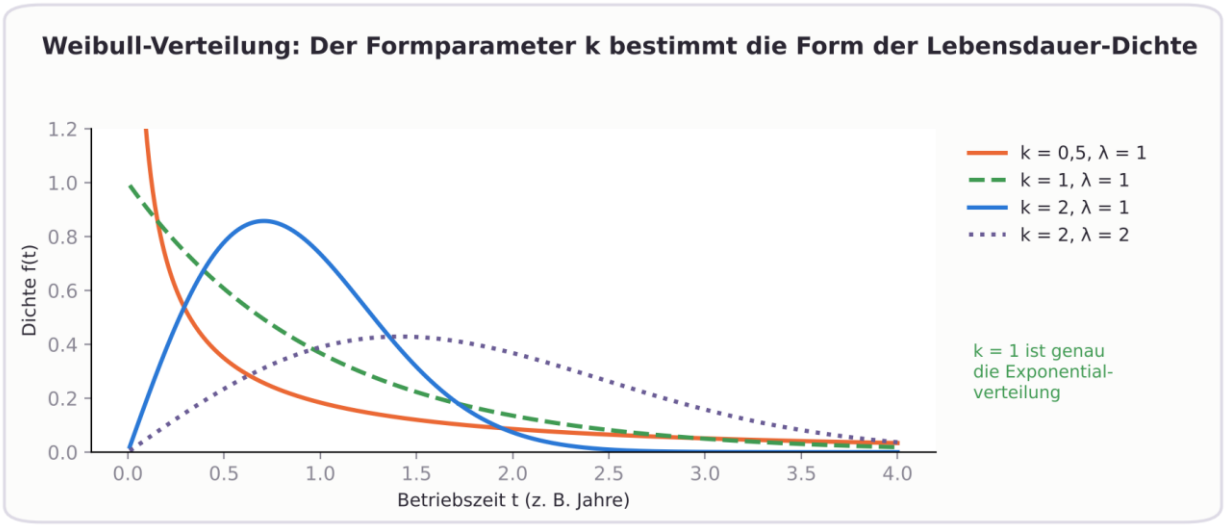


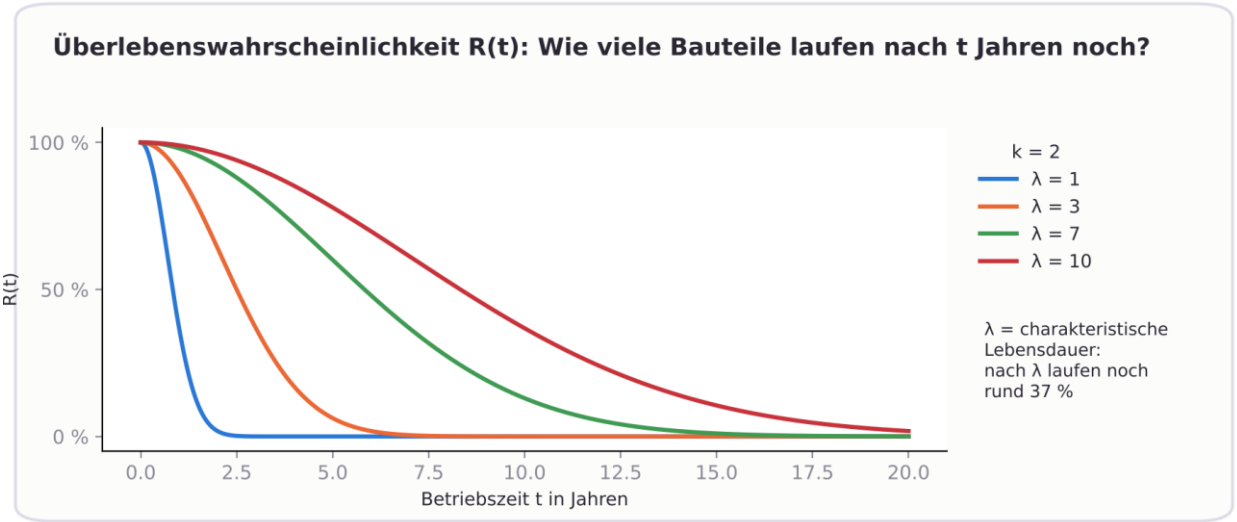
Mats sagt:
„Poisson und Exponential brauchen eine konstante Rate. Am Montagmorgen kommen aber viel mehr Tickets als am Freitagnachmittag. Für einen ganzen Tag stimmt das Modell also nicht, für eine einzelne Stunde schon eher."

6.3 – Weibull-Verteilung: Alterung modellieren. Die Weibull-Verteilung ist eine sehr flexible **stetige** Verteilung für Lebensdauern. Sie verallgemeinert die Exponentialverteilung, indem sie eine **veränderliche Ausfallrate** erlaubt. So kann sie Bauteile abbilden, die altern und verschleißen oder sich nach dem „Einfahren“ stabilisieren.

Steuerparameter: der **Formparameter k** (bestimmt, ob die Ausfallrate fällt, gleich bleibt oder steigt) und der **Skalenparameter λ** (die charakteristische Lebensdauer: Nach der Zeit λ laufen noch rund 37 % der Bauteile). In manchen Büchern heißen sie β und η oder γ und α.

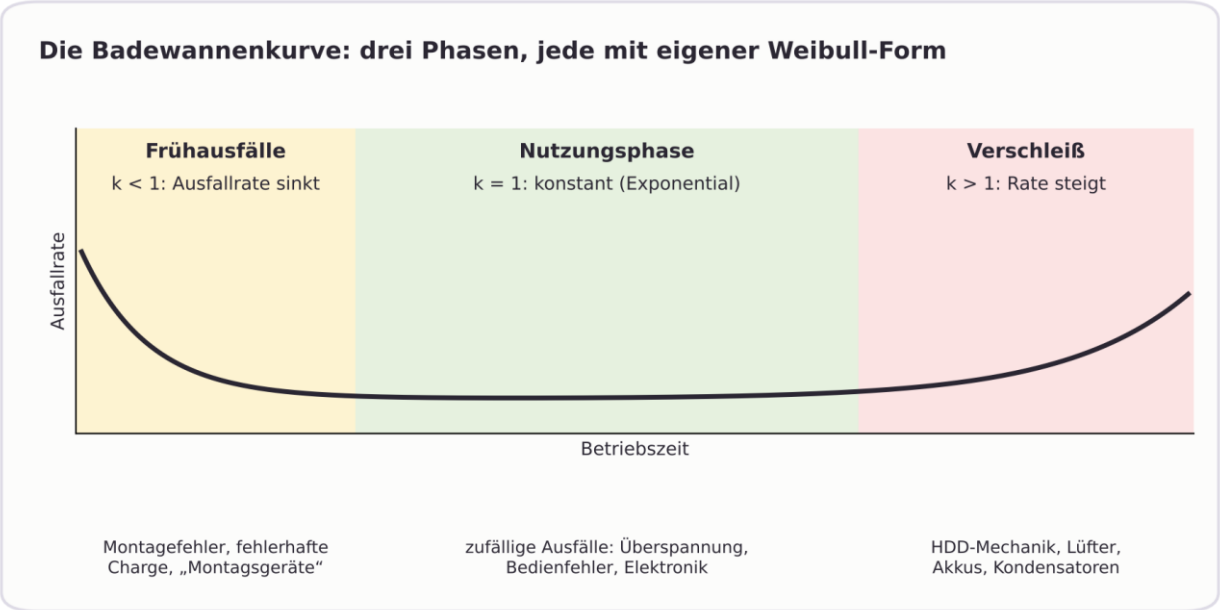
$$R(t) = P(T > t) = e^{-(t/\lambda)^k} \qquad k = 1\text{: Exponentialverteilung}$$





In der Zuverlässigkeitstechnik beschreibt man die Ausfallrate von Hardware über die gesamte Lebenszeit mit der **Badewannenkurve**. Sie besteht aus drei Phasen, und **jede Phase** lässt sich durch eine Weibull-Verteilung mit eigenem Formparameter beschreiben:

Phase	Ausfallrate	Weibull-Form	typische Ursachen
1. Frühphase	hoch, sinkt	$k < 1$	Produktionsfehler, Montagefehler („Kinderkrankheiten“)
2. Betriebsphase	niedrig, konstant	$k = 1$ (Exponential)	zufällige Ausfälle: Überspannung, Bedienfehler
3. Verschleißphase	steigt stark	$k > 1$	Materialermüdung, Alterung, mechanischer Verschleiß



- **Rechenzentrum:** Lebensdaueranalyse rotierender Festplatten (HDDs), bei denen mechanischer Verschleiß nach einigen Jahren Dauerbetrieb unvermeidbar ist.
- **Hardware-Rollout:** Planung von Garantie- und Austauschzyklen für Firmen-Notebooks oder Server-Netzteile.
- **Software:** Zeit bis zum nächsten Absturz bei einem Programm mit Speicherleck. Das Risiko steigt mit der Laufzeit des Prozesses, also $k > 1$.

6.4 – Ausblick. Zwei weitere Verteilungen werdet ihr in Kapitel 5 (Testen) wiedersehen: die **t-Verteilung** (eine etwas breitere Glocke für kleine Stichproben) und die **Chi-Quadrat-Verteilung** (für Kreuztabellen). Rechtsschiefe Verteilungen wie die Log-Normalverteilung kommen in Skript 5.

6.5 – Steckbriefe.

Verteilung	Art	Parameter	E(X)	beschreibt …	IT-Beispiel
Gleichverteilung	stetig	a, b	(a + b)/2	kein Wert bevorzugt	Jitter, Backup-Start
Normal	stetig	μ, σ	μ	viele kleine Einflüsse	Messwerte, Latenz (ungefähr)
Binomial	diskret	n, p	n · p	Erfolge in n Versuchen	Paketverlust
Poisson	diskret	λ	λ	Anzahl pro Zeitintervall	Requests pro Sekunde
Exponential	stetig	λ	1/λ	Wartezeit bis zum nächsten Ereignis	Zeit zwischen Paketen
Weibull	stetig	k, λ	–	Lebensdauer mit Alterung	HDD-Ausfälle

Zum Weiterlesen: Poisson-Verteilung – seltene Ereignisse, Selbsttest

Zum Weiterlesen: Exponentialverteilung – Wartezeiten, Lebensdauer

Zum Ausprobieren: Seeing Theory – Probability Distributions (englisch, interaktiv)

Auf einen Blick

Begriff	Bedeutung / Formel
stetige Zufallsvariable	jeder Wert in einem Intervall; „float“; $P(X = x) = 0$
Dichte f(x)	Höhe der Kurve, keine Wahrscheinlichkeit, kann > 1 sein
Wahrscheinlichkeit	Fläche unter der Dichte; Gesamtfläche 1; ≤ gleich <
Verteilungsfunktion	$F(x) = P(X \leq x)$; $P(a \leq X \leq b) = F(b) - F(a)$
Gleichverteilung	$f(x) = 1/(b - a)$; $P = (d - c)/(b - a)$; $E = (a + b)/2$
Normalverteilung	$N(\mu, \sigma^2)$; $E = \mu$ = Median = Modus; Sigma-Regeln 68,3 / 95,4 / 99,7 %
z-Wert	$z = (x - \mu)/\sigma$; Standardnormalverteilung N(0, 1); Tabelle $\Phi(z)$
Poisson	Anzahl pro Intervall; $\lambda = E$ = Varianz
Exponential	Wartezeit; $E = 1/\lambda$; gedächtnislos
Weibull	Lebensdauer; $k < 1$ / $= 1$ / > 1: Badewannenkurve

Übungen

Du brauchst Stift und Taschenrechner. Die Tabelle Φ(z) steht in Abschnitt 5.2.

Übung 1 Diskret oder stetig?

Gehört zu Abschnitt 1.

Entscheide und gib an, welcher Datentyp im Code passt.

Größe	diskret oder stetig?	Datentyp
Anzahl offener Tickets		
Akkulaufzeit eines Notebooks		
CPU-Temperatur		
Anzahl Logins pro Tag		
Ladezeit einer Webseite		
Dateigröße in Byte		

Übung 2 Genau oder ungefähr?

Gehört zu Abschnitt 2.

Die Antwortzeit X eines Servers ist eine stetige Zufallsvariable.

a) Wie groß ist P(X = 20 ms)? Begründe mit dem Metallstab.

---

b) Warum ist P(X ≤ 20) = P(X < 20)? Gilt das auch für die Anzahl der Tickets aus Skript 3?

---

c) Formuliere Herrn Bauchgefühls Satz „Der Server antwortet sehr oft in genau 14 ms“ so, dass er stimmen kann.

Übung 3 Eine Dichte größer als 1

Gehört zu Abschnitt 2.

X ist gleichverteilt zwischen 0 und 0,5 Sekunden.

a) Wie hoch ist die Dichte f(x)? (Tipp: Gesamtfläche = 1)

b) Berechne $P(0{,}1 \leq X \leq 0{,}2)$.

c) Eine Wahrscheinlichkeit kann nie größer als 1 sein. Ist $f(x) = 2$ ein Widerspruch?

Übung 4 Die S-Bahn

Gehört zu Abschnitt 3.

Die S-Bahn fährt alle 10 Minuten. Du kommst zu einem zufälligen Zeitpunkt ans Gleis.

a) Wie lautet die Dichte $f(x)$ der Wartezeit?

b) Wie wahrscheinlich wartest du länger als 8 Minuten?

c) Wie wahrscheinlich wartest du zwischen 2 und 3 Minuten?

d) Wie lange wartest du im Mittel?

Übung 5 Jitter

Gehört zu Abschnitt 3.

Nach einem Verbindungsfehler wartet ein Client eine gleichverteilte Zeit zwischen 10 ms und 50 ms.

a) Berechne die Dichte im Intervall.

b) Berechne den Erwartungswert.

c) Wie wahrscheinlich wartet der Client weniger als 20 ms?

---

d) Zwei Clients warten unabhängig voneinander. Warum kollidieren sie trotzdem fast nie genau gleichzeitig?

Übung 6 Die Verteilungsfunktion ablesen

Gehört zu Abschnitt 2.

Für die API-Antwortzeit ($\mu = 45$ ms, $\sigma = 5$ ms) gilt: $F(40) = 0{,}159$, $F(45) = 0{,}5$, $F(50) = 0{,}841$, $F(55) = 0{,}977$.

a) Wie wahrscheinlich ist eine Antwort in höchstens 50 ms?

---

b) Wie wahrscheinlich dauert eine Antwort länger als 55 ms?

---

c) Berechne $P(40 \leq X \leq 50)$. Welche Sigma-Regel erkennst du?

---

d) Berechne $P(45 \leq X \leq 55)$.

Übung 7 Build-Dauer und Sigma-Regeln

Gehört zu Abschnitt 4.

Die Dauer eines automatischen Builds ist annähernd normalverteilt mit $\mu = 12$ Minuten und $\sigma = 2$ Minuten.

a) In welchem Bereich liegen rund 68 % aller Builds?

---

b) In welchem Bereich liegen rund 95 % aller Builds?

---

c) Wie wahrscheinlich dauert ein Build länger als 16 Minuten?

---

d) Ein Build dauert 19 Minuten. Was sagst du dem Team?

Übung 8 Zwei Server vergleichen

Gehört zu Abschnitt 5.

Server A: $\mu = 45$ ms, $\sigma = 5$ ms. Server B: $\mu = 120$ ms, $\sigma = 20$ ms. Benutze die Tabelle aus Abschnitt 5.2.

a) Server A braucht 52 ms, Server B 150 ms. Berechne beide z-Werte. Welcher Wert ist ungewöhnlicher?

---

b) Wie wahrscheinlich braucht Server B höchstens 150 ms?

---

c) Wie wahrscheinlich braucht Server A weniger als 40 ms?

Übung 9 Wer ist ein Ausreißer?

Gehört zu Abschnitt 4.

Die API-Antwortzeit hat $\mu = 45$ ms und $\sigma = 5$ ms. Gemessen wurden 47, 58, 62 und 31 ms.

a) Berechne für jeden Wert den z-Wert.

---

b) Welche Werte liegen außerhalb von $\mu \pm 3\sigma$? Was würde der Kater sagen?

Übung 10 Ist die Anfahrt normalverteilt?

Gehört zu Abschnitt 4.

Die Anfahrtszeiten der Kurs-Umfrage in Minuten, sortiert: 12, 18, 22, 25, 25, 28, 30, 30, 32, 35, 35, 38, 40, 42, 45, 48, 52, 55, 65, 115. Mittelwert 39,6, Standardabweichung 22,0.

a) Berechne $\mu - \sigma$ und $\mu + \sigma$. Wie viele der 20 Werte liegen dazwischen? Wie viele wären es bei einer Normalverteilung?

---

b) Berechne $\mu - 2\sigma$. Was fällt auf?

---

c) Vergleiche Mittelwert und Median (35). Was folgt daraus?

Übung 11 Poisson oder Binomial?

Gehört zu Abschnitt 6.

Gibt es eine feste Anzahl n von Versuchen (Binomial) oder zählt man Ereignisse in einem Zeitraum ohne feste Obergrenze (Poisson)?

Situation	Verteilung	Parameter
Defekte Platinen in einer Lieferung von 50 Stück, 2 % Ausschuss		
HTTP-Anfragen pro Sekunde, im Mittel 120		
Richtige Antworten bei 10 geratenen Multiple-Choice-Fragen		
Blockierte Brute-Force-Versuche pro Minute, im Mittel 3		
Gemeldete Bugs pro Woche, im Mittel 6		

Übung 12 Tickets und Wartezeiten

Gehört zu Abschnitt 6.

Am Helpdesk kommen im Mittel $\lambda = 4$ Tickets pro Stunde, unabhängig voneinander.

a) Wie wahrscheinlich kommt in einer Stunde kein einziges Ticket? ($e^{-4} \approx 0{,}0183$)

---

b) Wie lange wartet man im Mittel auf das nächste Ticket?

---

c) Wie wahrscheinlich wartet man länger als 30 Minuten? ($e^{-2} \approx 0{,}135$)

---

d) Es ist schon 20 Minuten kein Ticket gekommen. Herr Bauchgefühl: „Jetzt muss gleich eins kommen!“ Wie wahrscheinlich dauert es noch mehr als 30 Minuten?

Übung 13 Welche Phase der Badewanne?

Gehört zu Abschnitt 6.

Ordne jede Beobachtung einer Phase der Badewannenkurve zu und gib an, ob $k < 1$, $k = 1$ oder $k > 1$ passt.

Beobachtung	Phase	k
Von 50 neuen Servern fallen in den ersten zwei Wochen drei aus, danach lange keiner mehr.		
Seit drei Jahren fallen die Switches selten und ganz gleichmäßig verteilt aus.		
Die HDDs im Archiv fallen nach sechs Jahren immer häufiger aus.		
Ein Prozess mit Speicherleck stürzt umso eher ab, je länger er läuft.		

Übung 14 Welche Verteilung bin ich?

Gehört zu Abschnitt 6.

Ordne jeder Beschreibung eine Verteilung zu: Gleichverteilung, Normal, Binomial, Poisson, Exponential, Weibull.

Beschreibung	Verteilung
„Ich zähle Ereignisse pro Stunde. Mein einziger Parameter ist die mittlere Anzahl.“	
„Ich bin ein Rechteck. Kein Wert ist mir lieber als ein anderer.“	
„Ich messe, wie lange es bis zum nächsten Ereignis dauert, und vergesse sofort, wie lange du schon wartest.“	
„Ich bin eine symmetrische Glocke und entstehe aus vielen kleinen Einflüssen.“	
„Ich zähle Erfolge in einer festen Anzahl von Ja/Nein-Versuchen.“	
„Mit meinem Formparameter kann ich Kinderkrankheiten und Verschleiß beschreiben.“	