# Wahrscheinlichkeit 5

## Schiefe Verteilungen, Schätzen und Simulieren

In den Skripten 3 und 4 haben wir Verteilungen als fertige Modelle benutzt: Wir kannten p, λ, μ und σ und haben Wahrscheinlichkeiten ausgerechnet. In der Praxis ist es meistens umgekehrt. Ihr habt Logfiles, Antwortzeiten und Ticket-Zahlen, aber keine Parameter. Und die Daten sehen selten aus wie eine schöne Glocke. Heute lernen wir, schiefe Daten zu beschreiben und zu zähmen, aus Daten auf Parameter zu schließen und Probleme, für die es keine Formel gibt, einfach tausendfach durchzuspielen.

| Schritt | Frage | Abschnitt |
|---|---|---|
| **Form erkennen** | Wohin zieht der lange Ausläufer? | 1 |
| **Form messen** | Wie schief, wie spitz, wie fett die Ränder? | 2 |
| **Gruppen trennen** | Was bedeuten zwei Gipfel? | 3 |
| **Transformieren** | Wie wird aus schiefen Daten eine Glocke? | 4 |
| **Schätzen** | Welcher Parameter passt am besten zu meinen Daten? | 5 |
| **Simulieren** | Was tun, wenn es keine Formel gibt? | 6 |

> **Heute:** Zuerst lest ihr Formen ab, rechnet mit Logarithmen und spielt eine Monte-Carlo-Simulation mit Stift und Papier durch. Dann simuliert ihr in Pandas 100 000 Projekte und schätzt Parameter aus echten Logdaten.

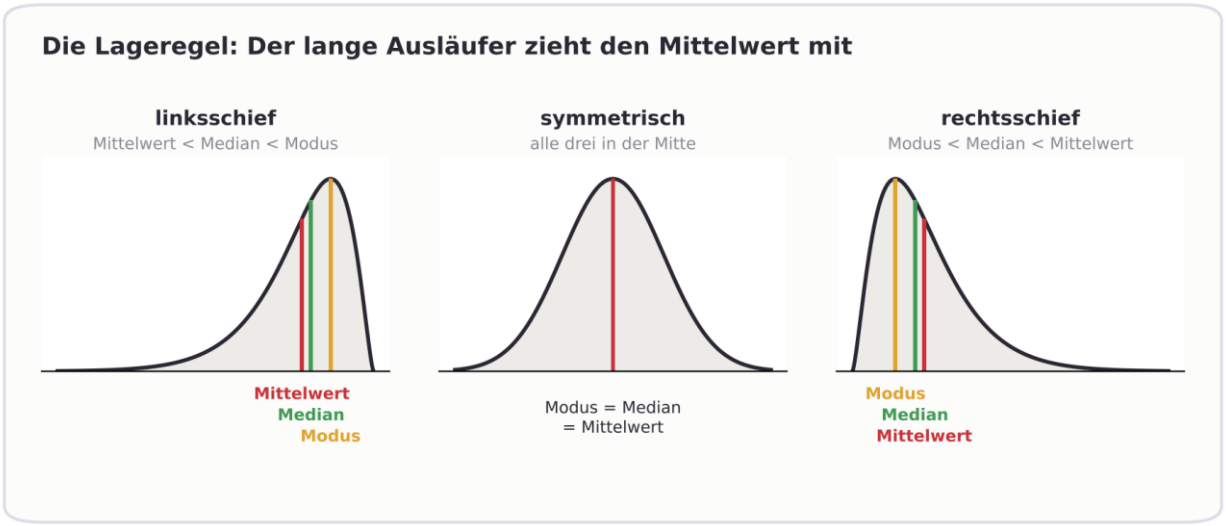
## 1 – Rechtsschief und linksschief



**Herr Bauchgefühl behauptet:**
„Unsere API braucht im Durchschnitt 54 Millisekunden. Eine typische Anfrage dauert also 54 Millisekunden.“

**1.1 – Echte Daten sind selten symmetrisch.** In der Realität sind Daten selten perfekt symmetrisch wie die Normalverteilung. Besonders in der IT, bei Antwortzeiten, Dateigrößen oder Benutzeraktivitäten, stoßen wir fast immer auf **asymmetrische** Verteilungen. Aus Statistik 2 und 4 kennt ihr schon die Begriffe rechtsschief und linksschief. Die Richtung der Schiefe beschreibt immer, wohin sich der längere „Schwanz“ (englisch: Tail) der Verteilung erstreckt, **nicht**, wo der höchste Hügel ist.

**1.2 – Die Igel-Drillinge zeigen die Richtung.** Erinnert euch an die Igel-Drillinge aus Statistik 2: **Modus** (gelber Schal) macht, was die meisten machen, und steht am Gipfel. **Median** (grüner Schal) stellt sich stur in die Mitte der Reihe. **Mittelwert** (roter Schal) rechnet jeden mit ein, auch den Kater ganz draußen, und wird deshalb vom langen Ausläufer mitgezogen.

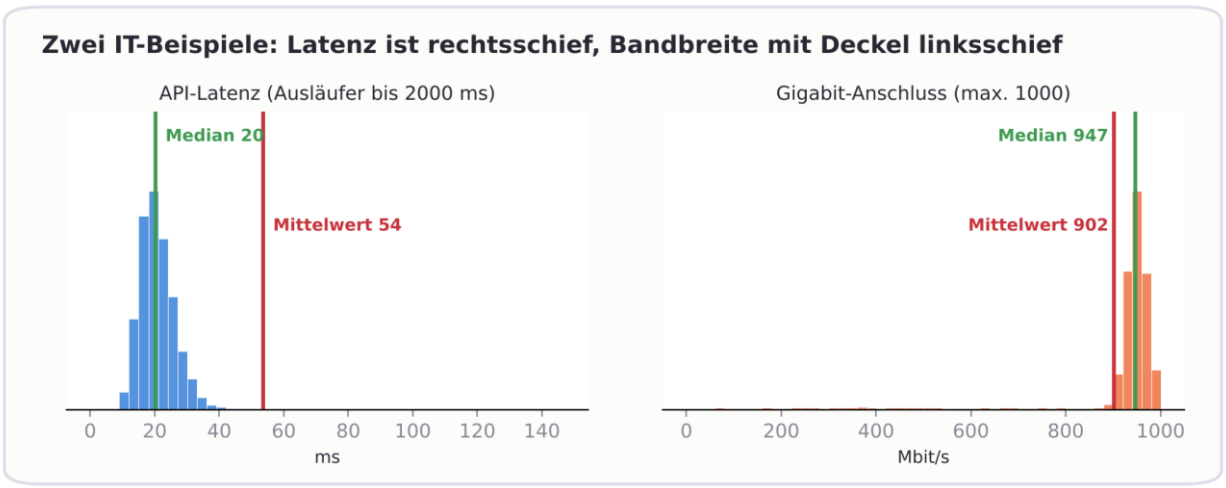



| | rechtsschief (linkssteil) | linksschief (rechtssteil) |
|---|---|---|
| **Form** | steigt links steil an, flacht nach rechts langsam ab | steigt von links flach an, Gipfel rechts, fällt steil ab |
| **langer Ausläufer** | nach rechts, zu hohen Werten | nach links, zu niedrigen Werten |
| **Lageregel** | Modus < Median < Mittelwert | Mittelwert < Median < Modus |
| **Wirkung** | wenige, sehr hohe Werte ziehen den Mittelwert nach oben | wenige, sehr niedrige Werte ziehen den Mittelwert nach unten |

> **Faustregel, kein Gesetz:** Die Lageregel stimmt für glatte Verteilungen mit einem Gipfel fast immer. Bei kleinen Datensätzen oder diskreten Werten mit wenigen Ausprägungen kann sie verletzt sein. Dann lieber ein Histogramm zeichnen.

**1.3 – IT-Beispiel rechtsschief: Antwortzeiten.** Die meisten API-Aufrufe dauern rund 20 ms. Einige wenige Anfragen dauern wegen Cold-Starts oder Datenbank-Timeouts aber bis zu 2000 ms. Schneller als eine Mindestzeit geht es nicht, langsamer fast beliebig. Diese seltenen Extremwerte ziehen den Mittelwert künstlich nach oben.

**1.4 – IT-Beispiel linksschief: der Gigabit-Anschluss.** Ein Internetanbieter schaltet ein Gigabit-Netz frei (maximal 1000 Mbit/s). Der Großteil der Kunden erreicht über eine stabile Glasfaserleitung konstant rund 950 Mbit/s. **Nach oben ist die Kurve hart gedeckelt.** Nach links gibt es einen langen Ausläufer: Kunden mit schlechter WLAN-Abdeckung, defekten Kabeln oder überlasteten Zielservern surfen nur mit 100 Mbit/s oder weniger. Diese Einzelfälle ziehen den Mittelwert nach unten. Linksschief wird es typischerweise immer dann, wenn es eine **Obergrenze** gibt, an der sich die Werte stauen: Bandbreite, Verfügbarkeit in Prozent, Punkte in einer leichten Klausur.






**Herr Bauchgefühl stutzt:**
„Der Median liegt bei 20 Millisekunden, der Mittelwert bei 54. Die typische Anfrage ist also viel schneller, ein paar lahme Ausreißer haben meinen Durchschnitt aufgebläht."

## 2 – Schiefe und Wölbung als Zahl

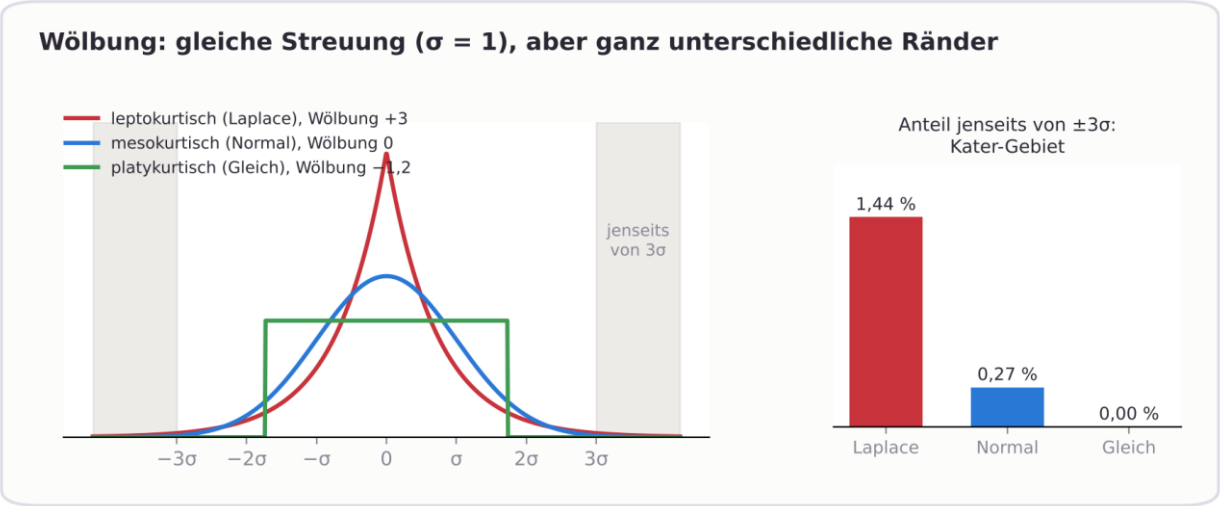
**2.1 – Die Schiefe (Skewness).** Statt nur „ein bisschen schief" zu sagen, kann man die Schiefe als **Kennzahl** berechnen. Die Idee kennt ihr: Jeder Wert bekommt seinen z-Wert aus Skript 4. Die z-Werte werden **hoch drei** genommen und gemittelt. Hoch drei behält das Vorzeichen und macht weit entfernte Werte sehr groß. Deshalb gewinnt die Seite mit dem längeren Ausläufer.

| Schiefe | Bedeutung |
|---|---|
| **ungefähr 0** | symmetrisch, z. B. Normalverteilung, Gleichverteilung |
| **größer als 0** | rechtsschief, langer Ausläufer nach rechts |
| **kleiner als 0** | linksschief, langer Ausläufer nach links |
| **zwischen −0,5 und 0,5** | Faustregel: annähernd symmetrisch |
| **über 1 bzw. unter −1** | Faustregel: stark schief |

Zum Vergleich aus Skript 4: Die Exponentialverteilung hat immer die Schiefe 2, die Anfahrt der Kurs-Umfrage hat 2,2. Beide sind also stark rechtsschief.

**2.2 – Die Wölbung (Kurtosis).** Neben der Schiefe gibt es ein zweites Maß für die Form: die **Wölbung**. Sie misst vor allem, **wie viel Masse in den Rändern** steckt, also wie oft extreme Werte vorkommen. Gerechnet wird wie bei der Schiefe, nur mit z-Werten **hoch vier**. Weil die Normalverteilung dabei 3 ergibt, ziehen Python und Excel 3 ab und zeigen die **Überschuss-Wölbung** (Exzess). Dann hat die Normalverteilung die Wölbung 0, und man liest nur noch das Vorzeichen.

| Typ | Wölbung (Exzess) | Form | Bedeutung |
|---|---|---|---|
| **leptokurtisch (steilgipflig)** | größer als 0 | spitze Mitte, fette Ränder | viele Normalfälle, aber überraschend oft extreme Ausreißer |
| **mesokurtisch** | ungefähr 0 | wie die Normalverteilung | Vergleichsmaßstab |
| **platykurtisch (flachgipflig)** | kleiner als 0 | breit, dünne Ränder | extreme Ausreißer sind sehr unwahrscheinlich |




**Häufiges Missverständnis:** Eine Glocke wird nicht leptokurtisch, nur weil sie schmal ist. Eine Normalverteilung mit kleinem σ ist schmaler und höher, hat aber trotzdem die Wölbung 0. Die Wölbung vergleicht Verteilungen **bei gleicher Streuung** und schaut auf die Ränder.

**IT-Beispiel:** Netzwerk-Traffic ist oft leptokurtisch. Fast immer läuft der normale Verkehr, aber plötzliche Lastspitzen, etwa eine DDoS-Attacke, treten viel häufiger auf, als eine Normalverteilung erwarten ließe. Wer hier mit den Sigma-Regeln plant, unterschätzt das Risiko.



**Der Ausreißer meldet sich:**
„Bei fetten Rändern komme ich fünfmal so oft vorbei wie bei der Normalverteilung. Und bei der Gleichverteilung komme ich gar nicht vor."

**So steht es in Büchern:** Schiefe = Mittelwert von $z^3$ Wölbung (Exzess) = Mittelwert von $z^4 - 3$

Rechnen müsst ihr das nicht von Hand. In Pandas heißen die Methoden skew() und kurt(), Excel kennt SCHIEFE und KURT.

**Zum Weiterlesen:** Schiefe einer Verteilung – Formel, links- und rechtsschief, Übungsaufgabe

**Zum Weiterlesen:** Kurtosis (Wölbung) – leptokurtisch vs. platykurtisch

## 3 – Zwei Gipfel: Mischverteilungen



**Etta sagt:**
„Die Antwortzeiten haben zwei Gipfel, einen bei 5 und einen bei 150 Millisekunden. Bevor ich irgendetwas mittele, sortiere ich lieber in zwei Gruppen.“

**3.1 – Bimodalität.** In Statistik 2 hieß eine Verteilung mit zwei häufigsten Werten **bimodal**. Gemeint ist hier mehr: zwei deutlich voneinander getrennte **Gipfel** (lokale Maxima) mit einem Tal dazwischen.

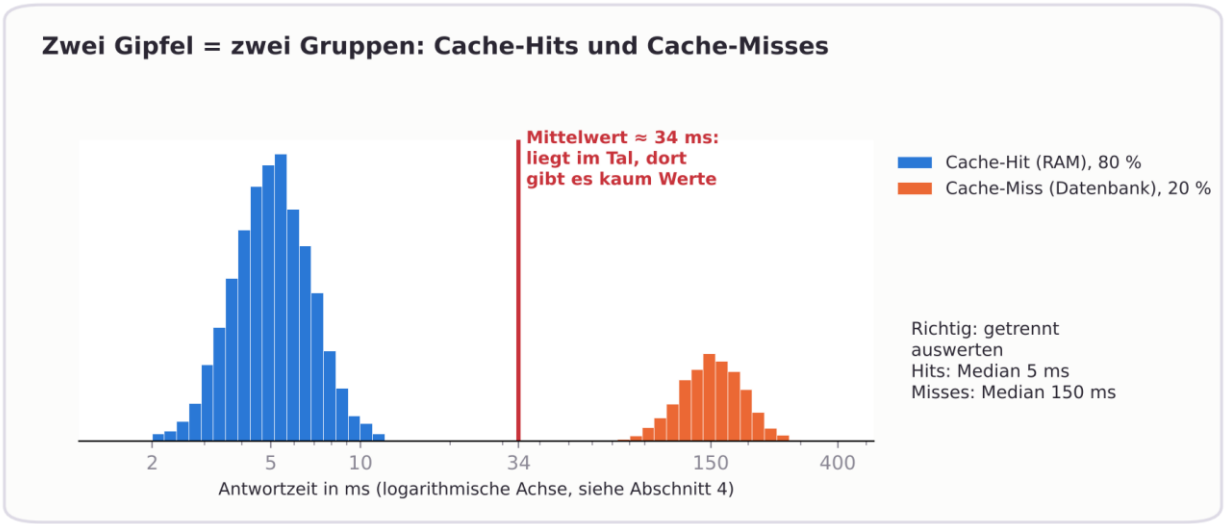
**3.2 – Die Ursache: zwei Gruppen in einem Datensatz.** Aus Sicht der Datenanalyse ist eine bimodale Verteilung fast nie das Ergebnis eines einzigen, einheitlichen Prozesses. Sie entsteht als **Mischverteilung**, wenn zwei Teilgruppen mit verschiedenen Eigenschaften in einem Datensatz vermischt werden. Berechnet man dann den Mittelwert, landet er irgendwo **im Tal zwischen den Gipfeln**, also dort, wo es in der Realität kaum Datenpunkte gibt. Der Mittelwert verliert seine Aussagekraft.

**3.3 – IT-Beispiel: Cache-Hits und Cache-Misses.** Das Monitoring einer Web-API zeigt eine Doppelspitze: einen hohen Gipfel bei 5 ms und einen flacheren bei 150 ms.

- **Gruppe 1, Cache-Hits (80 %):** Die Daten lagen schon im schnellen Arbeitsspeicher und wurden in rund 5 ms geliefert.
- **Gruppe 2, Cache-Misses (20 %):** Die Daten mussten aus der Datenbank geholt werden, rund 150 ms.

$$\text{Mittelwert} \approx 0{,}8 \cdot 5 + 0{,}2 \cdot 150 = 4 + 30 = 34 \text{ ms}$$

Keine einzige Anfrage dauert ungefähr 34 ms. Die Aussage „eine typische Anfrage dauert 34 ms“ beschreibt niemanden.

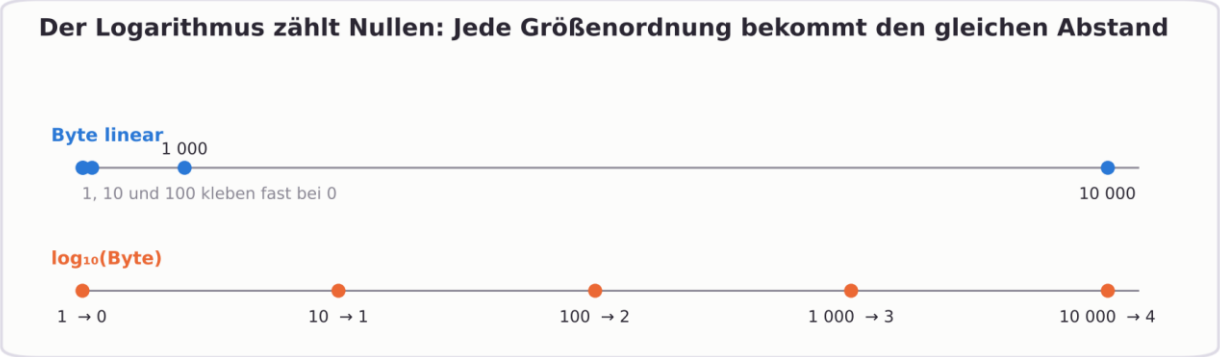


> **Praxis-Regel:** Zeigt eine Verteilung zwei Gipfel, ist der Datensatz nicht einheitlich. Sucht das Merkmal, das die Gruppen trennt (hier den Cache-Status), zerlegt die Daten und wertet jede Gruppe getrennt aus. In Pandas ist das ein groupby.

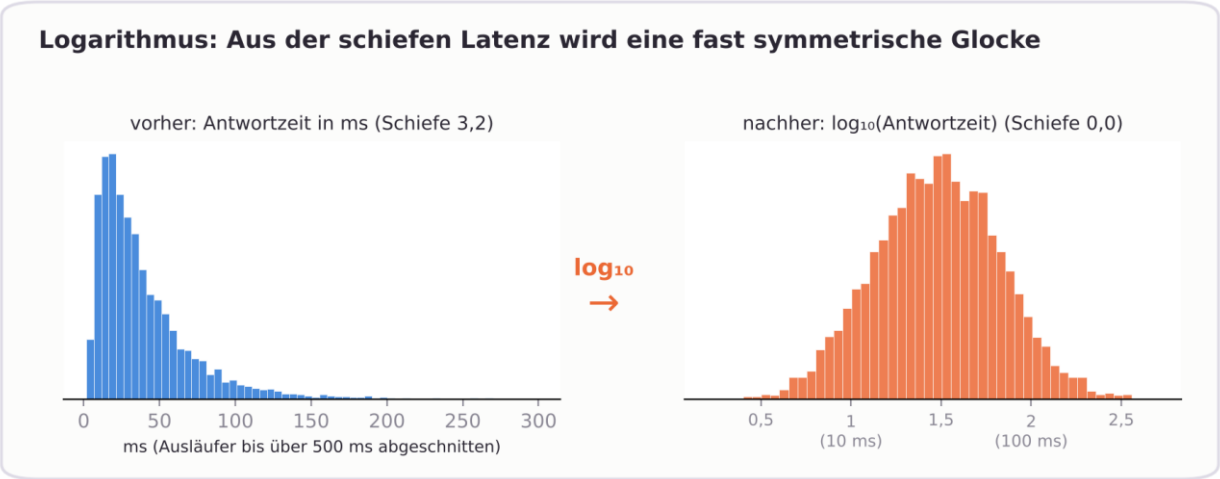
## 4 – Schiefe Daten transformieren

**4.1 – Warum transformieren?** Viele statistische Verfahren und Modelle arbeiten besser oder setzen sogar voraus, dass Daten (oder ihre Fehler) annähernd symmetrisch und normalverteilt sind, zum Beispiel der t-Test oder die lineare Regression. Füttert man ein Modell mit stark rechtsschiefen Daten wie Einkommen oder Server-Latenzen, bestimmen die wenigen Extremwerte das Ergebnis, und die Vorhersagen werden schlecht. Mit einer mathematischen **Transformation** staucht man die großen Werte zusammen und zieht die Verteilung in eine annähernd symmetrische Form.

**4.2 – Der Logarithmus zählt Nullen.** Die wichtigste Transformation ist der **Logarithmus**. Der Zehnerlogarithmus $\log_{10}$ beantwortet die Frage: „10 hoch wie viel ergibt x?“ Für glatte Zahlen zählt er einfach die Nullen: $\log_{10}(10) = 1$, $\log_{10}(100) = 2$, $\log_{10}(1000) = 3$. Aus Faktor 10 wird damit **plus 1**. Große Werte rücken zusammen, kleine Werte rücken auseinander.




In der Statistik und in Python benutzt man oft den natürlichen Logarithmus ln (Basis e ≈ 2,718). Für die Form ist das egal: Beide machen aus Faktoren gleiche Abstände.




Ist eine Größe nach dem Logarithmieren normalverteilt, heißt sie **log-normalverteilt**. Das ist das typische Modell für Antwortzeiten, Dateigrößen und Einkommen, die in Skript 4 im Ausblick schon angekündigt war.



**Der Ausreißer meldet sich:**
„Nach dem Logarithmus bin ich gar nicht mehr so weit draußen. Aus meinen 2000 Millisekunden wird eine 3,3, das fällt kaum noch auf.“

**4.3 – Die Methoden im Überblick.**

| Methode | Rechnung | Wann anwenden? | IT-Beispiel |
|---|---|---|---|
| **Log-Transformation** | $y = \log(x)$ | starke Rechtsschiefe, nur positive Werte ($x > 0$) | Dateigrößen: Aus Kilobyte bis Terabyte werden handliche Zahlen |
| **Log mit +1** | $y = \log(x + 1)$ | wie oben, aber es gibt Nullen ($\log(0)$ ist nicht definiert) | Downloads pro Tag, auch Tage mit 0 |
| **Wurzel** | $y = \sqrt{x}$ | mäßige Rechtsschiefe, Zähldaten (Poisson) | Fehlermeldungen pro Stunde |
| **Box-Cox** | automatisch gewählte Potenz | man weiß nicht, welche Potenz passt; nur $x > 0$ | automatisiertes Feature-Engineering |
| **Yeo-Johnson** | wie Box-Cox, erweitert | auch Nullen und negative Werte | Abweichungen vom Sollwert, Gewinn und Verlust |

> Box-Cox und Yeo-Johnson probieren viele Potenzen durch ($x^2$, $x^1$, $\sqrt{x}$, $\log x$, $1/x$ …) und nehmen die, nach der die Daten am symmetrischsten sind. Das erledigen Bibliotheken wie scikit-learn oder SciPy, von Hand macht das niemand.

**4.4 – Zurückrechnen: Vorsicht beim Mittelwert.** Hat man mit den transformierten Daten gerechnet, kann man das Ergebnis mit der **Umkehrfunktion** zurück in echte Einheiten bringen: nach $\log_{10}$ mit $10^x$, nach ln mit $e^x$, nach der Wurzel mit $x^2$. Das ist nicht immer nötig, aber für Berichte meist sinnvoll. Dabei gibt es eine Falle:

| Antwortzeit | 10 ms | 100 ms | 1000 ms | Mittelwert |
|---|---|---|---|---|
| **Originalwert** | 10 | 100 | 1000 | 370 ms |
| **$\log_{10}$** | 1 | 2 | 3 | 2 |
| **zurückgerechnet** | | | | $10^2 = 100$ ms |

Der zurückgerechnete Mittelwert der Logarithmen ist **nicht** der Mittelwert der Originaldaten (370 ms), sondern das **geometrische Mittel** (100 ms) aus dem Bonus von Statistik 2. Bei log-normalverteilten Daten liegt es genau beim Median. Für eine „typische“ Antwortzeit ist das sogar die bessere Zahl. Man muss nur dazuschreiben, was man berichtet.



**Nils sagt:**
„Ich zähle einfach die Nullen: 10, 100, 1000 sind 1, 2, 3. Der Mittelwert ist 2, zurück sind das 100. Das ist ja der Median!“

## 5 – Parameter schätzen



**Herr Bauchgefühl behauptet:**
„Ich habe 5 Testpakete geschickt, 3 sind angekommen. Die Leitung liefert also 60 % aller Pakete aus. Fertig.“

**5.1 – Der umgekehrte Weg.** In Skript 3 und 4 haben wir vorausgesetzt, dass wir die Parameter kennen: die Erfolgswahrscheinlichkeit p, die Rate λ, die Intervallgrenzen a und b. In der Praxis von Fachinformatikern für Daten- und Prozessanalyse ist der Weg genau umgekehrt: **Die Parameter sind unbekannt.** Alles, was ihr habt, sind die Daten, etwa Logfiles, Server-Antwortzeiten oder die Anzahl fehlerhafter Pakete in einer Stichprobe.

Man geht in zwei Schritten vor. Zuerst wählt man ein **Modell**, das zum Prozess passt. Beispiel: Eine Festplatte fällt in einem Zeitraum entweder aus oder läuft weiter, also passt die Binomialverteilung. Die Formel steht damit fest, aber p ist unbekannt. Dann **schätzt** man p so, dass das Modell die gemessenen Daten möglichst gut widerspiegelt. Geschätzte Werte bekommen ein Dach: $\hat{p}$ (sprich: „p Dach“).

**5.2 – Punktschätzung und Intervallschätzung.**

- **Punktschätzung:** Ein einzelner Wert ist der beste Tipp für den Parameter, z. B. $\hat{p} = 0{,}03$.
- **Intervallschätzung:** Ein Bereich, in dem der wahre Parameter mit hoher Sicherheit liegt, z. B. „p liegt zwischen 0,02 und 0,04“. Das ist das **Konfidenzintervall**. Wie man es berechnet, lernt ihr im Kapitel induktive Statistik.

**5.3 – Die Maximum-Likelihood-Methode.** Das am häufigsten benutzte Schätzverfahren in der Data Science ist die **Maximum-Likelihood-Methode** (ML-Schätzung, „größte Plausibilität“). Sie dreht die klassische Frage der Wahrscheinlichkeitsrechnung um:

| | Frage |
|---|---|
| **klassisch (Skript 3)** | „Wenn die Erfolgsquote p = 0,6 ist, wie wahrscheinlich kommen dann von 5 Paketen genau 3 an?“ |
| **Maximum Likelihood** | „Von 5 Paketen sind genau 3 angekommen. Bei welchem p wäre genau dieses Ergebnis am wahrscheinlichsten gewesen?“ |

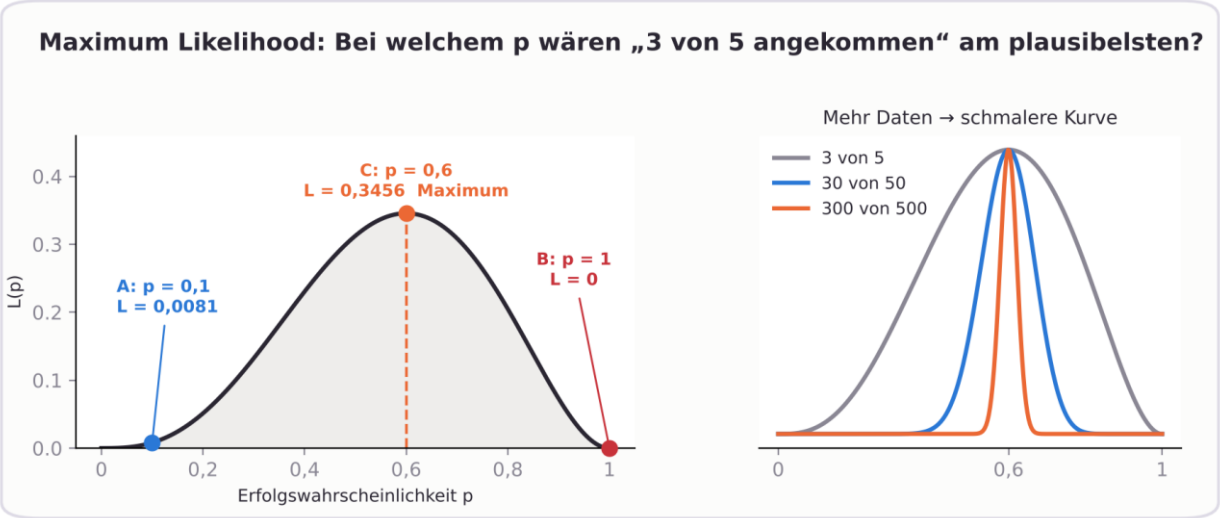
Gesucht ist also der Parameter, unter dem die **tatsächlich beobachteten Daten** am plausibelsten sind. Diese Plausibilität heißt **Likelihood** L.

**5.4 – Beispiel: Paketverlust.** Ein Skript sendet 5 Testpakete über eine Netzwerkverbindung. Ergebnis: **3 kamen an, 2 gingen verloren.** Wir nehmen an, der Prozess ist binomialverteilt (Skript 3). Wir setzen n = 5 und k = 3 ein. Weil p unbekannt ist, wird die Wahrscheinlichkeit zu einer Funktion von p, der **Likelihood-Funktion**:

$$L(p) = (5 \text{ über } 3) \cdot p^3 \cdot (1 - p)^2 = 10 \cdot p^3 \cdot (1 - p)^2$$

Jetzt probieren wir verschiedene Werte für p aus:

| Hypothese | Rechnung | L(p) | Fazit |
|---|---|---|---|
| **A: Leitung sehr schlecht, p = 0,1** | 10 · 0,001 · 0,81 | 0,0081 | Dass dann 3 von 5 ankommen, wäre extrem unwahrscheinlich (0,81 %). |
| **B: Leitung perfekt, p = 1** | 10 · 1 · 0 | 0 | Unmöglich: Wir hätten nie 2 Pakete verlieren können. |
| **C: der naheliegende Tipp, p = 0,6** | 10 · 0,216 · 0,16 | 0,3456 | Mit 34,56 % ist unser Ergebnis hier am plausibelsten. |




Zeichnet man L(p) für alle Werte zwischen 0 und 1, liegt der höchste Punkt genau bei p = 0,6. Der **Maximum-Likelihood-Schätzer** ist also $\hat{p} = 0{,}6 = 3/5$, die relative Häufigkeit.

**5.5 – Wie Computer das rechnen.** Von Hand zeichnet niemand diese Kurven. Das übernehmen Python-Bibliotheken wie SciPy (scipy.stats) oder statsmodels. Für das Verständnis hilft der Ablauf:

- **Likelihood aufstellen:** Die Messwerte gelten als unabhängig. Also multipliziert man die Wahrscheinlichkeiten aller Datenpunkte, wie bei der Pfadregel aus Skript 1.
- **Logarithmieren:** Tausende kleine Zahlen miteinander malzunehmen, ergibt am Computer irgendwann exakt 0 (Unterlauf, englisch: Underflow). Schon $0{,}5^{2000}$ ist für Python 0. Deshalb rechnet man mit dem Logarithmus der Likelihood, der **Log-Likelihood**. Der Logarithmus verwandelt Malnehmen in Addieren: $\ln(0{,}5^{2000}) = 2000 \cdot \ln(0{,}5) \approx -1386$, kein Problem. Und weil der Logarithmus immer steigt, bleibt das Maximum an derselben Stelle.
- **Maximum suchen:** Der Algorithmus sucht den höchsten Punkt der Log-Likelihood, entweder durch Ausprobieren vieler Werte oder mathematisch.

> **Für Mathe-Interessierte:** Mathematisch findet man das Maximum über die erste Ableitung, die man gleich null setzt: $d/dp \ln L(p) = 0$.
>
> Für die Standardverteilungen kommen dabei Formeln heraus, die ihr schon längst benutzt.

| Verteilung | ML-Schätzer | kennt ihr als … |
|---|---|---|
| **Binomial** | $\hat{p} = k / n$ | relative Häufigkeit (Statistik 1) |
| **Normal, Lage** | $\hat{\mu} = \bar{x}$ | arithmetischer Mittelwert (Statistik 2) |
| **Normal, Streuung** | $\hat{\sigma}$ = Wurzel aus (Summe der Abweichungen² / n) | Standardabweichung (Statistik 3), dort aber durch n − 1 |
| **Poisson** | $\hat{\lambda} = \bar{x}$ | mittlere Anzahl pro Intervall |
| **Exponential** | $\hat{\lambda} = 1 / \bar{x}$ | Kehrwert der mittleren Wartezeit |

Der kleine Unterschied bei σ: Der ML-Schätzer teilt durch n, die Stichproben-Standardabweichung aus Statistik 3 durch n − 1. Bei großen Datenmengen ist das praktisch egal, bei 5 Werten nicht.

**5.6 – Wie sicher ist die Schätzung?** Herr Bauchgefühl hat mit $\hat{p} = 0{,}6$ richtig gerechnet. Aber 5 Pakete sind sehr wenig. Mit 3 von 5 sind auch $p = 0{,}4$ oder $p = 0{,}8$ noch recht plausibel, die Likelihood-Kurve ist breit. Bei 300 von 500 Paketen ist der Schätzer wieder 0,6, aber die Kurve ist ganz schmal: Werte weit weg von 0,6 sind dann praktisch ausgeschlossen. **Mehr Daten, schmalere Kurve, genauere Schätzung.** Genau daraus wird im nächsten Kapitel das Konfidenzintervall.



**Mats sagt:**
„Bei 5 Paketen? Schick 500, dann glaube ich dir die 60 % eher.“

**Zum Weiterlesen:** Punktschätzung – ein Wert für den unbekannten Parameter

**Zum Weiterlesen:** Maximum-Likelihood-Methode – Beispiel Münzwurf, p = 0,6

## 6 – Monte-Carlo-Simulation



**Fiete Fuchs sagt:**
„Monte Carlo ist ein berühmtes Casino in Monaco. Einzelne Spiele sind reiner Zufall, aber über Millionen Spiele weiß die Bank sehr genau, was sie verdient. Genau diesen Trick nutzt die Monte-Carlo-Simulation.“

**6.1 – Die Idee.** Die **Monte-Carlo-Simulation** ist ein Verfahren, bei dem man ein Problem nicht exakt berechnet, sondern durch **massenhafte Zufallsexperimente** näherungsweise löst. Sie kommt immer dann zum Einsatz, wenn ein System zu komplex ist oder von zu vielen Zufallsfaktoren abhängt, um es mit einer

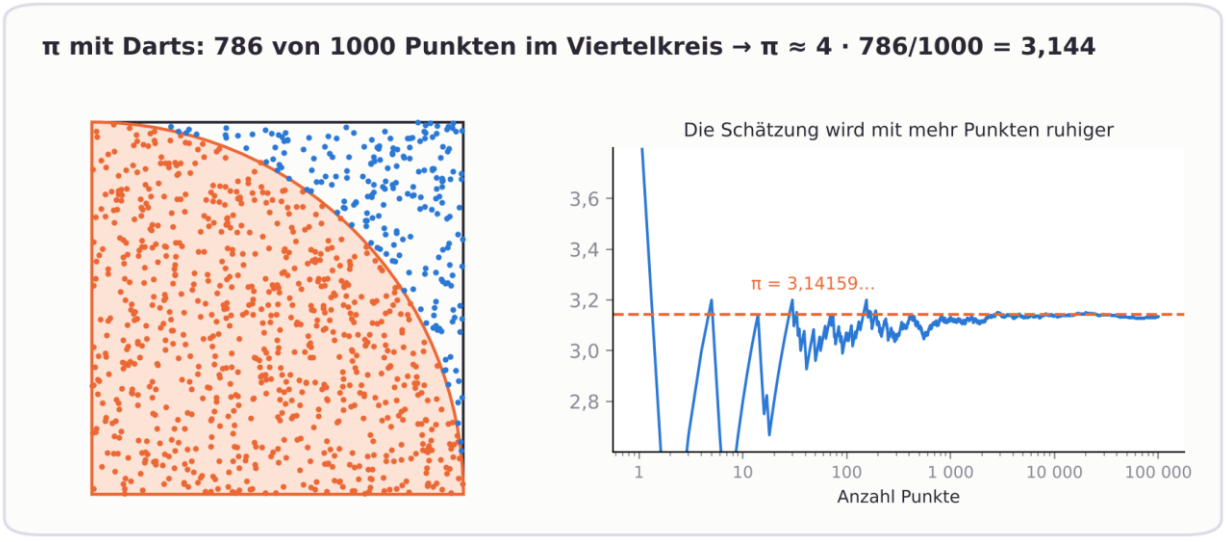
einfachen Formel zu berechnen. Ihr habt das schon gemacht: In Notebook 9 habt ihr den Bayes-Test mit 100 000 simulierten Personen nachgespielt.

**6.2 – Das Grundprinzip in vier Schritten.** Ihr wollt wissen, wie groß das Risiko ist, dass euer IT-Projekt die Deadline oder das Budget überschreitet:

| Schritt | Was passiert | Beispiel |
|---|---|---|
| **1. Unsicherheiten festlegen** | Für jede unsichere Größe eine Verteilung wählen | „Die Programmierung dauert mindestens 10, meistens 15, höchstens 30 Tage.“ |
| **2. Zufall würfeln** | Für jede Größe einen Zufallswert aus ihrer Verteilung ziehen | Konzept 6 Tage, Programmierung 22 Tage, Test 7 Tage |
| **3. Durchspielen** | Das Gesamtergebnis für diesen einen Durchlauf berechnen | „Durchlauf 1: 35 Tage, 52 500 €“ |
| **4. Massenhaft wiederholen** | Schritt 2 und 3 zehntausend- bis millionenfach | 100 000 Durchläufe → Häufigkeitsverteilung |

**6.3 – Ein anschauliches Beispiel: π mit Darts.** Man kann die Kreiszahl π experimentell bestimmen:

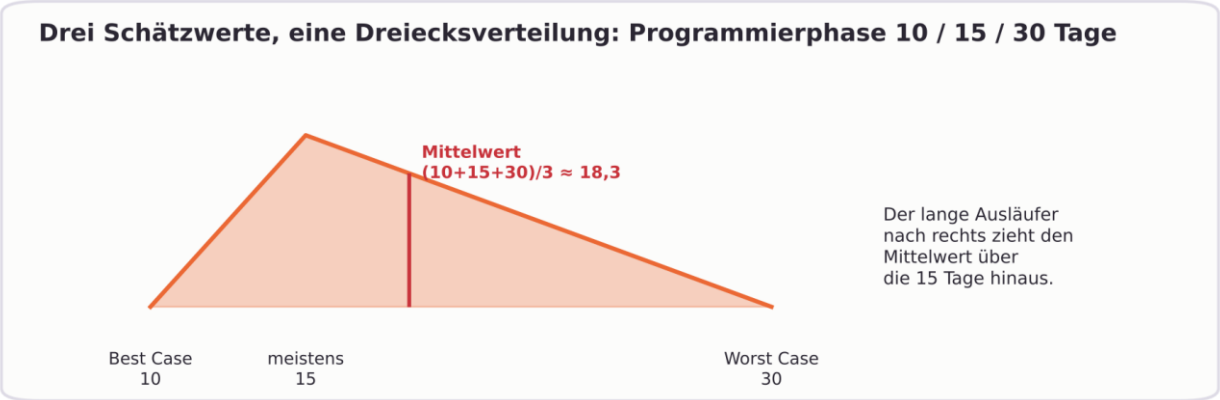
- Zeichnet ein Quadrat mit Seitenlänge 1 und darin einen Viertelkreis mit Radius 1.
- „Schießt“ völlig zufällig Punkte auf das Quadrat, wie beim Dartspielen mit verbundenen Augen. Jeder Punkt hat zwei gleichverteilte Koordinaten zwischen 0 und 1 (Skript 4).
- Zählt, wie viele Punkte im Viertelkreis gelandet sind. Ein Punkt liegt drin, wenn $x^2 + y^2 \leq 1$ ist.
- Der Anteil der Treffer nähert sich dem Verhältnis der Flächen: Viertelkreis / Quadrat = (π/4) / 1. Also gilt **π ≈ 4 · Anteil der Treffer**.




Je mehr Punkte, desto genauer, aber langsamer als man denkt: Bei 100 Punkten liegt die Schätzung typischerweise um ± 0,18 daneben, bei 10 000 Punkten um ± 0,014, bei einer Million um ± 0,002. **100-mal so viele Punkte bringen nur 10-mal so viel Genauigkeit.**

**6.4 – Die Dreiecksverteilung: drei Schätzwerte reichen.** Für Schritt 1 fragt man im Projektmanagement oft drei Werte ab: den günstigsten Fall (Best Case), den wahrscheinlichsten Fall („meistens“) und den

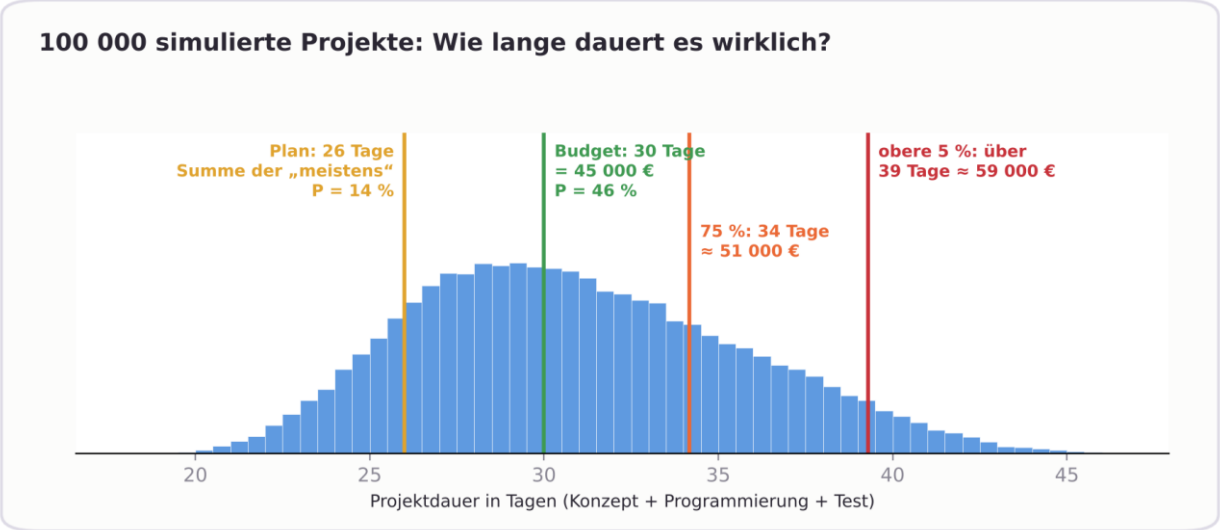
ungünstigsten Fall (Worst Case). Daraus entsteht eine **Dreiecksverteilung**. Ihr Mittelwert ist einfach der Durchschnitt der drei Werte. Weil Verzögerungen meist größer ausfallen als Beschleunigungen, ist das Dreieck fast immer rechtsschief.




**6.5 – Beispiel: Wie lange dauert unser Projekt?** Ein Projekt besteht aus drei Phasen nacheinander. Das Team kostet 1 500 € pro Tag, das Budget beträgt 45 000 €, also 30 Tage.

| Phase | Best Case | meistens | Worst Case | Mittelwert |
|---|---|---|---|---|
| **Konzept** | 3 | 5 | 8 | 5,3 |
| **Programmierung** | 10 | 15 | 30 | 18,3 |
| **Test** | 4 | 6 | 12 | 7,3 |
| **Summe** | 17 | 26 | 50 | 31,0 |

Der Computer zieht für jede Phase einen Wert aus ihrer Dreiecksverteilung, addiert die drei und wiederholt das 100 000-mal:




Am Ende steht kein einzelnes Ergebnis („Das Projekt kostet 39 000 €“), sondern eine **Verteilung**, aus der man ablesen kann:

- Der naheliegende Plan „wir rechnen mit den Meistens-Werten“ ergibt 26 Tage, wird aber nur in **14 %** der Fälle eingehalten.
- Das Budget von 30 Tagen (45 000 €) hält nur in **46 %** der Fälle.

- Mit einer Wahrscheinlichkeit von **75 %** ist das Projekt nach 34 Tagen fertig, das sind rund 51 000 €.
- Das Worst-Case-Risiko, die oberen 5 %: über 39 Tage, also über 59 000 €.

> **Warum ist der Plan so optimistisch?** Jede Phase ist rechtsschief, ihr Mittelwert liegt über dem Meistens-Wert. Addiert man drei Phasen, addieren sich auch diese Verschiebungen. Genau solche Effekte zeigt eine Simulation sofort, mit einer Formel wären sie mühsam.

### 6.6 – Wo Monte-Carlo eingesetzt wird.

- **Projektmanagement:** Risikoanalyse für Kosten und Deadlines bei Großprojekten, etwa in der Softwareentwicklung oder im Bauwesen.
- **Finanzwesen:** Entwicklung von Aktienkursen, Optionspreisen oder das Risiko eines Kreditportfolios.
- **Logistik und Produktion:** Engpässe in Lieferketten, Ausfallwahrscheinlichkeiten von Maschinen (Weibull aus Skript 4).
- **IT-Betrieb:** Kapazitätsplanung: Reichen drei Server, wenn die Anfragen Poisson-verteilt kommen und die Bearbeitungszeiten schief sind?
- **Künstliche Intelligenz:** Die „Monte Carlo Tree Search“ spielt Millionen zufälliger Spielverläufe durch, um den besten Zug zu finden, zum Beispiel bei AlphaGo.

### 6.7 – Vor- und Nachteile.

| Vorteile | Nachteile |
|---|---|
| bildet sehr komplexe Abhängigkeiten ab, die man nie mit einer Formel berechnen könnte | rechenaufwendig, ein „Brute-Force“-Verfahren mit vielen Durchläufen |
| liefert nicht nur einen Schätzwert, sondern eine ganze Risikoverteilung | Ergebnisse schwanken leicht von Lauf zu Lauf (Seed festlegen!) |
| leicht zu programmieren: ziehen, rechnen, zählen | Garbage in, Garbage out: Sind die Verteilungen aus Schritt 1 falsch geschätzt, ist das ganze Ergebnis wertlos |




**Herr Bauchgefühl stutzt:**
„100 000 Durchläufe, das klingt so genau. Aber wenn ich die Programmierung mit 10 bis 14 Tagen schätze, obwohl sie bisher immer 20 bis 40 gedauert hat, simuliert der Computer eben 100 000-mal meinen Irrtum.“

**Zum Ausprobieren:** Seeing Theory – Frequentist Inference: π schätzen, Konfidenzintervall, Bootstrap (englisch, interaktiv)

**Zum Weiterlesen:** A Simple Guide to Using Monte Carlo Simulation to Estimate Pi (Minitab, englisch)

## Auf einen Blick

| Begriff | Bedeutung / Formel |
|---|---|
| **rechtsschief** | langer Ausläufer rechts; Modus < Median < Mittelwert; Latenz, Dateigrößen |
| **linksschief** | langer Ausläufer links; Mittelwert < Median < Modus; Werte mit Obergrenze |
| **Schiefe** | Mittelwert von $z^3$; > 0 rechtsschief, < 0 linksschief, \|Schiefe\| > 1 stark |
| **Wölbung (Exzess)** | Mittelwert von $z^4 - 3$; Normal = 0; > 0 fette Ränder, < 0 dünne Ränder |
| **bimodal** | zwei Gipfel = zwei Gruppen; Mittelwert im Tal; Gruppen trennen |
| **Transformation** | log (x > 0), log(x + 1) bei Nullen, Wurzel bei Zähldaten, Box-Cox, Yeo-Johnson |
| **Rücktransformation** | 10^(Mittelwert der $\log_{10}$) = geometrisches Mittel ≈ Median, nicht der Mittelwert |
| **Punkt- / Intervallschätzung** | ein bester Wert $\hat{p}$ / ein Bereich (Konfidenzintervall) |
| **Maximum Likelihood** | der Parameter, unter dem die beobachteten Daten am plausibelsten sind; Log-Likelihood gegen Underflow |
| **Monte-Carlo** | Unsicherheiten als Verteilungen, zufällig ziehen, durchrechnen, massenhaft wiederholen; Garbage in, Garbage out |

**Ausblick:** Mit der Schätzung haben wir den Schritt von der Wahrscheinlichkeitsrechnung zur **induktiven Statistik** gemacht. Im nächsten Kapitel geht es darum, wie sicher solche Schätzungen sind (Konfidenzintervalle) und wie man Vermutungen mit Daten prüft (Hypothesentests).

# Übungen

Du brauchst Stift und Taschenrechner (mit log- und ln-Taste).

## Übung 1  Die Lageregel anwenden

*Gehört zu Abschnitt 1.*

Bestimme aus den drei Lagemaßen, ob die Verteilung rechtsschief, linksschief oder symmetrisch ist.

| Daten | Modus | Median | Mittelwert | Form |
|---|---|---|---|---|
| Ladezeit einer Webseite in ms | 20 | 24 | 31 | |
| Punkte in einer leichten Klausur | 81 | 78 | 72 | |
| Messfehler eines Thermometers in 0,1 °C | 0 | 0 | 0 | |
| Verfügbarkeit der Server in % | 99,9 | 99,5 | 97,8 | |

## Übung 2  Rechts oder links?

*Gehört zu Abschnitt 1.*

Überlege, wo sich die Werte stauen und in welche Richtung der lange Ausläufer zeigt.

| Größe | rechts- oder linksschief? | Begründung |
|---|---|---|
| Dateigrößen auf einem File-Server | | |
| Akkukapazität neuer Notebooks in % des Nennwerts | | |
| Anzahl Logins pro Person und Monat | | |
| Upload-Geschwindigkeit eines Anschlusses mit Obergrenze | | |

## Übung 3  Kennzahlen lesen

*Gehört zu Abschnitt 2.*

Ein Kollege hat für vier Datensätze Schiefe und Wölbung (Exzess) berechnet. Ordne jedem Datensatz die passende Quelle zu: Jitter gleichverteilt zwischen 10 und 50 ms, Messfehler eines Sensors, Dateigrößen, Verfügbarkeit in Prozent.

| Datensatz | Schiefe | Wölbung | Beschreibung der Form | Quelle |
|---|---|---|---|---|
| A | 0,03 | −0,05 | | |
| B | 2,4 | 9,1 | | |
| C | −0,9 | 0,4 | | |
| D | 0,0 | −1,2 | | |

## Übung 4 Der Cache und der Mittelwert

*Gehört zu Abschnitt 3.*

Eine API beantwortet Anfragen aus dem Cache in rund 5 ms, Anfragen an die Datenbank in rund 150 ms.

**a)** 80 % der Anfragen sind Cache-Hits. Berechne den Mittelwert ungefähr.

---

**b)** Im Bericht steht: „Eine typische Anfrage dauert 34 ms.“ Was ist daran falsch?

---

**c)** Nach einem Cache-Umbau sind 95 % der Anfragen Hits. Wie ändert sich der Mittelwert?

---

**d)** Wie sollte man die Antwortzeiten stattdessen berichten?

---

## Übung 5 Logarithmus von Hand

*Gehört zu Abschnitt 4.*

Fünf Dateien sind 1 KB, 10 KB, 100 KB, 1 000 KB und 10 000 KB groß.

**a)** Berechne Mittelwert und Median der Dateigrößen.

---

**b)** Berechne $\log_{10}$ jeder Dateigröße und den Mittelwert dieser Logarithmen.

---

**c)** Rechne den Mittelwert aus b) zurück. Mit welchem Wert aus a) stimmt er überein?

---

**d)** Welche Zahl beschreibt eine „typische“ Datei besser? Begründe.

---

## Übung 6 Welche Transformation passt?

*Gehört zu Abschnitt 4.*

Wähle eine passende Transformation: Log, Log mit +1, Wurzel, Yeo-Johnson oder keine.

| Daten | Transformation | Begründung |
|---|---|---|
| Dateigrößen in Byte, alle größer 0, stark rechtsschief | | |
| Fehlermeldungen pro Stunde, Zähldaten, leicht rechtsschief | | |
| Downloads pro Tag, stark rechtsschief, viele Tage mit 0 | | |
| Abweichung der Raumtemperatur vom Sollwert in °C, schief, auch negativ | | |
| Messfehler eines Sensors, symmetrisch | | |

## Übung 7 Parameter schätzen

*Gehört zu Abschnitt 5.*

Schätze jeweils den Parameter aus den Daten.

**a)** Von 200 Testpaketen gingen 6 verloren. Schätze die Verlustwahrscheinlichkeit p.

---

**b)** Tickets pro Stunde an sechs Stunden: 3, 5, 4, 2, 6, 4. Schätze λ der Poisson-Verteilung.

---

**c)** Zwischen zwei Monitoring-Alarmen vergehen im Mittel 12 Minuten. Schätze die Rate λ der Exponentialverteilung pro Stunde.

---

**d)** Fünf Latenzen: 44, 47, 43, 46, 45 ms. Schätze μ der Normalverteilung.

---

## Übung 8 Likelihood von Hand

*Gehört zu Abschnitt 5.*

Von 10 geprüften Paketen sind 3 fehlerhaft. p ist die unbekannte Fehlerquote. Die Likelihood ist $L(p) = 120 \cdot p^3 \cdot (1 - p)^7$.

**a)** Woher kommt die Zahl 120?

---

**b)** Berechne L(0,1), L(0,3) und L(0,5). ($0{,}9^7 \approx 0{,}478$; $0{,}7^7 \approx 0{,}082$; $0{,}5^7 \approx 0{,}0078$)

---

**c)** Welcher der drei Werte ist am plausibelsten? Wie lautet der ML-Schätzer?

---

## Übung 9 Warum logarithmieren?

*Gehört zu Abschnitt 5.*

Ein Algorithmus multipliziert die Wahrscheinlichkeiten von 2000 Datenpunkten, jede ist 0,5. Es gilt $\ln(0{,}5) \approx -0{,}693$.

**a)** Berechne $0{,}5 \cdot 0{,}5 \cdot 0{,}5 \cdot 0{,}5$ und ln davon. Rechne ln auch als $4 \cdot \ln(0{,}5)$.

---

**b)** Der Computer liefert für $0{,}5^{2000}$ genau 0. Was ist passiert, und wie hilft der Logarithmus?

---

**c)** Warum ändert das Logarithmieren nichts an der Stelle des Maximums?

---

## Übung 10 Wenig oder viel Daten?

*Gehört zu Abschnitt 5.*

Test A: 3 von 5 Paketen kamen an. Test B: 300 von 500 Paketen kamen an.

**a)** Berechne für beide Tests den ML-Schätzer.

---

**b)** Herr Bauchgefühl: „Beide Schätzungen sind 60 %, also sind sie gleich gut.“ Stimmt das?

---

**c)** Bei welchem Test wäre ein Konfidenzintervall breiter?

---

## Übung 11 π mit Darts

*Gehört zu Abschnitt 6.*

Von 1 000 zufälligen Punkten im Einheitsquadrat landen 786 im Viertelkreis.

**a)** Schätze π. Warum muss man mit 4 multiplizieren?

---

**b)** Eine Kollegin kommt mit 100 Punkten auf 3,24. Hat sie falsch gerechnet?

---

**c)** Wie viele Punkte braucht man ungefähr, um 10-mal genauer zu werden als mit 1 000 Punkten?

---

## Übung 12 Monte-Carlo mit Stift und Papier

*Gehört zu Abschnitt 6.*

Ein Projekt hat drei Phasen. Ein Programm hat für fünf Durchläufe schon Zufallswerte gezogen (in Tagen). Die Deadline liegt bei 30 Tagen.

| Durchlauf | Konzept | Programmierung | Test | Summe | Deadline gehalten? |
|---|---|---|---|---|---|
| 1 | 4 | 14 | 6 | | |
| 2 | 6 | 22 | 7 | | |
| 3 | 5 | 16 | 9 | | |
| 4 | 7 | 27 | 8 | | |
| 5 | 4 | 12 | 5 | | |

**a)** Ergänze die Tabelle. In wie viel Prozent der Durchläufe wird die Deadline gehalten?

---

**b)** Berechne die mittlere Projektdauer.

---

**c)** Warum reichen fünf Durchläufe nicht für eine Entscheidung?

---

## Übung 13 Ein Simulationsergebnis lesen

*Gehört zu Abschnitt 6.*

Die Simulation mit 100 000 Durchläufen liefert für die Projektdauer: 50 % der Projekte sind nach 30,5 Tagen fertig, 75 % nach 34 Tagen, 90 % nach 37,5 Tagen, 95 % nach 39 Tagen. Das Team kostet 1 500 € pro Tag.

**a)** Die Chefin will einen Termin, der mit 90 % Sicherheit hält. Welchen Termin und welches Budget nennst du?

---

**b)** Das bewilligte Budget beträgt 45 000 €. Wie wahrscheinlich reicht es ungefähr?

---

**c)** Das Team hat die Programmierung mit 10 / 12 / 14 Tagen geschätzt. Bei den letzten drei Projekten dauerte sie 22, 31 und 38 Tage. Was bedeutet das für die Simulation?

---

**d)** Herr Bauchgefühl: „100 000 Durchläufe! Das Ergebnis ist also exakt.“ Was antwortest du?

---