

Statistik 1

Grundbegriffe, Skalenniveaus und Tabellen

Willkommen in der **Datenwald-Akademie**, einem erfundenen Bildungsträger am Waldrand. In diesem Skript geht es um deskriptive Statistik: Daten beschreiben, ordnen und zusammenfassen.

Vier Gestalten begleiten dich durch die ganze Statistik-Woche:



Herr Bauchgefühl

leitet die Akademie und weiß alles, ohne je nachzuschauen



Etta

die Elster, sortiert alles nach Sorten und hängt ein Etikett dran



Nils

das Eichhörnchen, zählt und misst alles, was ihm zwischen die Pfoten kommt



Der Ausreißer

der Kater, immer weit weg vom Rest; heute huscht er nur kurz vorbei

So läuft jeder Abschnitt: Herr Bauchgefühl behauptet etwas. Die Daten entscheiden, ob er recht hat.

Heute: Vormittags klären wir die Begriffe ohne Computer, mit Stift und Strichliste. Nachmittags baut ihr dieselben Tabellen in Pandas nach.

1 – Nichts ist immer gleich



Herr Bauchgefühl behauptet:

„Unsere Teilnehmenden brauchen alle ungefähr eine halbe Stunde bis zur Akademie. Das weiß man doch.“

1.1 – Nachschauen statt glauben. Die Akademie hat 20 Teilnehmende befragt. Jede Zeile ist eine Person:

ID	Kurszeit	Getränk	T-Shirt	Haustiere	Anfahrt (Min.)
101	Vormittag	Kaffee	M	0	25
102	Abend	Tee	S	1	35
103	Vormittag	Mate	L	0	18
104	Vormittag	Kaffee	L	2	42
105	Abend	Wasser	M	0	30
106	Vormittag	Tee	M	1	28
107	Abend	Kaffee	XL	0	55
108	Vormittag	Kaffee	S	3	12
109	Vormittag	Mate	M	1	38
110	Abend	Tee	M	0	115

ID	Kurszeit	Getränk	T-Shirt	Haustiere	Anfahrt (Min.)
111	Vormittag	Kaffee	L	0	32
112	Abend	Mate	L	2	45
113	Vormittag	Wasser	S	1	22
114	Vormittag	Kaffee	M	0	35
115	Abend	Tee	L	1	48
116	Vormittag	Tee	M	0	30
117	Abend	Kaffee	M	3	65
118	Vormittag	Mate	XL	1	40
119	Abend	Wasser	S	0	52
120	Vormittag	Kaffee	L	2	25

1.2 – Die Spalte Anfahrt ansehen. Die kürzeste Anfahrt dauert 12 Minuten, die längste 115 Minuten.

1.3 – Die Werte schwanken. Von 12 bis 115 Minuten ist alles dabei. Fast nichts in der Welt ist bei allen gleich: Anfahrtswege, Getränkevorlieben, Prüfungsergebnisse. Genau das ist der Stoff der Statistik. Sie beschreibt, was typisch ist, wie stark die Werte schwanken und was aus der Reihe fällt.



Herr Bauchgefühl stutzt:
„115 Minuten? Wer fährt denn so weit?“



Der Ausreißer huscht vorbei.
Ein Wert, der weit weg von allen anderen liegt, heißt **Ausreißer**. Merk dir die 115: Ab dem nächsten Skript bringt er die Kennzahlen durcheinander.

4 – Zwei Arten von Statistik.

- **Deskriptive (beschreibende) Statistik** fasst die Daten zusammen, die man hat: zählen, ordnen, Kennzahlen berechnen, Diagramme zeichnen. Darum geht es in dieser Woche.
- **Schließende Statistik** zieht aus wenigen Daten Schlüsse über viele, die man nicht gefragt hat. Das kommt später.

Im Kurs: Stellt euch gegenseitig dieselben vier Fragen (Lieblingsgetränk, T-Shirt-Größe, Anzahl Haustiere, Anfahrt in Minuten) und sammelt die Antworten an der Tafel. Eure eigene Tabelle begleitet euch durch den Tag.

Zum Weiterlesen: [numiqo: Deskriptive Statistik und Inferenzstatistik](#)

2 – Wer, was, welcher Wert



Herr Bauchgefühl behauptet:

„Daten sind einfach Zahlen. Mehr muss man dazu nicht wissen.“

2.1 – Die Zeile: der Merkmalsträger. Jede Zeile steht für jemanden oder etwas, das untersucht wird. Das ist der **Merkmalsträger**. Hier sind es Personen. Es können genauso gut Songs, Geräte oder Kurse sein.

2.2 – Die Spalte: das Merkmal. Jede Spalte hält eine Eigenschaft fest, zum Beispiel das Lieblingsgetränk. Das ist ein **Merkmal**. Ein anderes Wort dafür ist **Variable**, weil der Wert von Träger zu Träger variiert.

2.3 – Die Zelle: die Merkmalsausprägung. Der Wert, den ein Merkmal bei einem bestimmten Träger hat, heißt **Merkmalsausprägung**.

Begriff	In der Tabelle	Beispiel aus der Umfrage
Merkmalsträger	Zeile	die Person mit der ID 103
Merkmal (Variable)	Spalte	Getränk
Merkmalsausprägung	Zelle	„Mate“

2.4 – Die Urliste. Alle Ausprägungen eines Merkmals, so unsortiert, wie sie erhoben wurden, nennt man **Urliste**. Für das Merkmal Getränk beginnt sie so: Kaffee, Tee, Mate, Kaffee, Wasser, Tee, Kaffee, Kaffee ...



Herr Bauchgefühl stutzt:

„Kaffee, Tee, Mate ... da steht ja gar keine Zahl.“

Stimmt. Daten sind oft Wörter. Ob man mit einem Merkmal rechnen darf, klären Etta und Nils in Abschnitt 4.

Ausblick. Später fragen wir, ob zwei Merkmale zusammenhängen, etwa Kurszeit und Lieblingsgetränk. Das Merkmal, das man erklären will, heißt dann **abhängige Variable**, das andere **unabhängige Variable**. Mehr dazu beim Streudiagramm.

Zum Weiterlesen: [Merkmale, Merkmalsträger und Grundgesamtheit](#)

3 – Grundgesamtheit und Stichprobe



Herr Bauchgefühl behauptet:

„Ich habe heute früh drei Leute an der Kaffeemaschine gefragt. Alle drei lieben Kaffee. Also lieben alle unsere Teilnehmenden Kaffee.“




Nils überlegt:

„Im Datenwald stehen 40 Bäume. Ich will wissen, wie viele Nüsse ein Baum im Schnitt trägt. Auf alle 40 klettern? Das schaffe ich nicht vor dem Winter. Ich nehme 6.“

● **Grundgesamtheit:** alle 40 Bäume ($N = 40$)

● **Stichprobe:** 6 Bäume ($n = 6$)



3.1 – Grundgesamtheit. Alle Merkmalsträger, über die man etwas wissen will. Bei Nils: alle 40 Bäume. Ihre Anzahl schreibt man als großes **N**.

3.2 – Stichprobe. Der Teil, den man tatsächlich untersucht. Bei Nils: 6 Bäume. Ihre Anzahl schreibt man als kleines **n**.

3.3 – Voll- oder Teilerhebung. Untersucht man alle, ist das eine **Vollerhebung**. Meist ist das zu teuer, dauert zu lange oder ist unmöglich: Wer die Qualität von Nüssen prüft, indem er jede knackt, hat danach keine mehr. Dann bleibt die **Teilerhebung**, also eine Stichprobe.

3.4 – Eine gute Stichprobe ist ein kleines Abbild. Sie heißt **repräsentativ**, wenn sie die Grundgesamtheit im Kleinen widerspiegelt. Der beste Weg dorthin ist der Zufall: Bei einer **Zufallsstichprobe** hat jeder Baum dieselbe Chance, ausgewählt zu werden.

3.5 – Eine schiefe Stichprobe täuscht. Kommen bestimmte Merkmalsträger leichter in die Stichprobe als andere, ist sie **verzerrt**.

Drei typische Fallen:

Falle	Was passiert	Beispiel
Bequeme Auswahl	Man nimmt, was gerade da ist.	Nils zählt nur die Bäume direkt am Weg.
Selbstselektion	Es antworten nur die, die antworten wollen.	Bei einer freiwilligen Online-Umfrage melden sich vor allem die sehr Zufriedenen und die sehr Verärgerten.
Survivorship Bias	Man sieht nur die, die übrig geblieben sind.	Die Akademie befragt nur Absolventen, wie gut der Kurs war. Wer abgebrochen hat, fehlt.

3.6 – Herr Bauchgefühls Kaffeemaschine. Seine drei Befragten haben die IDs 101, 104 und 108. Alle drei trinken Kaffee, das sind 100 %. In der ganzen Umfrage sind es 8 von 20, also 40 %.



Herr Bauchgefühl stutzt:

„Nur 40 %? An der Kaffeemaschine waren es alle!“

Wer an der Kaffeemaschine steht, trinkt eben Kaffee. Das ist eine bequeme Auswahl und keine Zufallsstichprobe.

3.7 – Auch Zufallsstichproben schwanken. Lost man mehrmals 5 der 20 Personen aus, fällt der Kaffee-Anteil jedes Mal anders aus, zum Beispiel 80 %, 20 % und 40 %. Eine Zahl aus einer Stichprobe ist deshalb immer nur eine **Schätzung** für die Grundgesamtheit. Je größer die Stichprobe, desto kleiner werden diese Schwankungen in der Regel.

Im Kurs: Schreibt die 20 Getränke aus der Umfrage auf Zettel, zieht mehrmals blind fünf davon und notiert jedes Mal den Kaffee-Anteil. Wie weit liegen eure Ergebnisse auseinander?

Zum Weiterlesen: [numigo: Stichproben](#)

4 – Qualitativ oder quantitativ



Herr Bauchgefühl behauptet:

„Wenn eine Zahl dasteht, kann man damit rechnen. Ich hätte gern die durchschnittliche Teilnehmer-ID für meinen Quartalsbericht.“

4.1 – Zwei Sorten von Merkmalen.



Etta ist zuständig für qualitative Merkmale.

Die Ausprägungen sind Namen, Sorten oder Etiketten. Ihre Frage lautet: „Welche Sorte?“ Beispiele: Getränk, Kurszeit, T-Shirt-Größe. Ein anderes Wort dafür ist **kategorial**.



Nils ist zuständig für quantitative Merkmale.

Die Ausprägungen sind echte Zahlen, gezählt oder gemessen. Seine Frage lautet: „Wie viele?“ oder „Wie viel?“ Beispiele: Anzahl Haustiere, Anfahrt in Minuten. Ein anderes Wort dafür ist **metrisch**.

4.2 – Der Differenz-Test. Bist du unsicher, zieh zwei Werte voneinander ab und frag dich, ob das Ergebnis etwas bedeutet.

- Anfahrt: 30 Minuten – 20 Minuten = 10 Minuten länger unterwegs. Das bedeutet etwas, also ist Nils zuständig.
- Teilnehmer-ID: 117 – 112 = 5. Fünf was? Das bedeutet nichts. Die ID ist ein Etikett aus Ziffern, also ist Etta zuständig.

Genauso verkleidet sind Postleitzahlen, Telefonnummern, Rückennummern und Kursnummern.

4.3 – Rechnen lässt sich trotzdem. Der Durchschnitt aller 20 Teilnehmer-IDs lässt sich ausrechnen. Er beträgt 110,5.



Herr Bauchgefühl stutzt:

„110,5. Und was schreibe ich jetzt dazu in den Quartalsbericht?“

Nichts. Ein Taschenrechner sieht nur Ziffern, nicht ihre Bedeutung. Dass die ID ein Etikett ist und die Anzahl der Haustiere eine echte Zahl, musst du wissen.

4.4 – Nils zählt oder misst. Quantitative Merkmale gibt es in zwei Arten:

	Diskret	Stetig
Wie entsteht der Wert?	durch Zählen	durch Messen
Welche Werte sind möglich?	nur einzelne Werte, dazwischen gibt es nichts	jeder Zwischenwert
Beispiel	Haustiere: 0, 1, 2, 3. Niemand hat 1,5 Haustiere.	Anfahrt: 27 Minuten, 27,5 Minuten, 27,53 Minuten ...

4.5 – Stetig bleibt stetig, auch wenn gerundet wird. In der Umfrage steht die Anfahrt in ganzen Minuten. Das liegt an der Frage, nicht am Merkmal: Mit einer Stoppuhr käme 27 Minuten und 31 Sekunden heraus. Wie genau ein stetiger Wert ist, hängt nur vom Messgerät ab.

Überblick:

Merkmalsart	Unterart	So entsteht der Wert	In der Umfrage
qualitativ (Etta)		Sorten und Etiketten	Getränk, Kurszeit, T-Shirt-Größe, Teilnehmer-ID
quantitativ (Nils)	diskret	gezählt	Anzahl Haustiere
quantitativ (Nils)	stetig	gemessen	Anfahrt in Minuten


5 – Die vier Skalenniveaus



Herr Bauchgefühl behauptet:

„Gestern hatten wir 10 °C, heute sind es 20 °C. Heute ist es also doppelt so warm!“

5.1 – Was darf man mit den Werten tun? Das **Skalenniveau** eines Merkmals legt fest, welche Vergleiche und Rechnungen sinnvoll sind. Es gibt vier Stufen. Jede kann alles, was die Stufe darunter kann, und eine Sache mehr.



5.2 – Nominal: nur gleich oder verschieden. Die Ausprägungen sind Namen ohne Reihenfolge. Man kann nur sagen, ob zwei Personen dasselbe Getränk mögen oder nicht. Beispiele: Getränk, Kurszeit, Postleitzahl.

5.3 – Ordinal: dazu eine Reihenfolge. Die Ausprägungen lassen sich ordnen, aber die Abstände sind unbekannt. $S < M < L < XL$, doch niemand weiß, ob zwischen S und M genauso viel liegt wie zwischen L und XL. Beispiele: T-Shirt-Größe, Schulnoten, Platzierungen, Zufriedenheit von 1 bis 5.

5.4 – Intervall: dazu gleiche Abstände. Jetzt sind Differenzen sinnvoll, aber der Nullpunkt ist willkürlich gewählt. 0 °C heißt nicht „keine Temperatur“. Beispiele: Temperatur in °C, Jahreszahlen, Uhrzeiten.

5.5 – Verhältnis: dazu ein echter Nullpunkt. Null bedeutet wirklich „nichts da“. Erst jetzt sind Aussagen wie „doppelt so viel“ erlaubt. Beispiele: Anfahrt in Minuten, Anzahl Haustiere, Alter, Preis, Gewicht.

Intervall- und Verhältnisskala zusammen heißen **metrisch**.

Skalenniveau	Was ist sinnvoll?	Beispiel	Zuständig
Nominal	gleich / verschieden	Getränk	Etta
Ordinal	+ größer / kleiner	T-Shirt-Größe	Etta
Intervall	+ Differenzen	Temperatur in °C	Nils
Verhältnis	+ Verhältnisse („doppelt so ...“)	Anfahrt in Minuten	Nils

5.6 – Zurück zu Herrn Bauchgefühl. Temperatur in °C ist intervallskaliert. „10 Grad wärmer“ stimmt, „doppelt so warm“ nicht. Kelvin ist die Temperaturskala mit echtem Nullpunkt. Dort sind es 283,15 K und 293,15 K. Das Verhältnis ist 1,035, also ein Plus von rund 3,5 %.



Herr Bauchgefühl stutzt:

„Dreieinhalb Prozent wärmer. Das klingt deutlich weniger beeindruckend.“

5.7 – Stolperfallen.

Merkmal	Skalenniveau	Warum
Postleitzahl	nominal	12487 ist nicht „mehr“ als 10115.
Schulnote	ordinal	Der Abstand zwischen 1 und 2 muss nicht dem zwischen 4 und 5 entsprechen.
Zufriedenheit von 1 bis 5	ordinal	Wie bei der Schulnote.
Geburtsjahr	Intervall	Das Jahr 0 ist kein Anfang der Zeit.
Alter	Verhältnis	0 Jahre ist ein echter Nullpunkt, 40 ist doppelt so alt wie 20.

Notendurchschnitte werden trotzdem überall berechnet. Das ist üblich, aber streng genommen eine Vereinfachung. Gut zu wissen, wenn jemand aus einer 2,3 und einer 2,4 große Schlüsse zieht.

5.8 – Wozu das Ganze? Das Skalenniveau entscheidet, welche Kennzahlen und Diagramme erlaubt sind. Ein Vorgeschmack auf das nächste Skript: Den häufigsten Wert gibt es schon bei nominalen Merkmalen, die „Mitte“ erst ab ordinal, den Durchschnitt erst bei metrischen.

Zum Weiterlesen: [numiqo: Skalenniveau](#)

6 – Die Häufigkeitstabelle



Herr Bauchgefühl behauptet:

„Acht Leute trinken am liebsten Kaffee. Das ist die Mehrheit!“

**Etta sortiert:**

„20 Antworten durcheinander sagen wenig. Ich mache eine Strichliste und zähle.“

Getränk	Strichliste	absolut	relativ	in Prozent
Kaffee		8	0,40	40 %
Tee		5	0,25	25 %
Mate		4	0,20	20 %
Wasser		3	0,15	15 %
Summe		20	1,00	100 %

6.1 – Absolute Häufigkeit. Die Anzahl, wie oft eine Ausprägung vorkommt. Alle absoluten Häufigkeiten zusammen ergeben n , hier 20.

6.2 – Relative Häufigkeit. Der Anteil: absolute Häufigkeit geteilt durch n . Für Kaffee sind das $8 / 20 = 0,40$, also 40 %. Alle relativen Häufigkeiten zusammen ergeben 1, also 100 %.

**Herr Bauchgefühl stutzt:**

„40 %. Das ist ja gar nicht die Mehrheit.“

Kaffee ist die häufigste Antwort, aber eine Mehrheit bräuchte mehr als 50 %. Sechs von zehn Befragten bevorzugen etwas anderes.

6.3 – Warum Anteile? Absolute Zahlen lassen sich nur vergleichen, wenn die Gruppen gleich groß sind. 8 Kaffee-Fans unter 20 Befragten sind 40 %. 30 Kaffee-Fans unter 100 Befragten sind nur 30 %, obwohl 30 größer ist als 8.

6.4 – Kumulierte Häufigkeit. Man zählt alle Häufigkeiten bis einschließlich einer Ausprägung zusammen. Das beantwortet Fragen mit „höchstens“. Sinnvoll ist das nur, wenn die Ausprägungen eine Reihenfolge haben, also ab ordinalem Niveau. „Höchstens Tee“ ergibt keinen Sinn, „höchstens Größe M“ schon.

T-Shirt	absolut	relativ	kumuliert	kumuliert relativ
S	4	0,20	4	0,20
M	8	0,40	12	0,60
L	6	0,30	18	0,90
XL	2	0,10	20	1,00

Lies die Zeile M: 8 Personen tragen M (absolut), das sind 40 % (relativ). 12 Personen tragen höchstens M (kumuliert), das sind 60 % (kumuliert relativ).

6.5 – Zu viele verschiedene Werte? Klassen bilden. Bei der Anfahrt kommt fast jeder Wert nur ein- oder zweimal vor. Eine Häufigkeitstabelle wäre fast so lang wie die Urliste. Deshalb fasst man Werte zu **Klassen**

zusammen. Zwei Regeln: Die Klassen dürfen sich nicht überlappen, und jeder Wert muss in genau eine Klasse fallen.

Anfahrt	Schreibweise	Anzahl
bis 20 Minuten	$(0, 20]$	2
über 20 bis 40 Minuten	$(20, 40]$	11
über 40 bis 60 Minuten	$(40, 60]$	5
über 60 bis 120 Minuten	$(60, 120]$	2

Die runde Klammer heißt „ausschließlich“, die eckige „einschließlich“. Aus genau so einer Klassentabelle entsteht später das Histogramm. Und in der letzten Klasse sitzt, weit weg vom Rest, wieder der Ausreißer.

Zum Weiterlesen: [numiqo: Häufigkeitstabelle](#)

7 – Die Kreuztabelle



Herr Bauchgefühl behauptet:

„Kaffee ist bei uns überall die Nummer eins. Ob Vormittags- oder Abendkurs, völlig egal.“

7.1 – Zwei Merkmale gleichzeitig zählen. Eine Häufigkeitstabelle zählt ein Merkmal. Eine **Kreuztabelle** (auch Kontingenztabelle) zählt zwei auf einmal: Die Zeilen sind die Ausprägungen des einen Merkmals, die Spalten die des anderen. In jeder Zelle steht, wie viele Merkmalsträger beide Ausprägungen haben.

Kurszeit	Kaffee	Mate	Tee	Wasser	Gesamt
Abend	2	1	3	2	8
Vormittag	6	3	2	1	12
Gesamt	8	4	5	3	20

Lies die Zelle Abend / Tee: 3 Personen besuchen den Abendkurs und trinken am liebsten Tee.

7.2 – Randhäufigkeiten. Die Summen am Rand sind die einfachen Häufigkeitstabellen der beiden Merkmale. Rechts steht: 8 Personen im Abendkurs, 12 im Vormittagskurs. Unten steht die Getränke-Tabelle aus Abschnitt 6.

7.3 – Ungleich große Gruppen brauchen Prozente. Im Vormittagskurs trinken 6 Personen Kaffee, im Abendkurs 2. Aber der Vormittagskurs ist auch größer. Fair wird der Vergleich erst mit Anteilen.

Davon gibt es drei Arten, und jede beantwortet eine andere Frage:

Art	Was ergibt 100 %?	Beispielfrage
Zeilenprozente	jede Zeile	Wie viel Prozent des Abendkurses trinken Tee?
Spaltenprozente	jede Spalte	Wie viel Prozent der Tee-Fans sitzen im Abendkurs?
Gesamtprozente	die ganze Tabelle	Wie viel Prozent aller Befragten sitzen im Abendkurs und trinken Tee?

7.4 – Herr Bauchgeföhls Behauptung prüfen. Er vergleicht die Kurse miteinander. Jeder Kurs muss also für sich 100 % ergeben: Zeilenprozente.

Kurszeit	Kaffee	Mate	Tee	Wasser	Gesamt
Abend	25,0 %	12,5 %	37,5 %	25,0 %	100 %
Vormittag	50,0 %	25,0 %	16,7 %	8,3 %	100 %

Im Vormittagskurs liegt Kaffee mit 50 % klar vorn. Im Abendkurs führt Tee mit 37,5 %, Kaffee kommt nur auf 25 %.



Herr Bauchgeföhls stutzt:

„Die Abendleute trinken Tee? Na gut. Um die Uhrzeit will ja auch keiner mehr wach bleiben.“

7.5 – Zwei Warnungen.

- **Kleine Gruppen:** Im Abendkurs sitzen nur 8 Befragte. Eine einzige Person macht dort 12,5 Prozentpunkte aus. Solche Anteile schwanken stark.
- **Die Erklärung mit der Uhrzeit ist schon wieder Bauchgeföhls.** Die Tabelle zeigt einen Unterschied zwischen den Kursen, aber nicht, woher er kommt. Dazu mehr beim Thema Korrelation und Kausalität.

7.6 – Für welche Merkmale? Kreuztabellen eignen sich für nominale und ordinale Merkmale sowie für diskrete mit wenigen Ausprägungen. Metrische Merkmale mit vielen Werten teilt man vorher in Klassen ein.

Zum Weiterlesen: [numiqo: Kreuztabelle](#)



Bis zum nächsten Skript.

Dort geht es um Lagemaße: Was ist ein typischer Wert? Der Ausreißer hat dazu eine sehr eigene Meinung.

Statistik 1 – Übungen

Grundbegriffe, Skalenniveaus und Tabellen · ohne Computer



Herr Bauchgefühl meint:

„Übungen? Das kann ich alles aus dem Bauch heraus.“ Zeig ihm, dass Stift und Strichliste zuverlässiger sind.

Für die Übungen 7 bis 10 brauchst du die Kurs-Umfrage der Datenwald-Akademie:

ID	Kurszeit	Getränk	T-Shirt	Haustiere	Anfahrt (Min.)
101	Vormittag	Kaffee	M	0	25
102	Abend	Tee	S	1	35
103	Vormittag	Mate	L	0	18
104	Vormittag	Kaffee	L	2	42
105	Abend	Wasser	M	0	30
106	Vormittag	Tee	M	1	28
107	Abend	Kaffee	XL	0	55
108	Vormittag	Kaffee	S	3	12
109	Vormittag	Mate	M	1	38
110	Abend	Tee	M	0	115
111	Vormittag	Kaffee	L	0	32
112	Abend	Mate	L	2	45
113	Vormittag	Wasser	S	1	22
114	Vormittag	Kaffee	M	0	35
115	Abend	Tee	L	1	48
116	Vormittag	Tee	M	0	30
117	Abend	Kaffee	M	3	65
118	Vormittag	Mate	XL	1	40
119	Abend	Wasser	S	0	52
120	Vormittag	Kaffee	L	2	25

Übung 1 Wer, was, welcher Wert?

Gehört zu Abschnitt 2 im Skript.

Ergänze die Tabelle.

Situation	Merkmalsträger	Merkmal	eine mögliche Ausprägung
Eine Bibliothek notiert für jedes Buch die Seitenzahl.			
Ein Fitnessstudio erfasst für jedes Mitglied den Tarif.			
Eine Hitliste führt für jeden Song die Anzahl der Wochen in den Charts.			

Wie viele Merkmalsträger und wie viele Merkmale hat die Kurs-Umfrage?

Übung 2 Stichprobe oder Schieflage?

Gehört zu Abschnitt 3 im Skript.

Beantworte für jede Situation: Was ist die Grundgesamtheit? Ist die Stichprobe in Ordnung? Wenn nein: Welche Falle ist es?

a) Ein Fitnessstudio will wissen, wie oft seine Mitglieder pro Woche trainieren. Es fragt alle, die am Montag um 6 Uhr früh da sind.

b) Die Akademie lost aus der Liste aller Teilnehmenden 50 Namen aus und ruft diese Personen an.

c) Ein Online-Shop will wissen, wie zufrieden seine Kundschaft ist, und wertet dafür die abgegebenen Sterne-Bewertungen aus.

Übung 3 Wer ist die Grundgesamtheit?

Gehört zu Abschnitt 3 im Skript.

Benenne jeweils Grundgesamtheit und Stichprobe.

Situation	Grundgesamtheit	Stichprobe
Eine Bäckerei probiert von jedem Blech ein Brötchen, um die Qualität der Tagesproduktion zu prüfen.		
Ein Institut befragt 1.000 Erwachsene in Berlin, wie zufrieden sie mit dem Nahverkehr sind.		
Ein Streamingdienst wertet die Hördauer von 5.000 zufällig gewählten Konten aus.		

Übung 4 Etta, Nils beim Zählen oder Nils beim Messen?

Gehört zu Abschnitt 4 im Skript.

Trage für jedes Merkmal **qualitativ**, **diskret** oder **stetig** ein.

Merkmal	qualitativ, diskret oder stetig?
Anzahl Tore in einem Fußballspiel	
Körpertemperatur	
Automarke	
Anzahl Fehltage	
Ladezeit einer Webseite	
Telefonnummer	
Gewicht eines Pakets	
Kfz-Kennzeichen	

Übung 5 Sortierspiel: Welche Stufe?

Gehört zu Abschnitt 5 im Skript.

Trage für jedes Merkmal das Skalenniveau ein: **nominal**, **ordinal**, **Intervall** oder **Verhältnis**.

Merkmal	Skalenniveau
Postleitzahl	
Schulnote	
Körpergröße in cm	
Temperatur in °C	
Lieblingsfarbe	
Platz im 100-m-Lauf	
Anzahl Geschwister	
Geburtsjahr	
Monatsmiete in Euro	
Hotelsterne	

Übung 6 Herr Bauchgeföhls Quartalsbericht

Gehört zu Abschnitt 5 im Skript.

In jedem Satz steckt ein Fehler. Erkläre, warum die Aussage nicht sinnvoll ist, und schlage vor, was man stattdessen sagen könnte.

1. „Die durchschnittliche Postleitzahl unserer Teilnehmenden ist 12487.“

2. „Die durchschnittliche T-Shirt-Größe ist 2,3.“ (codiert als S = 1, M = 2, L = 3, XL = 4)

3. „Im Seminarraum sind es 24 °C, im Flur 12 °C. Im Raum ist es also doppelt so warm.“

Übung 7 Haustiere zählen

Gehört zu Abschnitt 6 im Skript.

Erstelle für das Merkmal Haustiere eine Häufigkeitstabelle. Mach zuerst eine Strichliste aus der Kurs-Umfrage.

Anzahl Haustiere	Strichliste	absolut	relativ	kumuliert relativ
0				
1				
2				
3				
Summe				

a) Wie viel Prozent haben kein Haustier?

b) Wie viel Prozent haben höchstens ein Haustier?

c) Wie viel Prozent haben mindestens zwei Haustiere?

Übung 8 Eigene Klassen

Gehört zu Abschnitt 6 im Skript.

Teile die Anfahrt in drei Klassen ein und zähle aus.

Klasse	Strichliste	absolut	relativ
bis 30 Minuten			
über 30 bis 60 Minuten			
über 60 bis 120 Minuten			

Wie viel Prozent brauchen länger als 60 Minuten?

Übung 9 Haustier und Kurszeit

Gehört zu Abschnitt 7 im Skript.

Zähle aus, wie viele Personen in jedem Kurs mindestens ein Haustier haben, und fülle die Kreuztabelle samt Randhäufigkeiten aus.

Kurszeit	Haustier: ja	Haustier: nein	Gesamt
Abend			
Vormittag			
Gesamt			

a) Wie viel Prozent aller Befragten sitzen im Abendkurs und haben ein Haustier? Welche Prozentuierung ist das?

b) In welchem Kurs ist der Anteil der Haustierbesitzer höher? Welche Prozentuierung brauchst du?

Übung 10 Welche Prozente beantworten welche Frage?

Gehört zu Abschnitt 7 im Skript.

Nimm die Kreuztabelle aus Kurszeit und Getränk aus dem Skript (Abschnitt 7). Entscheide zuerst, welche Prozentuierung du brauchst, und rechne dann.

a) Wie viel Prozent der Mate-Fans sitzen im Vormittagskurs?

b) Wie viel Prozent des Vormittagskurses trinken am liebsten Mate?
