

Statistik 3

Streuungsmaße und Quantile

Wieder in der **Datenwald-Akademie**. Letztens ging es darum, wo die Daten liegen. Heute fragen wir, wie weit sie auseinanderliegen.

Mit dabei: Herr Bauchgefühl, die Igel Median und Mittelwert und der Ausreißer, der heute seinen Steckbrief bekommt.

Heute: Anfangs rechnen wir mit Stift und Taschenrechner. Weiter berechnet ihr dieselben Werte in Pandas.

Wir arbeiten weiter mit der Kurs-Umfrage:

ID	Kurszeit	Getränk	T-Shirt	Haustiere	Anfahrt (Min.)
101	Vormittag	Kaffee	M	0	25
102	Abend	Tee	S	1	35
103	Vormittag	Mate	L	0	18
104	Vormittag	Kaffee	L	2	42
105	Abend	Wasser	M	0	30
106	Vormittag	Tee	M	1	28
107	Abend	Kaffee	XL	0	55
108	Vormittag	Kaffee	S	3	12
109	Vormittag	Mate	M	1	38
110	Abend	Tee	M	0	115
111	Vormittag	Kaffee	L	0	32
112	Abend	Mate	L	2	45
113	Vormittag	Wasser	S	1	22
114	Vormittag	Kaffee	M	0	35
115	Abend	Tee	L	1	48
116	Vormittag	Tee	M	0	30
117	Abend	Kaffee	M	3	65
118	Vormittag	Mate	XL	1	40
119	Abend	Wasser	S	0	52
120	Vormittag	Kaffee	L	2	25

Die 20 Anfahrtszeiten, sortiert:

12 18 22 25 25 28 30 30 32 35 35 38 40 42 45 48 52 55 65 115

1 – Gleicher Mittelwert, anderes Bild



Herr Bauchgefühl behauptet:

„Kurs A fährt im Schnitt 40 Minuten zur Akademie, Kurs B auch. Die beiden Kurse sind also gleich. Ein Stundenplan für alle!“

Kurs A: 38, 39, 40, 41, 42



Kurs B: 5, 15, 25, 40, 115



1.1 – Hinschauen. In Kurs A liegen alle zwischen 38 und 42 Minuten. In Kurs B reicht es von 5 bis 115 Minuten. Derselbe Mittelwert, zwei völlig verschiedene Kurse.

1.2 – Was dem Lagemaß fehlt. Ein Lagemaß sagt, wo die Mitte ist. Ein **Streuungsmaß** sagt, wie weit die Werte um diese Mitte verteilt sind. Erst beide zusammen beschreiben eine Datenreihe.

1.3 – Die drei Streuungsmaße von heute.

Streuungsmaß	Idee	Gehört zu
Spannweite	Abstand zwischen kleinstem und größtem Wert	schneller erster Blick
Quartilsabstand	Breite des Bereichs, in dem die mittleren 50 % liegen	Median
Standardabweichung	typischer Abstand der Werte vom Mittelwert	Mittelwert



Herr Bauchgefühl stutzt:

„In Kurs B kommt einer nach fünf Minuten an und einer nach fast zwei Stunden. Gut, ein Stundenplan für alle wird schwierig.“

Zum Weiterlesen: [numiqo: Varianz, Standardabweichung, Spannweite](#)

2 – Die Spannweite



Herr Bauchgefühl behauptet:

„Größter Wert minus kleinster Wert. Mehr Streuungsmaß braucht kein Mensch.“

2.1 – Maximum minus Minimum. Die **Spannweite** ist der Abstand zwischen dem größten und dem kleinsten Wert. Kurs A: $42 - 38 = 4$ Minuten. Kurs B: $115 - 5 = 110$ Minuten. Die Kurs-Umfrage: $115 - 12 = 103$ Minuten.

2.2 – Ihr Vorteil. Sie ist in Sekunden berechnet und sofort verständlich.

3.3 – Ihre Schwäche. Sie hängt nur an zwei Werten, alle anderen sind ihr egal. Und einer der beiden ist oft ein Ausreißer. Ohne die 115 wäre die Spannweite der Umfrage $65 - 12 = 53$ Minuten. Ein einziger Wert verdoppelt sie fast.



Der Ausreißer meldet sich:

„103 Minuten Spannweite, und fast die Hälfte davon geht auf mein Konto.“



Herr Bauchgefühl stutzt:

„Ein Streuungsmaß, das von einem einzigen Kater abhängt. Hm.“

3 – Quartile und Quantile



Herr Bauchgefühl behauptet:

„Der Median teilt die Reihe in zwei Hälften. Feiner muss man nicht teilen.“



Median sagt:

„Teilt man jede meiner Hälften noch einmal, sind es vier Viertel. Die Schnittstellen heißen Quartile.“

3.1 – Drei Schnitte, vier Viertel. Die **Quartile** teilen die sortierte Reihe in vier gleich große Teile.

- **Q1** (unteres Quartil): Ein Viertel der Werte liegt darunter.
- **Q2** ist der Median: Die Hälfte liegt darunter.
- **Q3** (oberes Quartil): Drei Viertel liegen darunter.


3.2 – Das Rezept von Hand. Erst sortieren. Dann den Median bestimmen, er teilt die Reihe in eine untere und eine obere Hälfte. Q1 ist der Median der unteren Hälfte, Q3 der Median der oberen Hälfte. Bei ungerader Anzahl gehört der mittlere Wert zu keiner Hälfte.

3.3 – Die Anfahrt. Die untere Hälfte hat 10 Werte, ihre Mitte liegt zwischen dem 5. und dem 6. Wert:

12 18 22 25 **25** | **28** 30 30 32 35 → $Q1 = (25 + 28) / 2 = 26,5$

Die obere Hälfte genauso:

35 38 40 42 **45** | **48** 52 55 65 115 → $Q3 = (45 + 48) / 2 = 46,5$



3.4 – Lesen. Ein Viertel der Befragten braucht höchstens 26,5 Minuten. Die Hälfte braucht höchstens 35 Minuten. Drei Viertel brauchen höchstens 46,5 Minuten.

3.5 – Die Fünf-Punkte-Zusammenfassung. Minimum, Q1, Median, Q3 und Maximum. Mit fünf Zahlen hat man ein Bild der ganzen Verteilung. Am Diagramm-Tag wird daraus der Boxplot.

Minimum	Q1	Median	Q3	Maximum
12	26,5	35	46,5	115

3.6 – Quantile allgemein. Ein **Quantil** ist ein Wert, unter dem ein bestimmter Anteil der Daten liegt. Die Quartile sind die Quantile für 25 %, 50 % und 75 %. Teilt man in hundert Teile, spricht man von **Perzentilen**: Das 90. Perzentil ist der Wert, unter dem 90 % der Daten liegen. Die Idee kennst du schon: Der Median war die Stelle, an der die kumulierte Häufigkeit 50 % erreicht.

3.7 – Achtung, es gibt mehrere Rechenregeln. Liegt ein Quartil zwischen zwei Werten, gibt es verschiedene übliche Regeln, wo genau man es ansetzt. Unser Rezept nimmt die Mitte. Programme rechnen oft anders und landen leicht daneben: Pandas liefert heute Nachmittag $Q1 = 27,25$ und $Q3 = 45,75$. Beides ist richtig. Wichtig ist nur zu wissen, welche Regel verwendet wurde.



Herr Bauchgefühl stutzt:

„Vier Viertel. Dann weiß ich endlich, wer bei der Anfahrt ‚das obere Viertel‘ ist: alle über 46,5 Minuten.“

4 – Der Quartilsabstand und der Steckbrief des Ausreißers



Herr Bauchgefühl behauptet:

„Ob ein Wert ein Ausreißer ist, sieht man doch. Das entscheide ich nach Gefühl.“


4.1 – Der Quartilsabstand. Der **Quartilsabstand** ist $Q3$ minus $Q1$. Man kürzt ihn mit **IQR** ab, vom englischen interquartile range. Bei der Anfahrt: $46,5 - 26,5 = 20$ Minuten. So breit ist der Bereich, in dem die mittleren 50 % liegen.

4.2 – Er ist robust. Die äußeren Viertel spielen für ihn keine Rolle. Ohne die 115 liegen die Quartile bei 25 und 45, der Abstand bleibt 20.

4.3 – Eine Regel statt Gefühl. Ein Wert gilt als Ausreißer, wenn er mehr als das 1,5-Fache des Quartilsabstands unter Q1 oder über Q3 liegt. Diese beiden Grenzen nennt man **Zäune**.

$$\text{unterer Zaun} = Q1 - 1,5 \cdot IQR = 26,5 - 30 = -3,5$$

$$\text{oberer Zaun} = Q3 + 1,5 \cdot IQR = 46,5 + 30 = 76,5$$



4.4 – Anwenden. Unter $-3,5$ liegt nichts, negative Anfahrten gibt es nicht. Über $76,5$ liegt genau ein Wert: die 115. Die 65 Minuten sind lang, aber noch innerhalb des Zauns.



Der Ausreißer meldet sich:

„Über den Zaun bin ich mit Anlauf. Jetzt ist es amtlich.“

4.5 – Die Regel ist eine Vereinbarung. 1,5 ist eine verbreitete Faustregel, kein Naturgesetz. Sie markiert Werte, die man sich genauer ansehen sollte. Ob man sie behält, entscheidet man danach, wie gestern besprochen.



Herr Bauchgefühl stutzt:

„Eine Regel statt Gefühl. Dann kann mir wenigstens keiner vorwerfen, ich könnte den Kater bloß nicht leiden.“

Zum Weiterlesen: [numiqo: Boxplot](#) (Quartile, Quartilsabstand und Ausreißer)

5 – Varianz und Standardabweichung



Herr Bauchgefühl behauptet:

„Ich will wissen, wie weit die Leute im Schnitt vom Mittelwert weg sind. Also: Abstände zum Mittelwert ausrechnen und mitteln. Fertig.“



Mittelwert sagt:

„Gute Idee. Nur heben sich meine Abstände nach links und nach rechts immer genau auf.“

5.1 – Abweichungen ausrechnen. Für jeden Wert: Wert minus Mittelwert. Kurs A hat den Mittelwert 40.

Wert	Abweichung vom Mittelwert	Abweichung zum Quadrat
38	-2	4
39	-1	1
40	0	0
41	+1	1
42	+2	4
Summe	0	10

5.2 – Das Problem. Die Abweichungen ergeben zusammen immer 0. Das ist kein Zufall: Der Mittelwert ist genau der Punkt, an dem sich Plus und Minus ausgleichen. Das war gestern die Wippe.

5.3 – Der Trick: quadrieren. Quadrate sind nie negativ, also hebt sich nichts mehr auf. Große Abweichungen zählen dabei besonders stark.

5.4 – Die Varianz. Der Mittelwert der quadrierten Abweichungen heißt **Varianz**. Für Kurs A: $10 / 5 = 2$.

$$\text{Varianz} = ((x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2) / n$$

5.5 – Die Standardabweichung. Die Varianz hat eine seltsame Einheit, nämlich Quadratminuten. Zieht man die Wurzel, ist man zurück bei Minuten. Das Ergebnis heißt **Standardabweichung**. Für Kurs A: $\sqrt{2} \approx 1,4$ Minuten.

$$\text{Standardabweichung} = \sqrt{\text{Varianz}}$$

5.6 – Kurs B zum Vergleich.

Wert	Abweichung vom Mittelwert	Abweichung zum Quadrat
5	-35	1225
15	-25	625
25	-15	225
40	0	0
115	+75	5625
Summe	0	7700

Varianz: $7700 / 5 = 1540$. Standardabweichung: $\sqrt{1540} \approx 39,2$ Minuten.

5.7 – Lesen. Die Standardabweichung ist so etwas wie der typische Abstand eines Werts vom Mittelwert. Jetzt zeigt sich der Unterschied zwischen den Kursen auch in Zahlen:

Kurs	Mittelwert	Spannweite	Standardabweichung
A	40	4	1,4
B	40	110	39,2



Herr Bauchgefühl stutzt:

„Gleicher Mittelwert, aber 1,4 gegen 39 Minuten. Die Kurse sind also doch nicht gleich.“

5.8 – Empfindlich gegen Ausreißer. Wie der Mittelwert rechnet die Standardabweichung jeden Wert mit ein. Durch das Quadrieren wiegen Ausreißer sogar besonders schwer: In Kurs B stammen 5625 der 7700 Quadratpunkte allein von der 115.

Zum Weiterlesen: [numigo: Standardabweichung](#)

6 – Teilen durch n oder durch n – 1?



Herr Bauchgefühl behauptet:

„Geteilt wird durch die Anzahl. Wodurch denn sonst?“

6.1 – Fall 1: Man hat alle. Kennt man die Werte der ganzen Grundgesamtheit, teilt man durch n. Kurs A und Kurs B waren vollständig, also war das richtig.

6.2 – Fall 2: Man hat eine Stichprobe. Die Kurs-Umfrage ist eine Stichprobe: 20 von allen Teilnehmenden der Akademie. Will man damit die Streuung in der ganzen Akademie schätzen, teilt man durch n – 1, hier also durch 19.

6.3 – Warum eins weniger? Der Mittelwert einer Stichprobe wird aus genau diesen Werten berechnet und liegt ihnen deshalb näher als der wahre Mittelwert der Grundgesamtheit. Die Abweichungen fallen dadurch etwas zu klein aus. Das Teilen durch n – 1 gleicht das aus.

6.4 – Die Umfrage. Die quadrierten Abweichungen vom Mittelwert 39,6 ergeben zusammen 9212,8.

Die 20 Werte sind ...	geteilt durch	Varianz	Standardabweichung
die Grundgesamtheit	n = 20	460,6	21,5 Minuten
eine Stichprobe	n – 1 = 19	484,9	22,0 Minuten

6.5 – Die Schreibweise. Für die Grundgesamtheit schreibt man σ (Sigma) für die Standardabweichung und σ^2 für die Varianz. Für die Stichprobe schreibt man s und s^2 . Viele Taschenrechner haben dafür zwei verschiedene Tasten.

5.6 – Wie groß ist der Unterschied? Bei 20 Werten kaum: 21,5 gegen 22,0. Bei 5 Werten ist er deutlich, bei 1.000 Werten fast nicht mehr zu sehen. Wichtig für heute Nachmittag: Pandas teilt von sich aus durch $n - 1$.



Herr Bauchgefühl stutzt:

„Eins abziehen, weil die Stichprobe sich selbst zu gut kennt. Darauf wäre mein Bauch nie gekommen.“

7 – Robust oder empfindlich



Herr Bauchgefühl behauptet:

„Standardabweichung! Das Wort allein macht schon Eindruck. Die nehme ich ab jetzt immer.“

7.1 – Der Test mit dem Ausreißer. Dieselbe Umfrage, einmal mit und einmal ohne die 115:

Streuungsmaß	mit Ausreißer	ohne Ausreißer
Spannweite	103	53
Standardabweichung (s)	22,0	13,4
Quartilsabstand	20	20

7.2 – Zwei Paare, die zusammengehören.

- **Mittelwert und Standardabweichung:** Beide rechnen jeden Wert mit ein. Sie passen zu symmetrischen Daten ohne Ausreißer.
- **Median und Quartilsabstand:** Beide achten nur auf die Reihenfolge. Sie passen zu schiefen Daten und zu Daten mit Ausreißern.

7.3 – Die Anfahrt berichten. Sie ist rechtsschief und hat einen Ausreißer, also: Median 35 Minuten, Quartilsabstand 20 Minuten. Wer zusätzlich Mittelwert und Standardabweichung nennt (39,6 und 22,0), zeigt gleich mit, dass etwas an den Daten zieht.

7.4 – Und das Skalenniveau? Spannweite, Quartilsabstand und Standardabweichung rechnen mit Abständen und brauchen deshalb metrische Merkmale. Bei ordinalen Merkmalen kann man die Quartile selbst angeben, etwa $Q1 = M$ und $Q3 = L$ bei den T-Shirts. Voneinander abziehen kann man sie nicht.



Herr Bauchgefühl stutzt:

„Median 35, Quartilsabstand 20. Kürzer bekomme ich die Anfahrt meiner Leute nicht beschrieben.“

8 – Bonus: Vergleichen über Einheiten hinweg



Herr Bauchgefühl behauptet:

„Die Anfahrt streut um 22, die Haustiere nur um 1. Bei den Haustieren sind sich unsere Leute also viel ähnlicher.“

8.1 – Äpfel und Birnen. 22 Minuten und 1 Haustier lassen sich nicht vergleichen: andere Einheit, andere Größenordnung.

8.2 – Der Variationskoeffizient. Man teilt die Standardabweichung durch den Mittelwert und erhält die Streuung als Anteil des Mittelwerts, ganz ohne Einheit. Anfahrt: $22,0 / 39,6 \approx 0,56$, also 56 %. Haustiere: $1,02 / 0,9 \approx 1,13$, also 113 %. Relativ gesehen streuen die Haustiere doppelt so stark. Sinnvoll ist das nur bei Merkmalen mit echtem Nullpunkt.



Herr Bauchgefühl stutzt:

„Bei den Haustieren sind sie sich also am wenigsten ähnlich. Von null bis drei ist eben viel, wenn der Schnitt unter eins liegt.“

8.3 – Der z-Wert. Wie ungewöhnlich ist ein einzelner Wert? Der **z-Wert** misst seinen Abstand vom Mittelwert in Standardabweichungen:

$$z = (x - \bar{x}) / s$$

Für die 115 Minuten: $(115 - 39,6) / 22,0 \approx 3,4$. Für die 65 Minuten: $(65 - 39,6) / 22,0 \approx 1,2$. Als Faustregel gilt ein Wert ab etwa 2 als auffällig und ab 3 als sehr ungewöhnlich.



Der Ausreißer meldet sich:

„3,4 Standardabweichungen vom Mittelwert. Ich nenne das Persönlichkeit.“

Zum Weiterlesen: [numiqo: z-Standardisierung](#)

Übungen

Alle Übungen gehen mit Stift und Taschenrechner. Die Quartile bestimmst du mit dem Rezept aus Abschnitt 3.

Übung 1 Von ganz klein bis ganz groß

Gehört zu Abschnitt 2.

a) Höchsttemperaturen einer Woche in °C: 14, 17, 15, 21, 19, 16, 18. Berechne die Spannweite.

b) Bearbeitungszeiten in Minuten: 12, 15, 11, 48, 13. Berechne die Spannweite mit und ohne die 48.

Übung 2 Vier Viertel

Gehört zu Abschnitt 3.

Acht Prüfungsergebnisse in Punkten: 70, 52, 84, 61, 93, 75, 64, 78. Sortiere und trage die Fünf-Punkte-Zusammenfassung ein.

Minimum	Q1	Median	Q3	Maximum

Übung 3 Ungerade Anzahl

Gehört zu Abschnitt 3.

Neun Wartezeiten in Minuten: 9, 3, 12, 6, 20, 5, 15, 8, 11. Bestimme Median, Q1, Q3 und den Quartilsabstand.

Übung 4 Steht der Kater auch im Abendkurs draußen?

Gehört zu Abschnitt 4.

Die acht Anfahrtszeiten im Abendkurs: 30, 35, 45, 48, 52, 55, 65, 115.

a) Bestimme Q1, Q3 und den Quartilsabstand.

b) Berechne beide Zäune. Welche Werte sind nach der Regel Ausreißer?

Übung 5 Varianz von Hand

Gehört zu Abschnitt 5.

Fünf Teilnehmende lernen pro Woche 4, 6, 5, 9 und 6 Stunden. Der Mittelwert ist 6. Fülle die Tabelle aus und berechne Varianz und Standardabweichung. Die fünf sind die ganze Lerngruppe, teile also durch n.

Wert	Abweichung vom Mittelwert	Abweichung zum Quadrat
4		
6		
5		
9		
6		
Summe		

Übung 6 Zahlen lesen

Gehört zu Abschnitt 5.

Kurs C und Kurs D haben in der Abschlussprüfung beide im Mittel 70 Punkte. Die Standardabweichung beträgt in Kurs C 5 Punkte, in Kurs D 18 Punkte. In welchem Kurs sind die Leistungen einheitlicher? In welchem gibt es eher sehr gute und sehr schwache Ergebnisse?

Übung 7 n oder n – 1?

Gehört zu Abschnitt 6.

a) Entscheide für jede Situation, wodurch geteilt wird.

Situation	geteilt durch
Ein Betrieb wertet die Gehälter aller 12 Mitarbeitenden aus.	
Ein Shop befragt 100 seiner 5.000 Kunden und will etwas über alle wissen.	
Die Kurs-Umfrage: 20 Befragte stehen für die ganze Akademie.	

b) Die fünf Lernzeiten aus Übung 5 sind jetzt eine Stichprobe aus einem großen Kurs. Berechne Varianz und Standardabweichung neu.

Übung 8 Die Gehälter und der Chef

Gehört zu Abschnitt 7.

Aus dem letzten Skript: Fünf Mitarbeitende verdienen 2.400 €, 2.600 €, 2.800 €, 3.000 € und 3.200 €, Herr Bauchgefühl 14.000 €.

Fülle die Tabelle aus. Welches Streuungsmaß lässt sich vom Chefgehalt nicht beeindrucken?

	Spannweite	Q1	Q3	Quartilsabstand
alle sechs				
ohne Herrn Bauchgefühl				

Übung 9 Welches Paar passt?

Gehört zu Abschnitt 7.

Entscheide dich jeweils für „Mittelwert und Standardabweichung“ oder „Median und Quartilsabstand“.

Daten	Lagemaß und Streuungsmaß
Körpergröße der Teilnehmenden (symmetrisch verteilt)	
Monatseinkommen in einer Stadt (rechtsschief)	
Anfahrtszeit mit einem Ausreißer	
Füllmenge von Flaschen aus einer Abfüllanlage (symmetrisch)	

Übung 10 Bonus: z-Wert und Variationskoeffizient

Gehört zu Abschnitt 8.

a) Mira schreibt zwei Tests. Test 1: Mittelwert 60 Punkte, Standardabweichung 10, Mira hat 75. Test 2: Mittelwert 70 Punkte, Standardabweichung 5, Mira hat 78. In welchem Test war sie im Vergleich zu den anderen besser?

b) Anfahrt: Mittelwert 40 Minuten, Standardabweichung 10 Minuten. Gehalt: Mittelwert 3.000 €, Standardabweichung 300 €. Was streut relativ stärker?
