Statistik 6

Korrelation: Pearson, Spearman und warum Korrelation keine Ursache beweist

Gestern haben wir Streudiagramme mit den Augen gelesen: Richtung, Form, Stärke. Heute bekommt die Stärke eine Zahl. Danach lernen wir eine zweite Zahl für Ranglisten kennen und klären die wichtigste Frage des Tages: Wenn zwei Dinge zusammenhängen, verursacht dann das eine das andere?

> **Heute:** Zuerst rechnen wir kleine Beispiele von Hand. Nachmittags rechnet Pandas dieselben Zahlen für alle 20 Befragten.

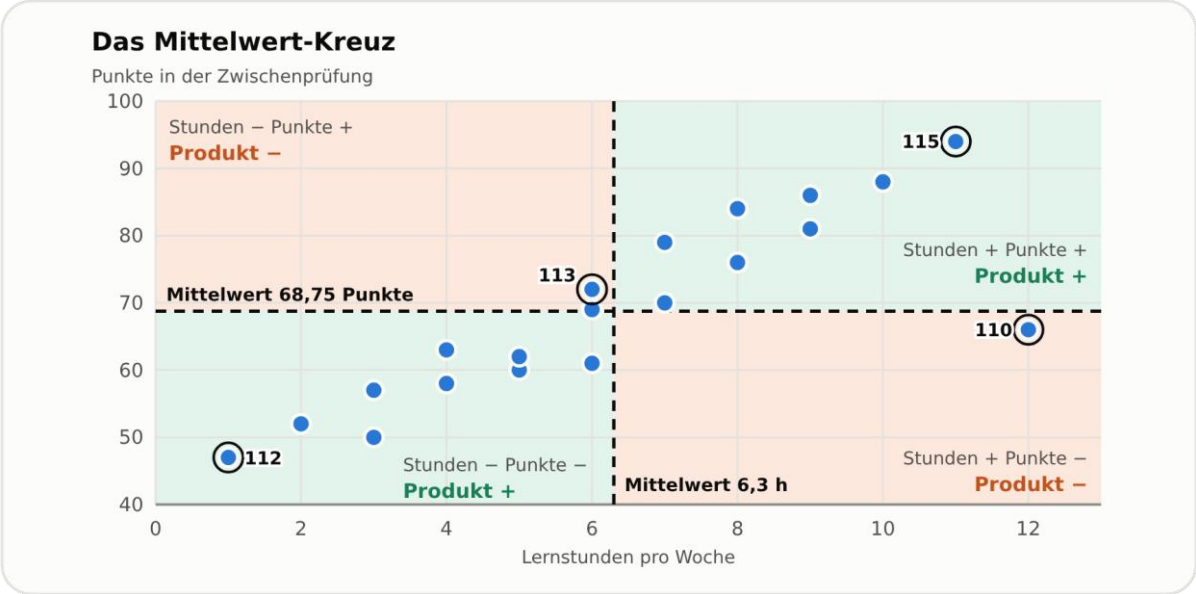
Wir arbeiten weiter mit den Spalten **Lernstunden pro Woche** und **Punkte in der Zwischenprüfung** aus Skript 5.

1 – Vom Bild zur Zahl: das Mittelwert-Kreuz



Herr Bauchgefühl behauptet:
„Gestern hieß es, der Zusammenhang sei ‚stark'. Stark ist Geschmackssache. Ich sage: mittel."

1.1 – Das Kreuz einzeichnen. Wir ziehen eine senkrechte Linie beim Mittelwert der Lernstunden (6,3) und eine waagerechte beim Mittelwert der Punkte (68,75). So entstehen vier Felder.



2.2 – Zwei Abweichungen pro Person. Jeder Punkt hat zwei Abweichungen vom Mittelwert, wie in Skript 3: eine bei den Stunden und eine bei den Punkten. Über das Vorzeichen entscheidet jeweils nur eine der beiden Linien:

- Die **senkrechte** Linie (6,3 Stunden) entscheidet über die Stunden: Wer rechts davon liegt, lernt mehr als der Durchschnitt, die Abweichung ist **plus**. Links davon ist sie **minus**.
- Die **waagerechte** Linie (68,75 Punkte) entscheidet über die Punkte: Wer oberhalb liegt, hat mehr Punkte als der Durchschnitt, die Abweichung ist **plus**. Unterhalb ist sie **minus**.
- Jedes Feld hat damit eine feste Kombination, sie steht in der Abbildung in der Ecke. Rechts unten heißt zum Beispiel: Stunden plus, Punkte minus.

1.3 – Das Produkt. Jetzt multiplizieren wir beide Abweichungen. Vier Personen als Beispiel, sie sind in der Abbildung eingekreist:

Person	Stunden	Punkte	Abw. Stunden	Abw. Punkte	Produkt	Feld
115	11	94	+4,7	+25,25	**+118,7**	rechts oben
112	1	47	−5,3	−21,75	**+115,3**	links unten
110	12	66	+5,7	−2,75	**−15,7**	rechts unten
113	6	72	−0,3	+3,25	**−1,0**	links oben

Person 115 lernt viel und hat viele Punkte: plus mal plus gibt plus. Person 112 lernt wenig und hat wenige Punkte: minus mal minus gibt **auch plus**. Beide passen zu „je mehr, desto mehr“. Person 110 lernt viel, hat aber wenige Punkte: plus mal minus gibt minus. Sie passt nicht zum Muster.

1.4 – Zählen und summieren. Von den 20 Produkten sind 17 positiv, zusammen **+664,2**. Nur drei sind negativ: Person 110 mit −15,7, Person 113 mit −1,0 und Person 118 mit −0,1, zusammen **−16,7**. Die Summe aller Produkte ist also 664,2 − 16,7 = **647,5**, deutlich positiv. Das bedeutet: Der Zusammenhang ist positiv.

Zum Vergleich die Wolke aus Skript 5, Anfahrt und Punkte: Dort sind 12 Produkte positiv mit zusammen +1 234,6 und 8 negativ mit zusammen −1 452,6. Plus und Minus heben sich weitgehend auf, die Summe ist −218. Gemessen an den einzelnen Beiträgen ist das wenig, und so sieht kein Zusammenhang aus.



Nils sagt:
„Abweichungen vom Mittelwert kenne ich von der Varianz. Neu ist nur, dass ich zwei davon multipliziere.“



Der Ausreißer meldet sich:
„Ich sitze rechts unten: viele Stunden, wenig Punkte. Mein Produkt ist −15,7, damit ziehe ich die Summe nach unten.“

1.5 – Von der Summe zur Kovarianz und weiter zu r. Die Summe der Produkte, geteilt durch n − 1, heißt **Kovarianz**: 647,5 / 19 ≈ **34,08**. Ihr Vorzeichen zeigt die Richtung. Ihre Größe hängt aber von den Einheiten

ab: Rechnet man die Lernstunden in Minuten um, wird jede Stunden-Abweichung 60-mal so groß, und die Kovarianz wächst auf 34,08 · 60 ≈ **2 044,7**. Am Zusammenhang hat sich nichts geändert, nur die Einheit.

Deshalb teilt man die Kovarianz noch durch die beiden Standardabweichungen aus Skript 3. Die Lernstunden haben s = 3,01 Stunden, die Punkte s = 13,46 Punkte:

	Kovarianz	geteilt durch	Ergebnis
in Stunden	34,08	3,01 · 13,46 = 40,51	**0,84**
in Minuten	2 044,7	180,6 · 13,46 = 2 430,6	**0,84**

Die Einheiten kürzen sich weg, und in beiden Fällen kommt dieselbe Zahl heraus. Das ist der **Korrelationskoeffizient r**. Er liegt immer zwischen −1 und 1.



Herr Bauchgefühl stutzt:
„17 von 20 in den Plus-Feldern. Gut, ‚mittel' nehme ich vorläufig zurück."

2 – Der Korrelationskoeffizient nach Pearson



Herr Bauchgefühl behauptet:
„Eine Zahl für einen Zusammenhang? Das rechnet doch kein Mensch von Hand."

Doch, für kleine Beispiele schon. Der **Korrelationskoeffizient nach Pearson**, kurz **r**, ist die Summe der Produkte, geteilt durch die Wurzel aus dem Produkt der beiden Quadratsummen:

$$r = \Sigma (x - \bar{x}) \cdot (y - \bar{y}) \;/\; \sqrt{\Sigma (x - \bar{x})^2 \cdot \Sigma (y - \bar{y})^2}$$

Fünf Personen aus einem anderen Kurs, x sind die Lernstunden, y die Punkte:

x	y	x − x̄	y − ȳ	Produkt	(x − x̄)²	(y − ȳ)²
2	55	−4	−10	40	16	100
4	60	−2	−5	10	4	25
6	70	0	5	0	0	25
8	65	2	0	0	4	0
10	75	4	10	40	16	100
x̄ = 6	**ȳ = 65**		**Summe**	**90**	**40**	**250**

2.1 – Mittelwerte. x̄ = 30 / 5 = 6 und ȳ = 325 / 5 = 65.

2.2 – Abweichungen. Von jedem Wert den Mittelwert abziehen. Zur Kontrolle: Jede Spalte der Abweichungen ergibt zusammen 0.

2.3 – Produkte. Zeile für Zeile multiplizieren und aufsummieren: 90.

2.4 – Quadratsummen. Die Abweichungen quadrieren und aufsummieren: 40 bei x, 250 bei y.

2.5 – Teilen. r = 90 / √(40 · 250) = 90 / √10 000 = 90 / 100 = **0,9**.

> **Gut zu wissen:** Ob man durch n oder durch n − 1 teilt, spielt bei r keine Rolle. Der Faktor steht oben und unten und kürzt sich weg.

Für alle 20 Befragten der Kurs-Umfrage ergibt dieselbe Rechnung **r = 0,84**. Weiter lassen wir Pandas rechnen.



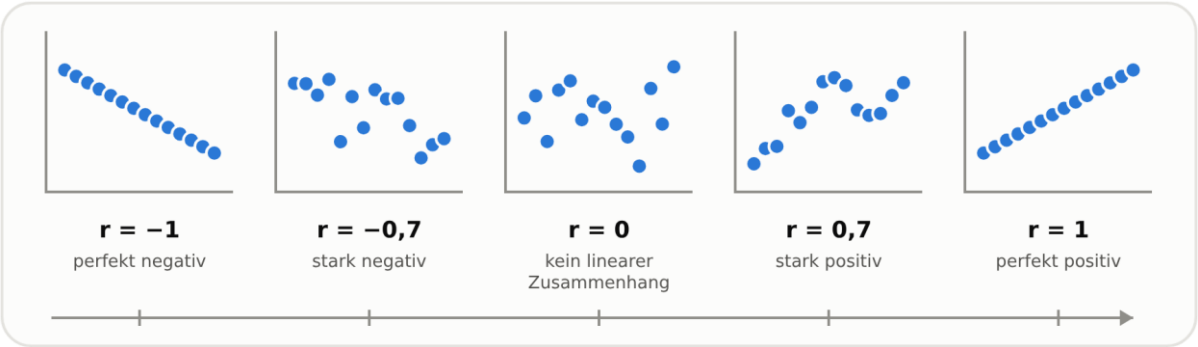
Herr Bauchgefühl stutzt:
„Fünf Spalten, eine Wurzel, fertig. Gut, das schafft sogar mein Taschenrechner."

Zum Weiterlesen: numigo: Korrelationsrechner (englisch)

3 – r lesen



Herr Bauchgefühl behauptet:
„r = 0,84 heißt: Jede Lernstunde bringt 0,84 Punkte."



3.1 – Das Vorzeichen zeigt die Richtung. Plus heißt: je mehr, desto mehr. Minus heißt: je mehr, desto weniger.

3.2 – Der Betrag zeigt die Stärke. Je näher r an 1 oder an −1 liegt, desto enger liegen die Punkte an einer geraden Linie. Bei r = 1 oder r = −1 liegen sie genau darauf. r = −0,8 ist deshalb ein **stärkerer** Zusammenhang als r = 0,5.

Betrag von r	Zusammenhang
unter 0,3	schwach
0,3 bis unter 0,7	mittel
ab 0,7	stark

Das ist eine Faustregel. Je nach Fachgebiet werden die Grenzen etwas anders gezogen.

3.3 – r hat keine Einheit. Ob man Stunden oder Minuten nimmt, Punkte oder Prozent: r bleibt gleich.

3.4 – r ist keine Steigung. Herr Bauchgefühl irrt. r sagt nur, wie eng die Punkte an einer Linie liegen, nicht wie steil diese Linie ist. Wie viele Punkte eine Stunde im Schnitt bringt, berechnet man mit einer Regression. Die kommt später.



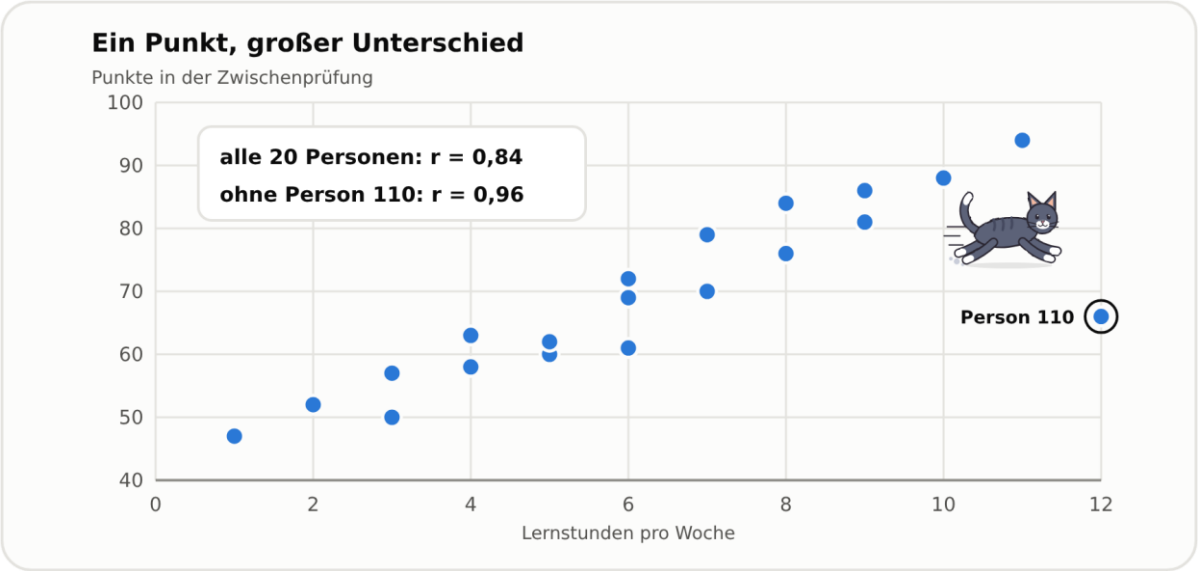
Herr Bauchgefühl stutzt:
„Keine Einheit, keine Steigung. Dann muss ich meine Präsentation ‚0,84 Punkte pro Stunde' wohl umbenennen."

4 – Wo r an seine Grenzen kommt



Herr Bauchgefühl behauptet:
„Ich brauche kein Streudiagramm mehr. Ich schaue nur noch auf r."

Grenze 1 – Ausreißer. Ein einzelner Punkt kann r deutlich verändern.

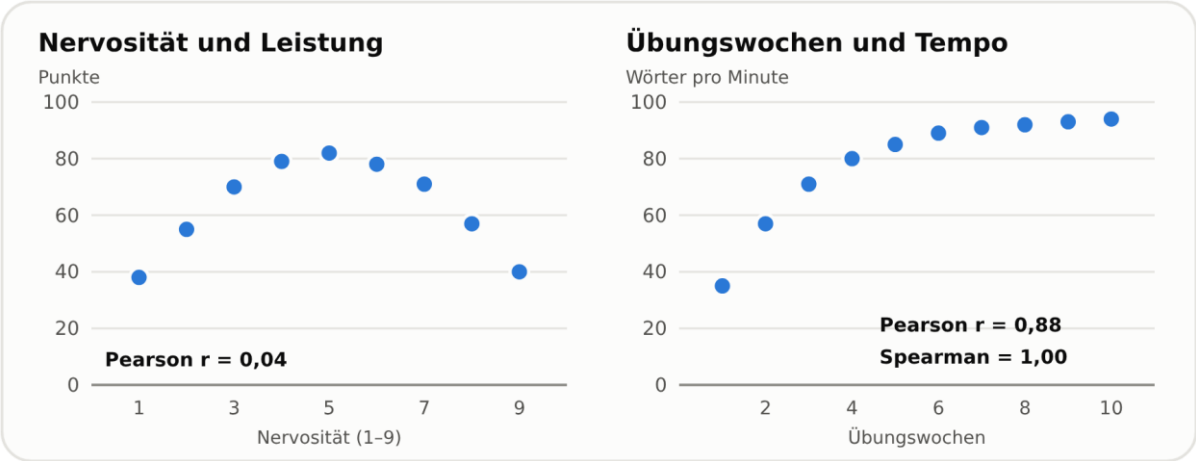


Person 110 lernt am meisten und hat trotzdem nur 66 Punkte. Mit ihr ist r = 0,84, ohne sie 0,96. Löschen darf man sie deswegen aber nicht einfach. Wie in Skript 3 gilt: erst prüfen, ob es ein Fehler ist, und im Zweifel beide Werte angeben.



Der Ausreißer meldet sich:
„Ein einziger Punkt, und r fällt um 0,12. Ich bin klein, aber ich habe Einfluss."

Grenze 2 – r misst nur gerade Zusammenhänge.



Links ein klares Muster: Zu wenig Nervosität und zu viel schaden beide. Trotzdem ist r = 0,04, weil sich die steigende und die fallende Hälfte gegenseitig aufheben. r = 0 heißt also nur: **kein linearer** Zusammenhang.

Rechts steigt das Tempo mit jeder Übungswoche, am Anfang schnell, später langsamer. Der Zusammenhang ist perfekt: mehr Wochen, immer mehr Tempo. r ist trotzdem nur 0,88, weil die Punkte auf einer Kurve liegen und nicht auf einer Geraden. Für solche Fälle gibt es eine zweite Zahl, den Spearman-Koeffizienten. Er ist hier genau 1.

> **Merke:** Erst das Streudiagramm anschauen, dann r berechnen. Nie umgekehrt.



Herr Bauchgefühl stutzt:
„r = 0,04 bei so einem schönen Bogen. Ich hole das Streudiagramm wieder aus dem Papierkorb."

5 – Spearman: Korrelation mit Rängen



Herr Bauchgefühl behauptet:
„Beim Hackathon waren sich die beiden Jurys völlig uneinig. Das sieht man doch."



Etta sagt:
„Platz 1, Platz 2, Platz 3: Ranglisten sind ordinal. Abstände gibt es da nicht, nur eine Reihenfolge. Genau dafür ist Spearman da."

5.1 – Die Idee. Wir ersetzen jeden Wert durch seinen **Rang**: der kleinste Wert bekommt Rang 1, der nächste Rang 2 und so weiter. Dann vergleichen wir die Ränge. Der **Rangkorrelationskoeffizient nach Spearman** heißt ρ (gesprochen „rho").

5.2 – Das Beispiel. Etta und Nils haben als Jury sechs Hackathon-Teams auf die Plätze 1 bis 6 gesetzt. Die Differenz der beiden Ränge heißt d.

Team	A	B	C	D	E	F	
Rang bei Etta	1	2	3	4	5	6	
Rang bei Nils	2	1	4	3	6	5	
d	−1	1	−1	1	−1	1	
d^2	1	1	1	1	1	1	$\Sigma d^2 = 6$

5.3 – Die Formel. Wenn keine Ränge doppelt vorkommen, gilt:

$$\rho = 1 - 6 \cdot \Sigma d^2 \;/\; (n \cdot (n^2 - 1))$$

Mit n = 6: ρ = 1 − 6 · 6 / (6 · 35) = 1 − 36 / 210 ≈ **0,83**. Die Jurys sind sich also ziemlich einig, sie haben nur benachbarte Teams vertauscht.

5.4 – Gleiche Werte. Kommen Werte doppelt vor, bekommen sie den Durchschnitt ihrer Ränge. Zwei gleiche Werte auf den Plätzen 3 und 4 bekommen beide Rang 3,5. Dann ist die kurze Formel nur noch eine Näherung. Programme rechnen deshalb anders: Sie bilden die Ränge und berechnen damit das ganz normale Pearson-r. Das Ergebnis ist ρ.

5.5 – Wann Spearman?

- Mindestens ein Merkmal ist **ordinal**, zum Beispiel Platzierungen, Schulnoten oder Zufriedenheit von „gar nicht" bis „sehr".
- Der Zusammenhang ist **monoton, aber nicht gerade**: Es geht immer nur in eine Richtung, aber in einer Kurve. So wie bei den Übungswochen.
- Es gibt **Ausreißer**. Ein Rang kann höchstens n sein, egal wie extrem der Wert ist.

Bei Lernstunden und Punkten ist ρ = 0,88, also etwas höher als r = 0,84. Person 110 stört Spearman weniger.



Herr Bauchgefühl stutzt:
„0,83. ‚Völlig uneinig' war wohl etwas übertrieben."

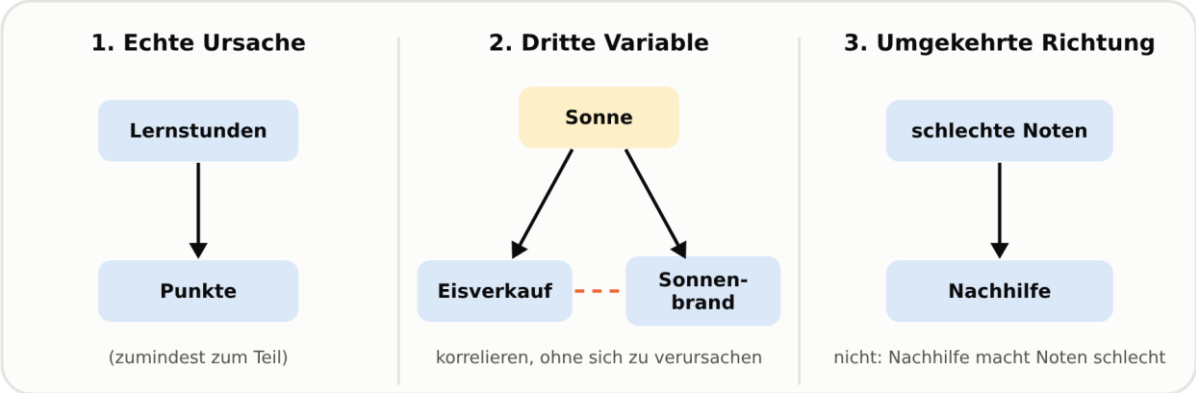
Zum Weiterlesen: numiqo: Spearman correlation (englisch)

6 – Korrelation ist nicht Kausalität



Herr Bauchgefühl behauptet:
„Lernstunden und Punkte: r = 0,84. Damit ist bewiesen, dass Lernen Punkte bringt. Und früher habe ich gezeigt, dass Kaffee Anmeldungen bringt.“

Eine Korrelation zeigt nur, **dass** zwei Merkmale gemeinsam steigen oder fallen. Sie zeigt nicht, **warum**. Mit **Kausalität** ist gemeint, dass das eine das andere verursacht. Für einen Zusammenhang gibt es mehrere mögliche Erklärungen:



6.1 – Echte Ursache. Lernen bringt Punkte. Das ist plausibel, aber r allein beweist es nicht. Vielleicht lernen motivierte Leute mehr **und** schreiben bessere Prüfungen, weil sie motiviert sind.

6.2 – Dritte Variable. An sonnigen Tagen wird mehr Eis verkauft, und es gibt mehr Sonnenbrand. Eis verursacht keinen Sonnenbrand. Beides hängt an einer dritten Variable, der Sonne. Genauso bei Herrn Bauchgefühls Kaffee aus Skript 5: Wenn mehr Leute in der Akademie sind, gibt es mehr Anmeldungen und mehr Kaffeedurst.

6.3 – Umgekehrte Richtung. Wer Nachhilfe hat, hat oft schlechtere Noten. Die Nachhilfe macht die Noten aber nicht schlecht, sondern die schlechten Noten sind der Grund für die Nachhilfe.

6.4 – Zufall und gemeinsamer Trend. Zwei Größen, die beide über die Jahre wachsen, korrelieren fast immer stark: zum Beispiel die Zahl der Teilnehmenden der Akademie und der Preis für eine Kugel Eis im Café nebenan. Beide haben nichts miteinander zu tun, sie wachsen nur gleichzeitig. Bei kleinen Stichproben kann eine Korrelation auch rein zufällig entstehen.

6.5 – Wie man eine Ursache zeigt. Mit einem **Experiment**: Man teilt Personen per Zufall in zwei Gruppen. Die eine Gruppe bekommt zum Beispiel einen Lernplan, die andere nicht. Durch die Zufallsaufteilung sind Motivation und Vorwissen in beiden Gruppen ungefähr gleich verteilt. Ist die Lernplan-Gruppe danach besser, liegt es am Lernplan.

Vier Fragen an jede Korrelation:

- Gibt es eine dritte Variable, die beide beeinflusst?
- Könnte die Richtung umgekehrt sein?
- Wachsen beide nur mit der Zeit, oder ist die Stichprobe sehr klein?

- Gab es ein Experiment mit Zufallsgruppen?



Herr Bauchgefühl stutzt:
„Also bringt Kaffee keine Anmeldungen. Ich trinke ihn trotzdem."

7 – Welches Maß wann? Und die Korrelationsmatrix

Was man berechnet, hängt vom Skalenniveau aus Skript 1 ab:

Merkmale	Werkzeug
zwei metrische, Zusammenhang ungefähr gerade	**Pearson r**
mindestens ein ordinales, oder Kurve, oder Ausreißer	**Spearman ρ**
zwei nominale	**Kreuztabelle (Skript 1), keine Korrelation**
ein nominales und ein metrisches	**Gruppen-Boxplots (Skript 5)**

Bei mehreren Merkmalen schreibt man alle Korrelationen in eine Tabelle, die **Korrelationsmatrix**. Für die Kurs-Umfrage nach Pearson:

	Anfahrt	Lernstunden	Punkte	Haustiere
Anfahrt	1	0,36	−0,04	−0,11
Lernstunden	0,36	1	0,84	−0,33
Punkte	−0,04	0,84	1	−0,22
Haustiere	−0,11	−0,33	−0,22	1

- Auf der Diagonale steht immer 1: Jedes Merkmal hängt perfekt mit sich selbst zusammen.
- Die Tabelle ist spiegelgleich, oben rechts steht dasselbe wie unten links. Eine Hälfte reicht zum Lesen.
- Der stärkste Zusammenhang ist Lernstunden und Punkte mit 0,84. Anfahrt und Punkte liegen mit −0,04 praktisch bei null.



Nils sagt:
„Sechs Zahlen, und ich sehe alle Zusammenhänge auf einen Blick. Nachmittags rechnet Pandas die ganze Tabelle in einem Schritt."

Übungen

Du brauchst Stift und Taschenrechner. Rechne Ergebnisse auf zwei Nachkommastellen.

Übung 1 Pearson von Hand

Gehört zu Abschnitt 2.

Fünf Teilnehmende haben Zehnfingerschreiben geübt. x sind die Übungsstunden, y die Tippfehler im Test.

a) Fülle die Tabelle aus.

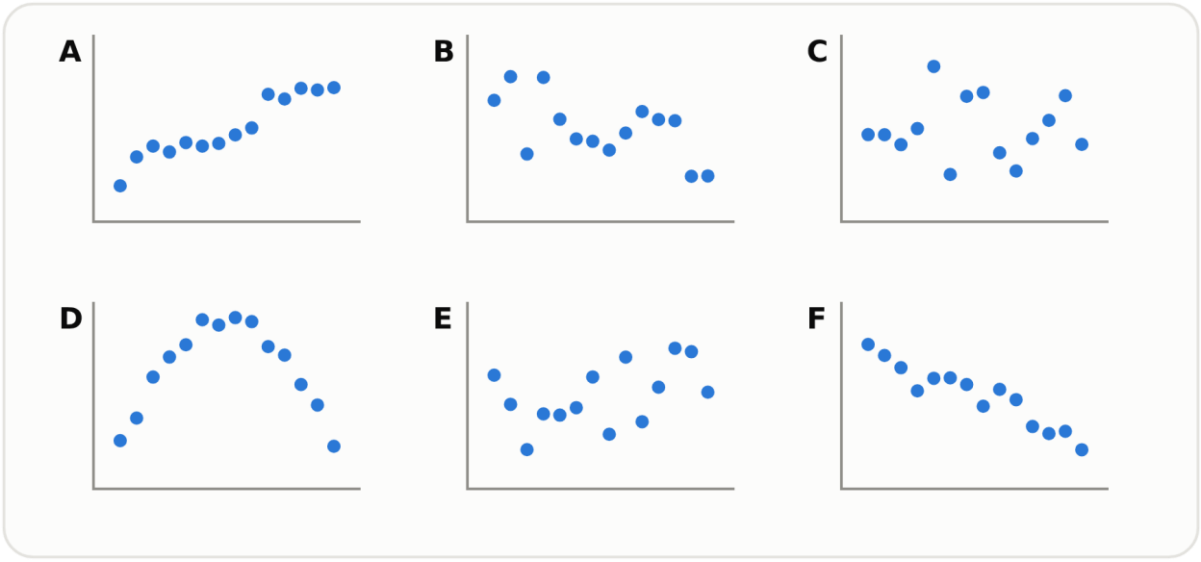
x	y	$x - \bar{x}$	$y - \bar{y}$	Produkt	$(x - \bar{x})^2$	$(y - \bar{y})^2$
1	10					
2	12					
3	8					
4	6					
5	4					
$\bar{x}$ =	$\bar{y}$ =		Summe			

b) Berechne r und beschreibe den Zusammenhang in einem Satz.

Übung 2 r schätzen

Gehört zu Abschnitt 3.

Ordne jedem Streudiagramm einen Wert zu: 0,95 · 0,45 · −0,6 · −0,95. Zwei Diagramme haben r ≈ 0.



	r
A	
B	
C	
D	
E	
F	

b) Die beiden Diagramme mit r ≈ 0 sehen ganz verschieden aus. Worin unterscheiden sie sich?

Übung 3 Richtig oder falsch?

Gehört zu Abschnitt 3.

Aussage	richtig oder falsch?
r = −0,8 ist ein schwächerer Zusammenhang als r = 0,5.	
r = 0 heißt: Es gibt überhaupt keinen Zusammenhang.	
Rechnet man die Anfahrt von Minuten in Stunden um, bleibt r gleich.	
r = 0,84 heißt: Jede Lernstunde bringt 0,84 Punkte.	
r kann nicht größer als 1 werden.	
Ein einzelner Ausreißer kann r stark verändern.	

Übung 4 Der Kater zieht

Gehört zu Abschnitt 4.

Mit Person 110 ist r = 0,84, ohne sie 0,96.

a) In welchem Feld des Mittelwert-Kreuzes liegt Person 110? Erkläre damit, warum r mit ihr kleiner ist.

---

b) Die Geschäftsführung möchte nur eine Zahl sehen. Herr Bauchgefühl schlägt vor, Person 110 zu löschen und 0,96 zu melden. Was sagst du?

Übung 5 Spearman von Hand

Gehört zu Abschnitt 5.

Fünf Teilnehmende haben angegeben, wie viele Stunden sie geschlafen haben. Danach haben sie einen Konzentrationstest gemacht.

Person	A	B	C	D	E	
Schlaf (Std.)	6	8	5	7	9	
Testpunkte	60	75	62	70	72	

a) Bilde die Ränge (kleinster Wert = Rang 1), dann d und d^2.

Person	A	B	C	D	E	
Rang Schlaf						
Rang Test						
d						
d^2						

b) Berechne ρ.

Übung 6 Zwei Jurys

Gehört zu Abschnitt 5.

Die Personalabteilung und die Teamleitung haben fünf Bewerbungen auf die Plätze 1 bis 5 gesetzt. Personalabteilung: A 1, B 2, C 3, D 4, E 5. Teamleitung: A 3, B 1, C 2, D 5, E 4. Wie einig sind sich die beiden?

Übung 7 Gleiche Werte

Gehört zu Abschnitt 5.

Bilde die Ränge für diese Anfahrtszeiten in Minuten: 12, 15, 15, 20, 31.

Übung 8 Pearson, Spearman oder keins von beiden?

Gehört zu Abschnitt 7.

Merkmale	Maß
Körpergröße und Gewicht	
Platz im Laufwettbewerb und Platz im Schwimmwettbewerb	
Schulnote und Zufriedenheit (gar nicht bis sehr)	
Lieblingsgetränk und Kurszeit	
Übungswochen und Tippgeschwindigkeit (Kurve aus Abschnitt 4)	
Anfahrt in Minuten und Punkte, mit dem Ausreißer 115	

Übung 9 Herrn Bauchgefühls Schlagzeilen

Gehört zu Abschnitt 6.

Nimm an, die Zusammenhänge wurden wirklich so gemessen. Welche Erklärung passt am besten: dritte Variable, umgekehrte Richtung oder gemeinsamer Trend? Nenne bei einer dritten Variable auch, welche es sein könnte.

Schlagzeile	Erklärung
„Kinder mit größeren Füßen lesen besser.“	
„Wer oft beim Arzt ist, ist öfter krank. Arztbesuche machen krank!“	
„Je mehr Feuerwehrleute im Einsatz sind, desto größer ist der Schaden.“	
„Seit 2015 steigen die Zahl der Smartphones und die Zahl der Zahnarztpraxen. Smartphones schaden den Zähnen!“	
„Wer ein Fitness-Armband trägt, ist sportlicher.“	

Übung 10 Die Korrelationsmatrix lesen

Gehört zu Abschnitt 7.

Nimm die Korrelationsmatrix aus Abschnitt 7.

a) Welche zwei Merkmale hängen am stärksten zusammen? Welche am schwächsten?

b) Haustiere und Lernstunden: r = −0,33. Beschreibe das in einem Satz. Darf man sagen: „Haustiere halten vom Lernen ab“?

---

c) Warum reicht es, nur die Hälfte der Tabelle zu lesen?
