Statistik 7

Vom Datensatz zum Bericht: Datenqualität, Kennzahlen, Pareto und Storytelling

Sechs Tage lang haben wir Werkzeuge gesammelt. Heute geht es darum, wie man sie im Beruf einsetzt: Daten prüfen, Kennzahlen sauber festlegen, zusammenfassen, das Wichtige vom Unwichtigen trennen und am Ende eine Seite schreiben, die eine Geschäftsführung versteht.

Schritt	Frage	Abschnitt
Prüfen	Kann ich den Daten trauen?	1
Festlegen	Was genau messe ich?	2 und 3
Zusammenfassen	Wie sieht es in den Gruppen aus?	4 und 5
Priorisieren	Was ist am wichtigsten?	6
Erzählen	Was soll die Leserin mitnehmen?	7

> **Heute:** Zuerst rechnen und schreiben wir von Hand. Später bereinigt, verbindet und pivotiert ihr echte Tabellen mit Pandas.

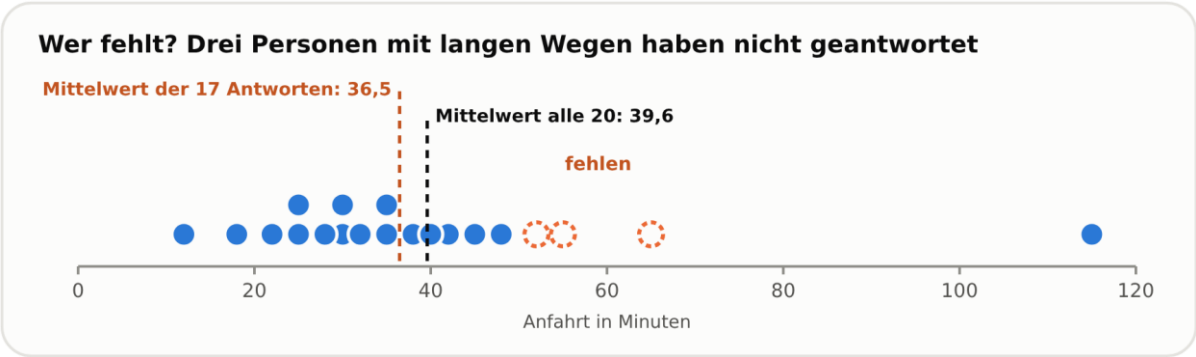
1 – Datenqualität: Kann ich den Daten trauen?



Herr Bauchgefühl behauptet:
„Die Daten kommen direkt aus dem System. Die stimmen."

Jede Kennzahl ist nur so gut wie die Daten dahinter. Fünf Fehlerarten begegnen euch in fast jeder echten Datei.

Fehler 1 – Lücken. Zuerst zählen: Wie viele Werte fehlen, und **wer** fehlt? In der Kurs-Umfrage haben drei Personen mit langen Wegen (52, 55 und 65 Minuten) die Anfahrt nicht angegeben.



Der Mittelwert der 17 Antworten ist 36,5 Minuten statt 39,6. Die Lücken sind nicht zufällig: Es fehlen gerade die langen Wege. Dann liegt jede Kennzahl daneben, egal wie sauber man danach rechnet. Fehlen dagegen nur wenige Werte rein zufällig, ist das meist harmlos.

Lücken füllen? Füllt man die drei Lücken mit dem Mittelwert 36,5, bleibt der Mittelwert gleich. Die Standardabweichung schrumpft aber von 22,4 auf 20,5 Minuten: Die Daten wirken einheitlicher, als sie sind. Mit dem Median zu füllen ist robuster gegen Ausreißer, ändert an diesem Problem aber nichts. Deshalb gilt:

- Lücken immer zählen und im Bericht nennen.
- Gefüllte Werte kennzeichnen, zum Beispiel mit einer eigenen Spalte „geschätzt“.
- Zeilen nur löschen, wenn wenige Werte zufällig fehlen.



Nils sagt:
„Ein gefüllter Wert ist eine Schätzung, kein Messwert. Ich schreibe immer dazu, welche Zahlen ich geschätzt habe.“

Fehler 2 – Dubletten. Steht Person 110 doppelt in der Tabelle, steigt der Mittelwert der Anfahrt von 39,6 auf 43,2 Minuten. Summen werden noch stärker verfälscht. Dubletten entstehen oft beim Zusammenführen von Tabellen.

Fehler 3 – Unplausible Werte. Werte, die so nicht stimmen können:

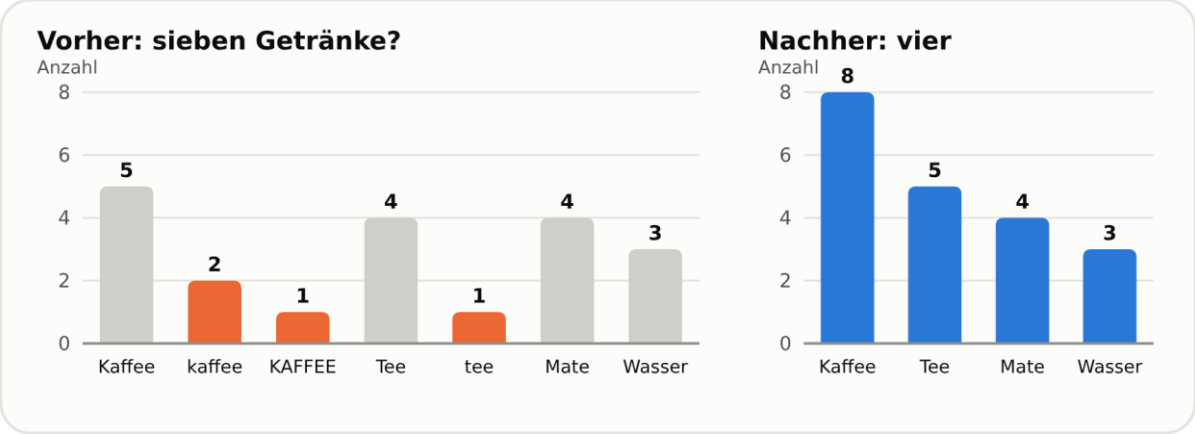
- **Außerhalb des Wertebereichs:** Alter 250, Anfahrt −5 Minuten.
- **Einheitenmix:** Jemand trägt 0,7 statt 42 ein, weil er in Stunden gedacht hat. Mittelwert und Median rutschen auf 37,5 und 33,5.
- **Logikfehler:** Prüfung vor Kursbeginn, Kurszeit „Nachts“, obwohl es nur Vormittag und Abend gibt.

Die IQR-Zäune aus Skript 3 helfen beim Finden. Aber Achtung: Ein Ausreißer ist nicht automatisch ein Fehler.



Der Ausreißer meldet sich:
„115 Minuten, und ja, die fahre ich wirklich. Bevor ihr mich löscht: erst nachfragen.“

Fehler 4 – Schreibvarianten. Für ein Programm sind „Kaffee“, „kaffee“ und „KAFFEE“ drei verschiedene Getränke. Aus vier Getränken werden sieben, und die Häufigkeitstabelle aus Skript 1 stimmt nicht mehr.



Fehler 5 – Zahlen als Text. „3,50 €“ oder „12 Min.“ sieht aus wie eine Zahl, ist für ein Programm aber Text. Damit lässt sich nichts rechnen. Auch das Komma statt des Punkts gehört dazu.

> **Das Bereinigungsprotokoll:** Schreibt jede Änderung auf: was, warum und wie viele Zeilen betroffen sind. Zum Beispiel: „3 Dubletten entfernt, 2 Anfahrten von Stunden in Minuten umgerechnet, 4 Schreibvarianten bei getraenk vereinheitlicht.“



Herr Bauchgefühl stutzt:
„Fünf Fehlerarten in einem einzigen System. Vielleicht schaue ich doch mal rein, bevor ich rechne.“

2 – Kennzahlen sauber festlegen: der KPI-Steckbrief



Herr Bauchgefühl behauptet:
„Unsere Bestehensquote liegt bei 73 %.“



Nils sagt:
„Komisch, ich habe 80 % ausgerechnet. Mit denselben Daten.“

Beide haben recht. Im letzten Kurs waren 120 Personen angemeldet, 110 sind zur Prüfung angetreten, 88 haben bestanden.

Wer?	Rechnung	Quote
Herr Bauchgefühl	bestanden / angemeldet = 88 / 120	73,3 %
Nils	bestanden / angetreten = 88 / 110	80,0 %

Der **Nenner** entscheidet. Deshalb legt man jede wichtige Kennzahl vorher in einem Steckbrief fest. Eine Kennzahl, an der eine Entscheidung hängt, heißt **KPI** (Key Performance Indicator, deutsch: Leistungskennzahl).

Feld	Beispiel: Bestehensquote
Name	Bestehensquote
Zweck	Zeigt, ob der Kurs auf die Prüfung vorbereitet
Formel	bestandene Prüfungen / angetretene Personen · 100
Datenquelle	Prüfungsliste der Akademie
Zeitraum	pro Kursdurchgang
Einheit	Prozent
Zielwert	mindestens 80 %
Verantwortlich	Kursleitung

2.1 – Nicht jede Zahl ist ein KPI. „1 000 Seitenaufrufe auf der Kursseite“ klingt gut, sagt aber nichts über den Lernerfolg. Solche Zahlen heißen auch Eitelkeitskennzahlen.

2.2 – Wenige KPIs reichen. Drei bis fünf gut definierte Kennzahlen sind besser als zwanzig, bei denen niemand mehr weiß, wie sie berechnet werden.

2.3 – Brücke zu Power BI. Dort heißt eine fest definierte Kennzahl „Measure“. Der Steckbrief ist genau die Vorarbeit dafür.



Herr Bauchgefühl stutzt:
„Gleiche Daten, zwei Quoten. Ab jetzt schreibe ich den Nenner dazu.“

3 – Prozent oder Prozentpunkte?



Herr Bauchgefühl behauptet:
„Die Bestehensquote ist von 60 auf 75 % gestiegen. Also um 15 %.“

Fast richtig, und genau das ist die Falle. Vergleicht man zwei Prozentwerte, gibt es zwei Antworten:

Frage	Rechnung	Ergebnis
Um wie viele **Prozentpunkte** ist die Quote gestiegen?	75 − 60	15 Prozentpunkte
Um wie viel **Prozent** ist die Quote gestiegen?	(75 − 60) / 60	25 %

3.1 – Prozentpunkte sind der einfache Abstand zwischen zwei Prozentwerten.

3.2 – Prozent beschreiben die Veränderung im Verhältnis zum Ausgangswert, wie bei jeder anderen Zahl auch.

3.3 – Absolut oder relativ? „Die Abbrüche haben sich verdoppelt!“ kann heißen: von 1 auf 2 von 100 Teilnehmenden. Eine relative Angabe braucht immer die Basis dazu.



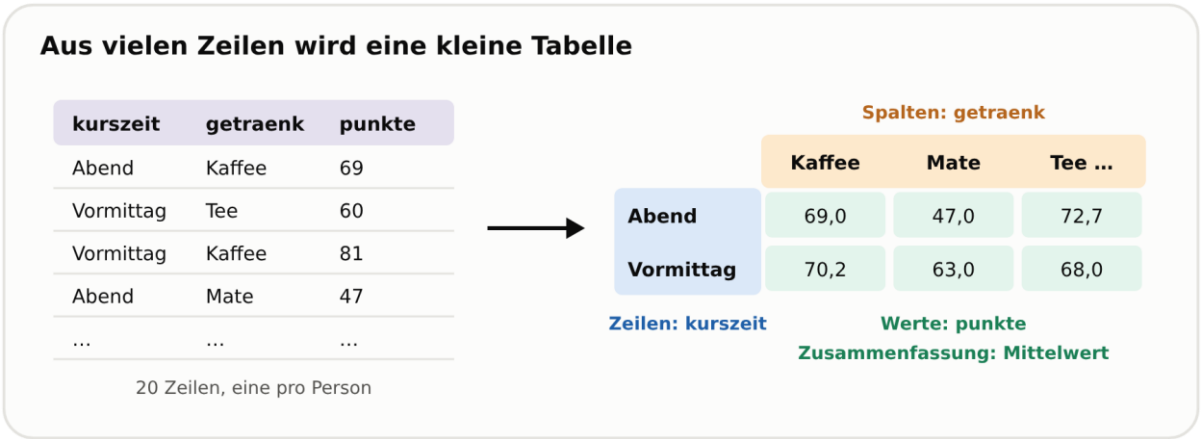
Herr Bauchgefühl stutzt:
„15 Punkte oder 25 Prozent. Für die Präsentation nehme ich natürlich … nein, ich nehme beides und sage, was was ist.“

4 – Die Pivot-Tabelle



Herr Bauchgefühl behauptet:
„Zwanzig Zeilen lese ich nicht. Sagt mir einfach, wie die Gruppen abschneiden.“

Dafür gibt es die **Pivot-Tabelle**. Sie ist der große Bruder der Kreuztabelle aus Skript 1: Die Kreuztabelle zählt, die Pivot-Tabelle fasst einen beliebigen Wert zusammen.



4.1 – Vier Zutaten. Zeilen (wonach gruppiere ich nach unten?), **Spalten** (wonach gruppiere ich nach rechts?), **Werte** (welche Spalte fasse ich zusammen?) und die **Zusammenfassung** (Mittelwert, Summe oder Anzahl). Genau diese vier Felder findet ihr in Excel unter PivotTable und in Power BI in der Matrix.

4.2 – Das Beispiel. Mittlere Punkte der Zwischenprüfung nach Kurszeit und Getränk. In Klammern steht, wie viele Personen dahinterstehen.

	Kaffee	Mate	Tee	Wasser	gesamt
Abend	69,0 (2)	47,0 (1)	72,7 (3)	77,0 (2)	69,6 (8)
Vormittag	70,2 (6)	63,0 (3)	68,0 (2)	72,0 (1)	68,2 (12)
gesamt	**69,9 (8)**	**59,0 (4)**	**70,8 (5)**	**75,3 (3)**	**68,8 (20)**

4.3 – Die Falle der kleinen Zellen. „Mate-Trinker am Abend schneiden schlecht ab!“ Dahinter steckt eine einzige Person. Deshalb gehört zu jedem Mittelwert in einer Pivot-Tabelle die Anzahl.

4.4 – Die Randzeile ist gewichtet. Die 69,9 bei Kaffee ist nicht der Mittelwert von 69,0 und 70,2, sondern der Mittelwert aller acht Kaffeetrinker. Der Vormittag zählt mit sechs Personen stärker. Das ist das gewichtete Mittel aus Skript 2.



Etta sagt:
„Zeilen und Spalten sind bei mir immer Kategorien. Je feiner ich sortiere, desto kleiner werden die Fächer. Dann zähle ich lieber nach.“

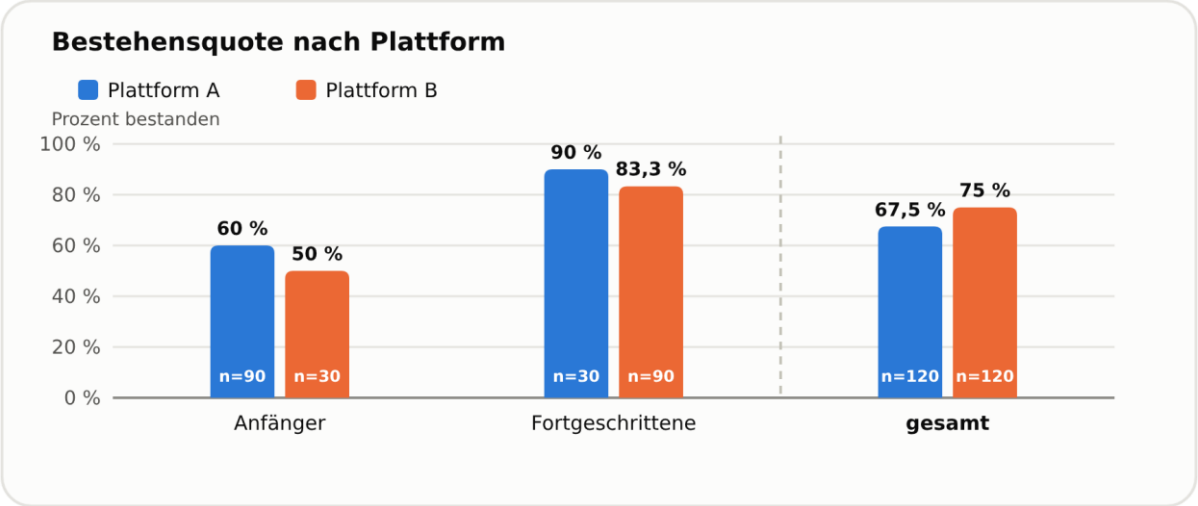
5 – Das Simpson-Paradoxon



Herr Bauchgefühl behauptet:
„Wir nehmen Lernplattform B. Dort haben 75 % bestanden, bei Plattform A nur 67,5 %.“

Die Akademie hat zwei Lernplattformen getestet. Nimmt man das Vorwissen als zweite Dimension in die Pivot-Tabelle, dreht sich das Bild um:

	Plattform A	Plattform B
Anfänger	54 von 90 = **60 %**	15 von 30 = 50 %
Fortgeschrittene	27 von 30 = **90 %**	75 von 90 ≈ 83 %
gesamt	81 von 120 = 67,5 %	90 von 120 = **75 %**



5.1 – Das Paradoxon. In **jeder** Gruppe ist Plattform A besser. Insgesamt liegt trotzdem B vorne. Das nennt man **Simpson-Paradoxon**.

5.2 – Die Erklärung. Plattform A wurde vor allem von Anfängern genutzt (90 von 120), Plattform B vor allem von Fortgeschrittenen. Anfänger bestehen seltener. A hatte also die schwierigere Gruppe, und das zieht die Gesamtquote nach unten. Die Gesamtquote ist ein gewichtetes Mittel, und die Gewichte sind hier sehr ungleich verteilt.



Mats Maulwurf meldet sich:
„Da bin ich wieder, die dritte Variable. Diesmal heiße ich Vorwissen. Wer mich übersieht, entscheidet sich für die falsche Plattform."

5.3 – Was tun? Bei Vergleichen immer fragen, ob sich die Gruppen in etwas Wichtigem unterscheiden. Wenn ja: die Pivot-Tabelle um diese Dimension erweitern und in den Untergruppen vergleichen.



Herr Bauchgefühl stutzt:
„Eine Spalte mehr, und meine Entscheidung dreht sich um. Gut, dass ich noch nicht unterschrieben habe."

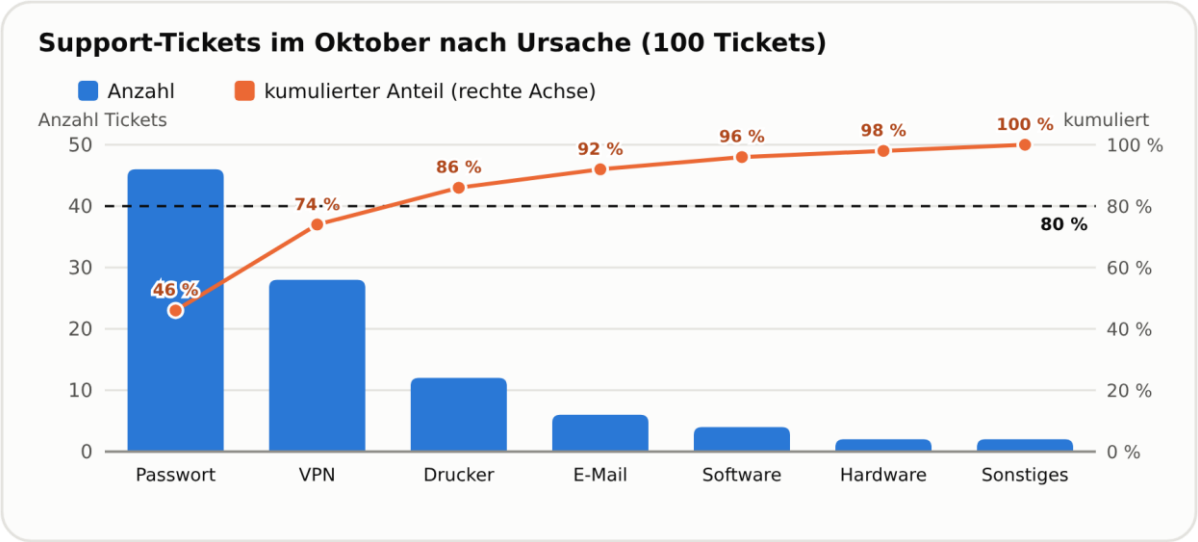
6 – Pareto-Prinzip und ABC-Analyse



Herr Bauchgefühl behauptet:
„Im IT-Support sind alle Probleme gleich wichtig. Wir arbeiten sie der Reihe nach ab."

Das Pareto-Prinzip. Oft verursachen wenige Ursachen den Großteil der Wirkung. Als Faustregel heißt das 80/20: 20 % der Ursachen sind für 80 % der Wirkung verantwortlich. Das ist eine Beobachtung, kein Gesetz, die Zahlen sind selten genau 80 und 20.

Das Pareto-Diagramm. Der IT-Support hat im Oktober 100 Tickets nach Ursache gezählt.



6.1 – Sortieren. Die Ursachen absteigend nach Häufigkeit ordnen.

6.2 – Balken zeichnen. Wie beim Balkendiagramm aus Skript 4, nur eben sortiert.

6.3 – Kumulieren. Die Anteile aufaddieren: 46 %, dann 46 + 28 = 74 %, dann 86 % und so weiter. Diese Werte als Linie über die Balken legen, mit einer eigenen Prozentachse rechts.

6.4 – Lesen. Passwort und VPN, also 2 von 7 Ursachen, machen 74 % aller Tickets aus. Wer dort ansetzt, zum Beispiel mit einer Selbstbedienung für Passwörter, spart am meisten Arbeit.

> **Moment mal:** In Skript 5 war die zweite y-Achse ein Trick. Hier ist sie ehrlich, weil beide Achsen dieselbe Größe zeigen: links die Anzahl, rechts den Anteil an genau diesen 100 Tickets. Die Linie wird nicht künstlich über die Balken geschoben, sie ergibt sich aus denselben Zahlen.

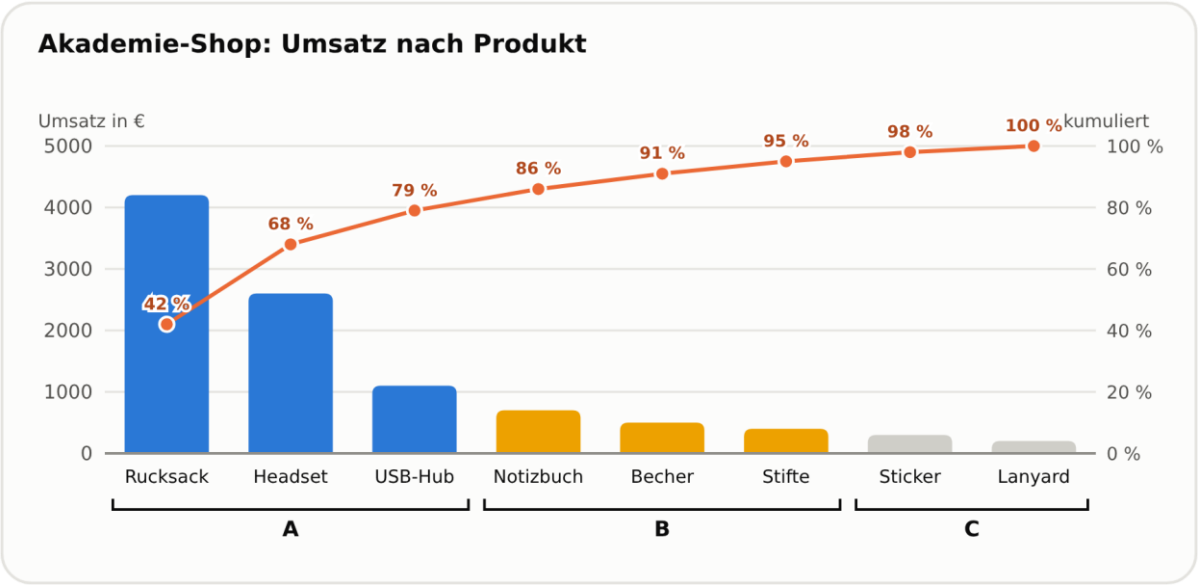
Die ABC-Analyse. Sie teilt die sortierten Elemente nach ihrem kumulierten Anteil in drei Klassen ein. Wir verwenden diese Grenzen:

Klasse	kumulierter Anteil	Bedeutung
A	bis einschließlich 80 %	wenige, sehr wichtige Elemente
B	über 80 bis einschließlich 95 %	mittlere Bedeutung
C	über 95 %	viele Elemente mit wenig Gewicht

In der Praxis werden auch andere Grenzen verwendet, zum Beispiel 70 und 90 %. Wichtig ist, sie vorher festzulegen.

Beispiel Akademie-Shop. Acht Produkte, zusammen 10 000 € Umsatz im Jahr.

Produkt	Umsatz (€)	Anteil	kumuliert	Klasse
Rucksack	4 200	42 %	42 %	A
Headset	2 600	26 %	68 %	A
USB-Hub	1 100	11 %	79 %	A
Notizbuch	700	7 %	86 %	B
Becher	500	5 %	91 %	B
Stifte	400	4 %	95 %	B
Sticker	300	3 %	98 %	C
Lanyard	200	2 %	100 %	C



Drei von acht Produkten, also 37,5 % des Sortiments, bringen 79 % des Umsatzes. A-Produkte werden eng beobachtet: Lagerbestand, Preis, Lieferzeit. Bei C-Produkten lohnt sich wenig Aufwand, man vereinfacht die Bestellung oder nimmt sie aus dem Sortiment.



Nils sagt:
„Sortieren, aufaddieren, Grenzen ziehen. Mehr ist es nicht, und trotzdem weiß man danach, wo man anfangen muss."



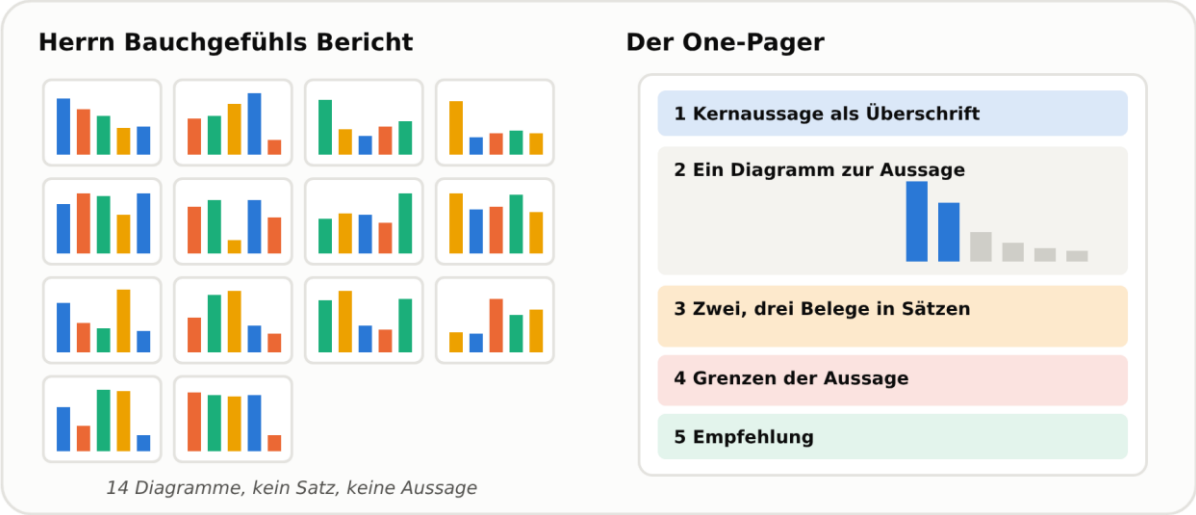
Herr Bauchgefühl stutzt:
„Zwei Ursachen, drei Viertel der Tickets. Ich fange wohl doch nicht beim Drucker an."

7 – Daten-Storytelling: der One-Pager



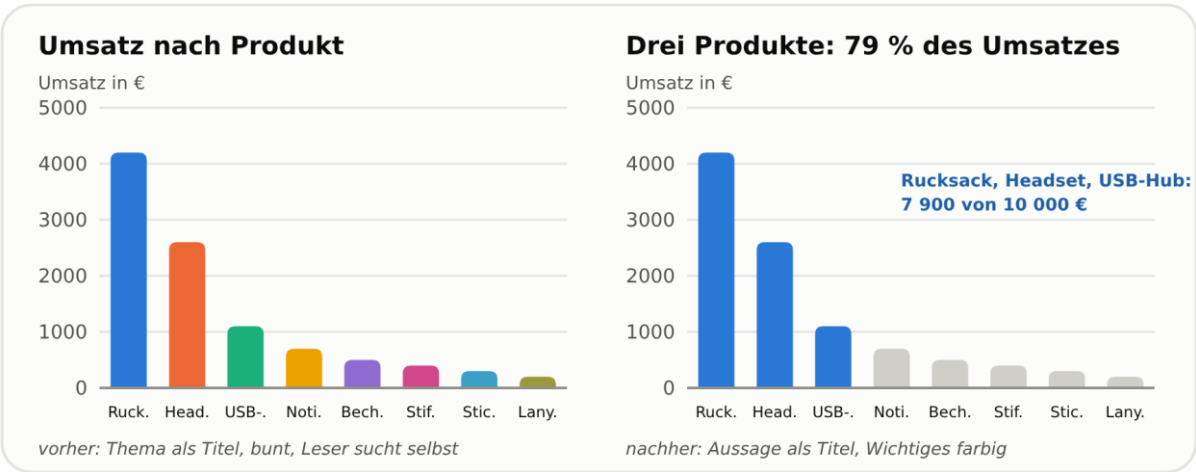
Herr Bauchgefühl behauptet:
„Ich habe der Geschäftsführung 14 Diagramme geschickt. Die Daten sprechen für sich.“

Das tun sie nicht. Eine Geschäftsführung hat wenig Zeit und will wissen, was los ist und was zu tun ist. Dafür gibt es den **One-Pager**: eine Seite, eine Aussage.



7.1 – Kernaussage als Überschrift. Ein ganzer Satz mit Zahl, nicht das Thema. Also „Drei Produkte bringen 79 % des Umsatzes“ statt „ABC-Analyse Akademie-Shop“. Wer nur die Überschrift liest, hat das Wichtigste.

7.2 – Ein Diagramm, das genau diese Aussage zeigt. Der Titel des Diagramms sagt, was man sehen soll. Das Wichtige ist farbig, der Rest grau. Achsen beschriften, Quelle nennen, keine Tricks aus Skript 5.



7.3 – Zwei, drei Belege in Sätzen. Zum Beispiel: „Der Rucksack allein bringt 42 % des Umsatzes. Die drei C-Produkte zusammen nur 5 %.“ Zahlen gerundet, keine Tabellenwüste.

7.4 – Grenzen der Aussage. Ehrlich sagen, was die Zahlen nicht zeigen: Wie groß ist die Datenbasis, welcher Zeitraum? Was wurde bereinigt oder geschätzt? Ist es ein Zusammenhang oder eine Ursache? Gibt es kleine Gruppen?

7.5 – Empfehlung. Was soll jetzt passieren? Zum Beispiel: „Lagerbestand der A-Produkte wöchentlich prüfen, Sticker und Lanyard nur noch auf Bestellung.“



Etta sagt:
„Erst die Frage, dann die Zahl, dann das Bild. Und zum Schluss das Etikett: Was heißt das?“

Die Checkliste für jeden Bericht, gesammelt aus allen sieben Tagen:

- Passt das Lagemaß zur Verteilung? Mittelwert oder Median? (Skript 2)
- Steht die Streuung dabei, nicht nur der Durchschnitt? (Skript 3)
- Passt das Diagramm, und ist es frei von Tricks? (Skripte 4 und 5)
- Ist ein Zusammenhang als Zusammenhang formuliert und nicht als Ursache? (Skript 6)
- Sind Lücken, Dubletten und Bereinigungen genannt? (Abschnitt 1)
- Ist der Nenner jeder Quote klar, und stimmen Prozent und Prozentpunkte? (Abschnitte 2 und 3)
- Stehen bei Gruppenwerten die Gruppengrößen dabei? (Abschnitte 4 und 5)



Herr Bauchgefühl stutzt:
„Eine Seite statt 14 Diagramme. Und die Geschäftsführung hat zum ersten Mal zurückgeschrieben.“

Übungen

Du brauchst Stift, Lineal und Taschenrechner. Für Übung 9 gibt es eine Vorlage zum Hineinzeichnen.

Übung 1 Was das Füllen mit der Streuung macht

Gehört zu Abschnitt 1.

Sieben Personen sollten ihre Lernstunden angeben. Fünf haben geantwortet: 2, 4, 6, 8 und 10 Stunden. Zwei Werte fehlen.

a) Berechne Mittelwert und Standardabweichung (mit n − 1) der fünf Antworten.

---

b) Fülle die zwei Lücken mit dem Mittelwert und rechne beides noch einmal für alle sieben Werte.

---

c) Was fällt dir auf, und was schreibst du in den Bericht?

Übung 2 Dubletten

Gehört zu Abschnitt 1.

Eine Liste von Bestellungen: B1 120 €, B2 80 €, B3 200 €, B2 80 €, B4 100 €, B3 200 €.

a) Berechne Summe und Mittelwert, so wie die Liste ist.

---

b) Entferne die Dubletten und rechne neu. Um wie viel Prozent war die Summe zu hoch?

Übung 3 Plausibel oder nicht?

Gehört zu Abschnitt 1.

Finde in jeder Zeile den Fehler und formuliere eine Prüfregel, die ihn künftig findet.

Eintrag	Prüfregel
Alter: 250	
Anfahrt: −5 Minuten	
Kurszeit: Nachts	
Anfahrt: 0,7	
E-Mail: julia.beispiel.de	
Prüfung am 03.03., Kursbeginn am 10.03.	

Übung 4 Schreibvarianten

Gehört zu Abschnitt 1.

Lieblingsgetränke von zwölf Personen: Kaffee · kaffee · Tee · KAFFEE · Mate · tee · Kaffee · Wasser · „Kaffee “ (mit Leerzeichen am Ende) · Mate · Tee · kaffee

a) Wie viele verschiedene Getränke zählt ein Programm, das Groß- und Kleinschreibung und Leerzeichen genau nimmt?

---

b) Erstelle die bereinigte Häufigkeitstabelle.

Getränk	Anzahl
Kaffee	
Tee	
Mate	
Wasser	

Übung 5 Zwei Nenner

Gehört zu Abschnitt 2.

Für eine Umfrage waren 30 Personen angemeldet, 25 waren am Umfragetag anwesend, 20 haben geantwortet.

a) Berechne die Antwortquote auf zwei Arten.

---

b) Fülle den Steckbrief für die Kennzahl aus, die du für sinnvoller hältst.

Feld	Eintrag
Name	
Zweck	
Formel	
Datenquelle	
Zeitraum	
Einheit	
Zielwert	

Übung 6 Prozent oder Prozentpunkte?

Gehört zu Abschnitt 3.

Aussage	Prozentpunkte und Prozent
Die Abschlussquote steigt von 40 % auf 50 %.	
In einer Stadt sinkt eine Quote von 6 % auf 5 %.	
Die Abbruchquote steigt von 2 % auf 4 %.	

Herr Bauchgefühl schreibt zur letzten Zeile: „Abbrüche verdoppelt, die Akademie ist in der Krise!“ Was antwortest du?

Übung 7 Eine Pivot-Tabelle von Hand

Gehört zu Abschnitt 4.

Umsätze in Tausend Euro aus zwölf Verkäufen:

Filiale	Nord	Nord	Nord	Nord	Nord	Nord	Süd	Süd	Süd	Süd	Süd	Süd
Quartal	Q1	Q1	Q1	Q2	Q2	Q2	Q1	Q1	Q1	Q2	Q2	Q2
Umsatz	10	14	12	12	16	11	8	9	13	20	18	7

a) Baue die Pivot-Tabelle: Zeilen Filiale, Spalten Quartal, Werte Umsatz, Zusammenfassung Summe. Ergänze die Randsummen.

	Q1	Q2	gesamt
Nord			
Süd			
gesamt			

b) Welche Filiale ist besser? Was zeigt die Pivot-Tabelle, was eine einzige Gesamtzahl verschweigt?

Übung 8 Simpson im Support

Gehört zu Abschnitt 5.

Zwei Support-Teams lösen Tickets möglichst beim ersten Anruf. Team Nord: einfache Tickets 70 von 80 gelöst, schwere 6 von 20. Team Süd: einfache 18 von 20, schwere 28 von 80.

a) Berechne für jedes Team die Lösungsquote bei einfachen, bei schweren und bei allen Tickets.

Tickets	Team Nord	Team Süd
einfach		
schwer		
gesamt		

b) Welches Team arbeitet besser? Wer ist hier die dritte Variable?

Übung 9 Ein Pareto-Diagramm von Hand

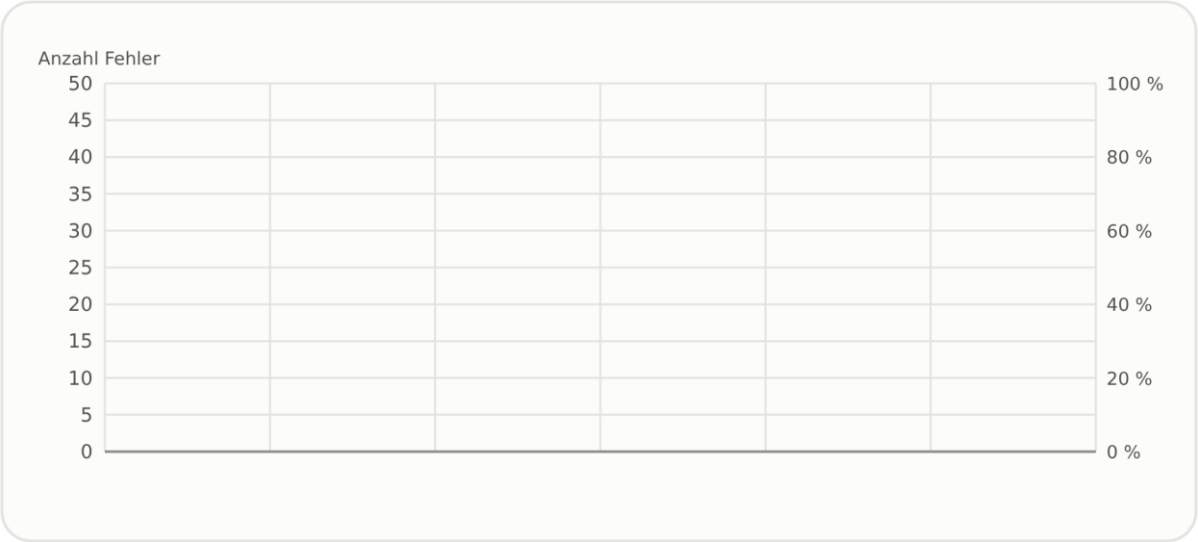
Gehört zu Abschnitt 6.

Ein Onlineshop hat 100 Bestellfehler nach Ursache gezählt: falsche Adresse 18, Artikel vergriffen 42, Zahlung fehlgeschlagen 9, falscher Artikel geliefert 21, Lieferverzug 6, Sonstiges 4.

a) Sortiere die Ursachen und berechne die kumulierten Anteile.

Ursache	Anzahl	kumuliert

b) Zeichne das Pareto-Diagramm in die Vorlage: Balken und kumulierte Linie.



c) Bei welchen Ursachen sollte der Shop zuerst ansetzen?

Übung 10 ABC-Analyse im Café

Gehört zu Abschnitt 6.

Jahresumsatz des Akademie-Cafés in Euro: Kaffee 3 600, belegte Brötchen 2 200, Kuchen 1 400, Mate 800, Tee 800, Wasser 500, Müsliriegel 400, Obst 300. Teile in A, B und C ein (Grenzen 80 % und 95 %).

Produkt	kumuliert	Klasse
Kaffee		
Brötchen		
Kuchen		
Mate		
Tee		
Wasser		
Müsliriegel		
Obst		

b) Formuliere die Kernaussage als einen Satz mit Zahl.

Übung 11 Überschriften mit Aussage

Gehört zu Abschnitt 7.

Schreibe jede Überschrift in eine Kernaussage um.

Überschrift	Kernaussage
Support-Tickets Oktober	
Lernstunden und Punkte	
Anfahrt nach Kurszeit	
Bestehensquote nach Plattform	

Übung 12 Herrn Bauchgefühls One-Pager

Gehört zu Abschnitt 7.

Herr Bauchgefühl hat einen One-Pager geschrieben:

> **Überschrift:** „Auswertung Lernplattformen“. **Diagramm:** Balken „Bestehensquote gesamt“, B 75 %, A 67,5 %, y-Achse beginnt bei 60 %. **Text:** „Plattform B ist klar besser. Wir wechseln komplett zu B.“

a) Finde mindestens vier Schwächen.

---

b) Schreibe eine bessere Überschrift und zwei Sätze zu den Grenzen der Aussage.
